

Trabajo de Fin de Grado

Estudio de técnicas de Machine Learning basadas en fingerprinting aplicadas al posicionamiento en interiores - C

TITULACIÓN: Grado en Ingeniería Informática

AUTOR: Juan Francisco Del Rosario Machin

TUTORIZADO POR:
De Blasio Gabriele Salvatore
Jose Carlos Rodriguez Rodriguez

Fecha Julio/2026

ULPGC Universidad de Las Palmas de Gran Canaria | EII ESCUELA DE INGENIERÍA INFORMÁTICA

TFT04

SOLICITUD DE DEFENSA DE TRABAJO DE FIN DE TÍTULO

D./Dª Juan Francisco Del Rosario Machin, autor del trabajo 'Estudio de técnicas de Machine Learning basadas en fingerprinting aplicadas al posicionamiento en interiores - C', correspondiente a la titulación Grado en Ingeniería Informática.

SOLICITA

que se inicie el procedimiento de defensa del mismo, para lo que se adjunta la documentación requerida, haciendo constar que

[X] se autoriza / [ ] no se autoriza la grabación en audio de la exposición y turno de preguntas.

Asimismo, con respecto al registro de la propiedad intelectual/industrial del TFT, declara que:

[ ] Se ha iniciado o hay intención de iniciarlo (defensa no pública).

[X] No está previsto.

Y para que así conste firma la presente. (fecha en firma electrónica)

El/La estudiante

Fdo.————————

A rellenar y firmar **obligatoriamente** por el/la/los/las tutores

En relación con la presente solicitud, se informa:(firmar donde corresponda)

Positivamente (en caso de detección de copia, esta firma quedará invalidada)	Negativamente (justificación en TFT05)
Fdo.————————	Fdo.————————

DIRECTOR DE LA ESCUELA DE INGENIERÍA INFORMÁTICA

Agradecimientos

Quiero expresar mi más sincero agradecimiento a mis padres y a mi pareja, las personas más cercanas a mí, quienes han sido testigos de primera mano del esfuerzo, la dedicación y el compromiso que he puesto en todo lo que hago. Gracias por su apoyo incondicional, su paciencia y por acompañarme en cada etapa de este camino.

Asimismo, agradezco al Instituto Universitario de Cibernética por brindarnos su tiempo, conocimiento y experiencia, contribuyendo de manera significativa a nuestro aprendizaje y desarrollo.

Por último, quiero agradecer a mis compañeros Eduardo Gainza Koller, Alejandro Armas Trujillo y Alberto Ramos Sánchez, con quienes he tenido la oportunidad de colaborar y trabajar codo con codo durante todo este proceso. Su esfuerzo, compañerismo y dedicación han sido fundamentales para alcanzar este resultado.

Resumen

Este trabajo aborda el problema del posicionamiento en entornos interiores, donde los sistemas de navegación por satélite, como GNSS (Global Navigation Satellite System), presentan importantes limitaciones debido a la atenuación, reflexión y bloqueo de las señales. Estas dificultades reducen la precisión de las estimaciones de posición en espacios cerrados, lo que hace necesario el estudio de alternativas específicas para este tipo de escenarios.

Dentro del amplio conjunto de soluciones existentes, este proyecto se centra en los IPS (Sistemas de Posicionamiento en Interiores) basados en tecnología BLE (Bluetooth Low Energy). En particular, se estudia el uso de técnicas de *fingerprinting*, que permiten estimar la posición de un objeto o individuo a partir de patrones de intensidad de señal recibida, RSSI (Received Signal Strength Indicator), previamente registrados en un entorno controlado.

Para ello, se ha empleado la plataforma robótica ROBOMAP, desarrollada por el IUCES (Instituto Universitario de Cibernética, Empresa y Sociedad), con el objetivo de automatizar la toma de datos y mejorar la precisión del proceso de adquisición. La campaña experimental se ha dividido en nueve campañas de medida, en las que la plataforma recorre una serie de puntos de referencia definidos. En cada uno de estos puntos se recopilan paquetes de señales Bluetooth en cuatro orientaciones distintas: norte, sur, este y oeste.

Una vez construida la base de datos a partir de las campañas realizadas, se lleva a cabo un proceso de tratamiento y preparación de los datos para su posterior análisis. A partir de estos datos procesados, se implementan y evalúan modelos de aprendizaje profundo mediante la librería PyTorch, comparando sus resultados con el algoritmo WKNN (Weighted k-Nearest Neighbors), ampliamente utilizado en sistemas de posicionamiento basados en *fingerprinting*.

Finalmente, mediante la herramienta IPSCampaign, se integran los algoritmos desarrollados y se obtienen métricas de evaluación que permiten analizar la precisión y exactitud del posicionamiento. De esta forma, el trabajo contribuye al estudio y comparación de técnicas de ML (Machine Learning) y DL (Deep Learning) aplicadas al posicionamiento en interiores mediante señales BLE.

Abstract

This work addresses the problem of positioning in indoor environments, where satellite navigation systems, such as GNSS (Global Navigation Satellite System), present significant limitations due to signal attenuation, reflection and blockage. These difficulties reduce the accuracy of position estimates in enclosed spaces, making it necessary to study specific alternatives for this type of scenario.

Among the wide range of existing solutions, this project focuses on IPS (Sistemas de Posicionamiento en Interiores) based on BLE (Bluetooth Low Energy) technology. In particular, it studies the use of *fingerprinting* techniques, which make it possible to estimate the position of an object or individual from previously recorded received signal strength patterns, RSSI (Received Signal Strength Indicator), in a controlled environment.

For this purpose, the robotic platform ROBOMAP, developed by the IUCES (Instituto Universitario de Cibernética, Empresa y Sociedad), has been used to automate data collection and improve the accuracy of the acquisition process. The experimental data collection was divided into nine measurement campaigns, in which the platform followed a route through a set of predefined reference points. At each of these points, Bluetooth signal packets were collected in four different orientations: north, south, east and west.

Once the database was built from the campaigns carried out, the collected data were treated and prepared for further analysis. Using these processed data, deep learning models were implemented and evaluated with the PyTorch library, and their results were compared with those obtained using the WKNN (Weighted k-Nearest Neighbors) algorithm, which is widely used in positioning systems based on *fingerprinting*.

Finally, through the IPSCampaign tool, the developed algorithms were integrated and evaluation metrics were obtained to analyse the precision and accuracy of the positioning estimates. In this way, this work contributes to the study and comparison of ML (Machine Learning) and DL (Deep Learning) techniques applied to indoor positioning using BLE signals.

Índice general

1. Introducción **1**

2. Estado del arte **4**
2.1. Estado actual del posicionamiento en interiores 4
2.2. Tecnología Bluetooth Low Energy 6
2.3. Técnicas de fingerprinting 7
2.4. Algoritmos de posicionamiento basados en fingerprinting 8

3. Objetivos **9**
3.1. Objetivo general 9
3.2. Objetivos específicos 10

4. Aportaciones del trabajo **11**
4.1. Principales aportaciones 11
4.2. Objetivos de Desarrollo Sostenible 12

5. Competencias específicas desarrolladas **13**

6. Metodología y planificación **15**
6.1. Metodología CRISP-DM 15
6.2. Aplicación de la metodología al trabajo 16

7. Tecnologías y herramientas utilizadas **17**
7.1. Plataforma ROBOMAP 17
7.2. Sistema Marvelmind y balizas de ultrasonido 18
7.3. Balizas BLE Kontakt.io 19
7.4. Blender y Robotcontrol Editor Toolbox 20
7.5. Herramienta IPSCampaign 21
7.6. Python 22
7.6.1. PyTorch 22
7.6.2. Scikit-learn 22

8. Diseño de la campaña de toma de datos **23**
8.1. Escenario 23
8.2. Diseño de las campañas 28

8.3. Puntos de referencia . . . 29
8.4. Orientaciones de medida . . . 30
8.5. Procedimiento de adquisición . . . 30

9. Tratamiento y preparación de los datos 31
9.1. Bases de datos generadas . . . 32
9.2. Análisis de calidad y definición de los escenarios . . . 34
9.3. Limpieza y normalización de los datos . . . 35
9.4. Transformación de los datos . . . 35
9.4.1. Construcción de las matrices para WKNN . . . 36
9.4.2. Construcción de fingerprints para los modelos neuronales . . . 37
9.5. Preparación de los conjuntos de referencia, entrenamiento y evaluación . . . 38
9.6. Formato final de los datos . . . 39

10. Implementación de algoritmos de posicionamiento 40
10.1. Algoritmo WKNN . . . 40
10.2. Algoritmos basados en Deep Learning . . . 43
10.2.1. Perceptrón multicapa con Scikit-learn . . . 44
10.2.2. Red neuronal residual con PyTorch . . . 46
10.2.3. Método híbrido multicanal . . . 48
10.3. Integración de los métodos en IPSCampaign . . . 50
10.4. Comparación de los métodos implementados . . . 51

11. Métricas de evaluación 52
11.1. Obtención de las posiciones finales . . . 52
11.2. Error de posicionamiento . . . 53
11.3. Gráfica de exactitud . . . 54
11.3.1. Media del error . . . 54
11.3.2. Mediana . . . 54
11.3.3. Raíz del error cuadrático medio . . . 55
11.3.4. Percentil 90 . . . 55
11.3.5. Error máximo y número de puntos . . . 56
11.4. Gráfica de precisión . . . 56
11.5. Métricas incorporadas y métricas existentes . . . 57
11.6. Comparación de los métodos . . . 58
11.7. Resumen del procedimiento de evaluación . . . 59

12. Resultados y análisis 60
12.1. Criterio de evaluación . . . 61
12.2. Escenarios experimentales . . . 62
12.3. Resultados del escenario 1: condiciones controladas . . . 62
12.3.1. WKNN . . . 63
12.3.2. Perceptrón multicapa . . . 64
12.3.3. Red residual . . . 66
12.3.4. Método híbrido . . . 67

12.3.5. Síntesis del escenario 1 . . . 68
12.4. Resultados del escenario 2: condiciones más realistas . . . 69
12.4.1. WKNN . . . 69
12.4.2. Perceptrón multicapa . . . 71
12.4.3. Red residual . . . 74
12.4.4. Método híbrido . . . 75
12.4.5. Síntesis del escenario 2 . . . 76
12.5. Evolución de cada método entre escenarios . . . 77
12.5.1. Evolución de WKNN . . . 77
12.5.2. Evolución del perceptrón multicapa . . . 77
12.5.3. Evolución de la red residual . . . 77
12.5.4. Evolución del método híbrido . . . 77
12.6. Análisis complementario de precisión . . . 78
12.7. Análisis espacial conjunto . . . 79
12.8. Síntesis final . . . 80

13. Conclusiones y trabajo futuro 81
13.1. Conclusiones generales . . . 81
13.1.1. Conclusiones sobre el escenario controlado . . . 82
13.1.2. Conclusiones sobre el escenario multijornada . . . 83
13.1.3. Comparación de estabilidad entre escenarios . . . 84
13.2. Principales aportaciones . . . 85
13.3. Grado de cumplimiento de los objetivos . . . 86
13.4. Limitaciones . . . 87
13.5. Trabajo futuro . . . 88
13.5.1. Ampliación del diseño experimental . . . 88
13.5.2. Mejora del tratamiento multijornada de WKNN . . . 88
13.5.3. Robustez ante fallos de balizas . . . 89
13.5.4. Mejora de los modelos neuronales . . . 89
13.5.5. Mejora del despliegue físico . . . 89
13.5.6. Análisis espacial y temporal más detallado . . . 90
13.5.7. Coste computacional e integración operativa . . . 90
13.6. Conclusión final . . . 90
13.7. Uso de la Inteligencia Artificial . . . 91
13.8. Disponibilidad del código y los materiales . . . 92

Índice de figuras

1. Fases de la metodología CRISP-DM. Fuente: DataSolut [4]. 15

2. Plataforma ROBOMAP 17
3. Balizas de ultrasonido Marvelmind 18
4. Balizas BLE Kontakt.io 19

5. Laboratorio 2.4. Fuente: DIS de la ULPGC [5]. 24
6. Diseño de la rejilla de puntos y sistema de coordenadas del escenario. 26
7. Escenario real utilizado durante la campaña de toma de datos. 27

8. Flujo general seguido desde la adquisición hasta la evaluación. 31

9. Arquitecturas monocanal utilizadas para la estimación de posiciones. B representa el número de balizas disponibles. 44
10. Arquitectura general del método híbrido multicanal. 50

11. Gráfica de exactitud de WKNN con distancia euclídea en el canal 37 del escenario 1. 63
12. Gráfica de exactitud del perceptrón multicapa en el canal 37 del escenario 1. 64
13. Gráfica de exactitud del perceptrón multicapa en el canal 38 del escenario 1. 65
14. Gráficas de exactitud de la red residual en los canales 37, 38 y 39 del escenario 1. 66
15. Gráfica de exactitud del método híbrido en el escenario 1. 67
16. Gráfica de exactitud de WKNN con distancia Chebyshev en el canal 39 del escenario 2. 69
17. Gráfica de exactitud del perceptrón multicapa en el canal 37 del escenario 2. 71
18. Gráfica de exactitud del perceptrón multicapa en el canal 38 del escenario 2. 72
19. Gráfica de exactitud del perceptrón multicapa en el canal 39 del escenario 2. 73
20. Gráficas de exactitud de la red residual en los canales 37, 38 y 39 del escenario 2. 74
21. Gráfica de exactitud del método híbrido en el escenario 2. 75
22. Gráfica de precisión del método híbrido en el escenario 1. 78
23. Gráfica de precisión del método híbrido en el escenario 2. 79

Índice de cuadros

1. Clasificación de tecnologías empleadas en sistemas de posicionamiento en interiores 5

2. Grado de relación del TFT con los objetivos de desarrollo sostenible. 12

3. Resumen del diseño de las campañas de toma de datos 29

4. Tablas principales de las bases de datos SQLite generadas por ROBOMAP . 32
5. Columnas más relevantes de las bases de datos SQLite generadas por ROBOMAP 33
6. Escenarios experimentales definidos tras el análisis de las campañas 34
7. Estructura final de los datos utilizados por los métodos 39

8. Configuraciones candidatas del perceptrón multicapa 45
9. Arquitecturas candidatas de la red residual 47
10. Comparación de los métodos de posicionamiento implementados 51

11. Escenarios utilizados en el análisis de resultados 62
12. Exactitud de WKNN euclídeo en el canal 37 del escenario 1 63
13. Exactitud del perceptrón multicapa en el escenario 1 65
14. Exactitud de la red residual en el escenario 1 67
15. Exactitud del método híbrido en el escenario 1 68
16. Comparación representativa en el escenario 1 68
17. Exactitud de WKNN Chebyshev en el canal 39 del escenario 2 70
18. Exactitud del perceptrón multicapa en el escenario 2 73
19. Exactitud de la red residual en el escenario 2 75
20. Exactitud del método híbrido en el escenario 2 76
21. Comparación representativa en el escenario 2 76

22. Grado de cumplimiento de los objetivos 86

Siglas

AoA Angle of Arrival

BLE Bluetooth Low Energy

CRISP-DM Cross Industry Standard Process for Data Mining

CSI Channel State Information

DL Deep Learning

GNSS Global Navigation Satellite System

IMU Inertial Measurement Unit

IPS Sistemas de Posicionamiento en Interiores

IUCES Instituto Universitario de Cibernética, Empresa y Sociedad

ML Machine Learning

RFID Radio-Frequency Identification

ROBOMAP Robotic Mapping Platform

RSSI Received Signal Strength Indicator

SLAM Simultaneous Localization and Mapping

TDoA Time Difference of Arrival

ToA Time of Arrival

UWB Ultra-Wideband

VLC Visible Light Communication

WKNN Weighted k-Nearest Neighbors

KNN k-Nearest Neighbors

CDF Cumulative Distribution Function

RMSE Root Mean Squared Error

MAE Mean Absolute Error

Glosario

early stopping Técnica de regularización utilizada durante el entrenamiento de modelos de aprendizaje automático o aprendizaje profundo. Consiste en detener el entrenamiento cuando el rendimiento del modelo deja de mejorar en un conjunto de validación, con el objetivo de evitar el sobreajuste y conservar una configuración con buena capacidad de generalización 46, 47

full-batch Modo de entrenamiento en el que cada actualización utiliza todo el conjunto de entrenamiento, en lugar de dividirlo en mini-lotes 48

baliza Dispositivo emisor situado en una posición conocida del entorno, utilizado como referencia para sistemas de posicionamiento. En este trabajo, las balizas BLE emiten señales Bluetooth de baja energía que permiten al receptor medir valores de intensidad de señal 2, 6, 7, 18, 19, 21, 25, 28–30, 32, 87

base de datos de fingerprinting Conjunto estructurado de mediciones utilizadas para construir, almacenar y evaluar huellas de señal. En este trabajo integra las campañas realizadas con ROBOMAP y sirve como entrada para los algoritmos de posicionamiento 3, 28, 30

bloque residual Estructura utilizada en redes neuronales profundas formada por un bloque, es decir, un conjunto de capas o componentes agrupados dentro del modelo, al que se añade una conexión directa entre su entrada y su salida. Esta conexión facilita el flujo del gradiente, mejora la estabilidad del entrenamiento y ayuda a entrenar modelos más profundos 46

campaña Proceso experimental en el que se recopilan mediciones en un entorno definido siguiendo una planificación concreta. En este trabajo, las campañas de toma de datos consisten en recorrer puntos de referencia del escenario para registrar señales BLE en distintas orientaciones 11, 18–22, 25, 28–32, 35

conjunto de evaluación Conjunto de muestras reservado para comprobar el comportamiento de los métodos de posicionamiento. No se utiliza para construir directamente el mapa de huellas ni para ajustar los parámetros finales del modelo 38

conjunto de referencia Conjunto de mediciones realizadas en posiciones conocidas y utilizado para construir el mapa de huellas o entrenar modelos. Constituye la base contra la que se comparan o aprenden las nuevas muestras 38, 41

datos brutos Registros originales obtenidos durante la adquisición antes de aplicar tareas de limpieza, transformación o agregación. Pueden incluir capturas, paquetes recibidos, valores RSSI, coordenadas y metadatos experimentales 31

distancia Chebyshev Métrica de distancia que toma la mayor diferencia absoluta entre las componentes de dos vectores. En este trabajo destaca la baliza con mayor discrepancia de RSSI entre dos huellas 41, 57

distancia Manhattan Métrica de distancia que suma las diferencias absolutas entre las componentes de dos vectores. En huellas RSSI mide la diferencia acumulada entre dos patrones de señal 41, 57

distancia Minkowski Familia de métricas de distancia parametrizada por un valor p. Permite representar métricas habituales, como Manhattan para p=1 o euclídea para p=2 41, 57

ensemble Técnica de aprendizaje automático que combina varios modelos para obtener una predicción conjunta. Su objetivo es mejorar la robustez y el rendimiento respecto a un único modelo individual, reduciendo la influencia de errores particulares de cada modelo 44, 46–50, 90

error de posicionamiento Distancia entre la posición real y la posición estimada por un método de localización. En este trabajo se calcula como distancia euclídea tridimensional y se expresa en metros 8, 50, 53

escalado Transformación de variables numéricas para situarlas en rangos más adecuados para el entrenamiento o la comparación. Ayuda a evitar que una variable domine el modelo únicamente por su magnitud 35

estandarización Tipo de escalado que transforma una variable para que tenga media cero y desviación típica unidad, o una escala equivalente según la implementación. Facilita la optimización en modelos de aprendizaje 41, 43, 46

exactitud Grado de cercanía entre la posición estimada y la posición real. En posicionamiento se relaciona con errores bajos respecto a las coordenadas verdaderas 7, 8, 54, 60, 61, 82

fase offline Etapa previa del método de fingerprinting en la que se recorren posiciones conocidas del entorno y se registran mediciones de señal. Con estos datos se construye la base de datos o mapa de huellas que se utilizará posteriormente para estimar posiciones 3, 7, 8

fase online Etapa de posicionamiento del método de fingerprinting en la que el dispositivo obtiene nuevas mediciones de señal desde una posición desconocida. Estas mediciones se comparan con el mapa de huellas construido en la fase offline para estimar la ubicación más probable 3, 7, 8

fingerprinting Técnica de posicionamiento en interiores basada en la creación de un mapa de huellas de señal. Cada huella asocia una posición conocida del entorno con un patrón

de valores de señal, como el RSSI, que posteriormente se compara con nuevas mediciones para estimar la ubicación de un dispositivo 2, 4, 5, 7, 9, 11, 13, 16, 17, 20, 23, 25, 33, 40, 81, 86, 90

función de activación Función matemática utilizada en una red neuronal para transformar la salida de una neurona antes de pasarla a la siguiente capa. Permite introducir no linealidad en el modelo, lo que facilita el aprendizaje de relaciones complejas entre los datos de entrada y la salida esperada 44, 47

función de pérdida Función que mide la diferencia entre la salida predicha por un modelo y el valor real esperado. Durante el entrenamiento, el optimizador intenta minimizar esta función 48

gradiente Vector que indica cómo debe modificarse cada parámetro del modelo para reducir la función de pérdida. Su magnitud influye en la estabilidad de las actualizaciones durante el entrenamiento 46, 48

huella de señal Representación de una posición del entorno mediante un conjunto de medidas de señal, normalmente valores RSSI recibidos desde varias balizas o puntos de acceso. Permite diferenciar posiciones a partir del patrón de señal observado 2, 7, 8, 40, 57, 81

mapa de huellas Base de referencia que almacena huellas de señal asociadas a posiciones conocidas del entorno. Durante la localización, las nuevas mediciones se comparan con este mapa para estimar la posición más probable del receptor 2, 3, 5, 7, 8, 28, 29, 38, 42, 51, 82, 88, 90

multitrayecto Fenómeno de propagación por el que una señal llega al receptor a través de varios caminos debido a reflexiones, difracciones o rebotes en paredes, objetos u otras superficies. Puede alterar la intensidad recibida y dificultar la estimación de posición 2, 5

máscara de ausencias Vector binario que indica qué balizas no han sido detectadas en una muestra. Permite distinguir una señal muy débil de una ausencia real de observación 38, 43, 85

métrica de distancia Función utilizada para cuantificar la separación o similitud entre dos muestras. En WKNN se emplea para comparar huellas de señal y seleccionar los vecinos más próximos 8, 41, 50, 57

optimizador Algoritmo utilizado durante el entrenamiento de un modelo de aprendizaje automático o aprendizaje profundo para ajustar sus parámetros internos. Su objetivo es minimizar una función de pérdida y mejorar progresivamente la capacidad del modelo para realizar predicciones 46, 47

orientación de medida Dirección con la que se coloca el receptor durante una adquisición. En sistemas basados en RSSI puede afectar a las señales recibidas por la geometría del dispositivo, los obstáculos y la relación angular con las balizas 28, 30

percentil Valor que deja por debajo un porcentaje determinado de observaciones ordenadas. Por ejemplo, el percentil 90 indica que el 90 % de las muestras tiene un valor igual o inferior 45, 54, 55

precisión Consistencia de los errores obtenidos por un método. Un sistema preciso produce estimaciones con una dispersión reducida, aunque debe analizarse junto con la exactitud para evaluar su calidad real 7, 8, 60, 82

preprocesamiento Conjunto de operaciones aplicadas a los datos antes del modelado, como limpieza, normalización, transformación, alineación de columnas, tratamiento de ausencias y preparación de matrices de entrada 3, 8

punto de referencia Posición conocida del escenario experimental en la que se realizan mediciones de señal durante la fase de calibración. Estos puntos definen la base espacial sobre la que se construye el mapa de huellas 3, 7, 28–30

pérdida Huber Función de pérdida robusta que se comporta de forma parecida al error cuadrático para errores pequeños y al error absoluto para errores grandes. Reduce la influencia excesiva de valores extremos durante el entrenamiento 48

radiofrecuencia Rango de señales electromagnéticas utilizado por tecnologías inalámbricas como Wi-Fi, Bluetooth, RFID o UWB. En posicionamiento en interiores, estas señales se aprovechan para estimar la posición a partir de medidas como la intensidad recibida, el tiempo de llegada o el ángulo de llegada 2, 4, 5

red neuronal Modelo de aprendizaje formado por capas de unidades conectadas que transforman los datos de entrada para producir una salida. Se utiliza para aprender relaciones no lineales entre las señales recibidas y la posición 40, 44

regresión multisalida Problema de regresión en el que el modelo predice varios valores numéricos simultáneamente. En este trabajo se utiliza para estimar las coordenadas X, Y y Z del receptor 42

regularización Conjunto de técnicas utilizadas para reducir el sobreajuste y favorecer modelos con mejor capacidad de generalización. Puede incluir parada anticipada, decaimiento de pesos, dropout u otras restricciones 45, 47

sobreajuste Situación en la que un modelo aprende demasiado bien los detalles o el ruido de los datos de entrenamiento y pierde capacidad para generalizar ante muestras nuevas 8, 45–47

tasa de aprendizaje Parámetro que controla el tamaño de las actualizaciones realizadas por el optimizador durante el entrenamiento. Una tasa demasiado alta puede volver inestable el aprendizaje y una tasa demasiado baja puede ralentizarlo 47

toma de datos Proceso individual de adquisición realizado en una posición y orientación concretas. En cada toma se registran paquetes BLE, valores RSSI e información auxiliar necesaria para asociar la medición con el escenario experimental 3, 28–30

trilateración Método de localización que estima la posición de un receptor a partir de su distancia respecto a varios puntos de referencia conocidos. Se utiliza en sistemas GNSS y en algunos sistemas de posicionamiento en interiores cuando es posible estimar distancias fiables 1

validación cruzada Técnica de evaluación de modelos que consiste en dividir los datos en varios subconjuntos para entrenar y probar el modelo de forma alterna. Su objetivo es estimar el rendimiento del modelo de manera más robusta y reducir la dependencia de una única partición entre datos de entrenamiento y prueba 45, 47

vector de características Representación numérica de una muestra mediante variables de entrada. En este trabajo suele estar formado por valores RSSI, valores relativos y máscaras de ausencia asociados a las balizas consideradas 7, 43

época Pasada completa del conjunto de entrenamiento por el modelo durante el proceso de aprendizaje 47, 49

Capítulo 1

Introducción

En este capítulo se presenta el contexto general en el que se enmarca el presente Trabajo de Fin de Grado. Para ello, se introduce el problema del posicionamiento en entornos interiores, se describen las limitaciones que presentan los sistemas de posicionamiento tradicionales en este tipo de escenarios y se justifica la necesidad de emplear soluciones alternativas basadas en tecnologías inalámbricas.

Asimismo, se expone la motivación del trabajo, centrada en el estudio de técnicas de posicionamiento en interiores mediante señales BLE (Bluetooth Low Energy) y en el uso de algoritmos de ML (Machine Learning) y DL (Deep Learning) aplicados a datos obtenidos mediante la plataforma robótica ROBOMAP.

En el día a día, la sociedad depende cada vez más de tecnologías que permiten conocer la posición en tiempo real y el entorno en el que se encuentra una persona, objeto o dispositivo. Estas tecnologías resultan útiles, por ejemplo, cuando se necesita ir desde una ubicación actual hasta un punto del que se desconoce la ruta, conocer sitios de interés cercanos o localizar a una persona ante una situación de emergencia. Sus aplicaciones no se limitan únicamente a servicios dirigidos a personas, sino que también se emplean en el seguimiento de paquetes, sistemas antirrobo, gestión de material industrial, localización de mascotas, estudio de migraciones de fauna salvaje o ganadería inteligente, entre otros ámbitos.

Gran parte de estos servicios, actualmente normalizados, funcionan principalmente gracias a los sistemas GNSS (Global Navigation Satellite System). Estos sistemas se basan en la recepción de señales procedentes de varios satélites, a partir de las cuales el receptor calcula el tiempo que ha tardado cada señal en llegar. Con esta información se estima la distancia a cada satélite y, comparando las distancias obtenidas respecto a varios satélites, normalmente al menos cuatro, el receptor puede calcular su posición sobre la Tierra mediante un proceso de trilateración [10, 6].

Sin embargo, las señales GNSS presentan importantes limitaciones en entornos interiores. Al acceder a un edificio, estas señales deben atravesar paredes, techos, cristales, metal, hormigón u otros obstáculos, lo que provoca problemas como atenuación, bloqueo, reflexión y multitrayecto. Como consecuencia, en interiores los sistemas basados en GNSS pueden tardar más en obtener una posición, proporcionar una localización aproximada, situar al usuario en una zona cercana incorrecta o, directamente, no funcionar de forma fiable [17, 7].

La exactitud en interiores resulta crucial cuando no basta con conocer en qué edificio se encuentra una persona, objeto o dispositivo, sino que es necesario determinar en qué pasillo, zona, habitación, planta o posición concreta se localiza. Por ejemplo, en un hospital puede ser necesario localizar rápidamente una camilla, un equipo médico o un paciente; en un almacén, encontrar un palé, una herramienta o un robot móvil; y, en una emergencia, conocer la ubicación de una persona dentro de un edificio.

En resumen, la precisión en interiores es clave cuando la ubicación afecta a la seguridad, la eficiencia o la toma de decisiones en tiempo real. Por lo tanto, la ineficacia de los sistemas GNSS en estos escenarios ha impulsado la investigación y el desarrollo de IPS (Sistemas de Posicionamiento en Interiores). Estos sistemas buscan estimar la ubicación de personas, objetos o dispositivos dentro de edificios, donde la señal satelital no resulta suficientemente fiable [19, 7].

Para ello, se han estudiado diversas tecnologías y técnicas. Entre ellas, este trabajo se centra en tecnologías de radiofrecuencia, es decir, en el uso de señales inalámbricas emitidas por dispositivos como puntos de acceso Wi-Fi o balizas Bluetooth. Estas señales pueden ser captadas por un dispositivo receptor, como un teléfono móvil, y utilizadas para estimar su posición. En este contexto, uno de los datos más empleados es el RSSI (Received Signal Strength Indicator), que indica la intensidad con la que el dispositivo recibe una señal procedente de un punto de acceso o una baliza. Aunque el RSSI no proporciona directamente una distancia exacta, sí permite caracterizar cómo se perciben las señales en distintas zonas del entorno interior [20].

Dentro de este enfoque, destaca la localización por fingerprinting, una técnica que consiste en crear previamente un mapa de huellas en distintas zonas del edificio. Estas huellas de señal suelen estar formadas por los valores de RSSI recibidos desde varios puntos de acceso Wi-Fi o balizas BLE (Bluetooth Low Energy) en posiciones conocidas. Posteriormente, durante la fase de localización, el sistema compara los valores de RSSI medidos en tiempo real con los almacenados en el mapa para estimar la ubicación más probable del usuario, objeto o dispositivo [18, 20].

En particular, este trabajo se centra en IPS implementados mediante BLE. Aunque Wi-Fi resulta especialmente interesante por estar ya desplegado en muchos edificios, BLE permite utilizar pequeñas balizas de bajo consumo energético para emitir señales de referencia. Ambas tecnologías son ampliamente utilizadas en interiores por su disponibilidad, bajo coste y facilidad de integración en dispositivos comunes [15].

La implementación de un IPS mediante BLE con localización por *fingerprinting* no solo presenta ventajas, sino que también implica un proceso laborioso dividido en dos etapas principales: la fase de calibración y la fase de posicionamiento.

En la fase de calibración, también conocida como fase offline, se realiza un estudio previo del entorno. Para ello, se seleccionan distintos puntos de referencia dentro del espacio interior y, en cada uno de ellos, se registran los valores de RSSI recibidos desde las balizas BLE disponibles. Con estos datos se construye una base de datos o mapa de huellas, donde cada posición conocida queda asociada a un patrón concreto de intensidades de señal. Esta etapa suele ser costosa en tiempo y esfuerzo, ya que requiere recorrer el entorno, tomar múltiples mediciones y actualizar el mapa si cambian las condiciones del espacio.

Posteriormente, en la fase de posicionamiento, también llamada fase online, el dispositivo recoge en tiempo real los valores de RSSI de las balizas BLE cercanas. Estos valores se comparan con las huellas almacenadas previamente en la base de datos, utilizando algoritmos de estimación o clasificación, con el objetivo de determinar la posición más probable del usuario, objeto o dispositivo dentro del edificio.

Dado el alto coste en tiempo y esfuerzo que supone crear manualmente el mapa de huellas, este trabajo utiliza una plataforma robótica desarrollada por el IUCES (Instituto Universitario de Cibernética, Empresa y Sociedad), dentro de su línea de investigación en IPS. Esta plataforma permite automatizar parte del proceso de toma de datos, recorriendo el entorno de estudio y registrando las señales necesarias para construir la base de datos de fingerprinting.

Una vez construida la base de datos de huellas, el trabajo se centra en el tratamiento y análisis de los datos adquiridos. En primer lugar, se realiza una etapa de preprocesamiento, cuyo objetivo es organizar, limpiar y preparar las mediciones para que puedan ser utilizadas por los algoritmos de posicionamiento. Posteriormente, se estudian distintos métodos capaces de estimar la ubicación a partir de los valores de señal registrados.

En concreto, este proyecto se enfoca en investigar y aplicar técnicas de DL (Deep Learning), utilizando la librería PyTorch. El DL permite entrenar modelos capaces de aprender patrones complejos a partir de los datos, en este caso, la relación entre las señales recibidas y la posición correspondiente dentro del entorno interior. Los resultados obtenidos mediante estas técnicas se comparan con los del algoritmo WKNN (Weighted k-Nearest Neighbors), uno de los métodos más utilizados en este campo debido a su sencillez y eficacia. Este algoritmo estima la posición comparando la medición actual con las huellas más parecidas de la base de datos, asignando mayor peso a aquellas que presentan mayor similitud [3].

Para llevar a cabo el análisis comparativo se utiliza la herramienta IPSCampaign, desarrollada en un trabajo previo en la Universidad de Las Palmas de Gran Canaria. Esta herramienta permite agilizar y optimizar el procesamiento de los datos obtenidos por la plataforma robótica ROBOMAP, facilitando la incorporación, prueba y evaluación de nuevas metodologías de posicionamiento. Además, incorpora gráficas estadísticas que permiten comparar, para cada método aplicado, las posiciones reales con las posiciones estimadas, evaluando así la precisión y exactitud alcanzadas por cada técnica [14].

Capítulo 2

Estado del arte

En este capítulo se presenta el estado actual de las tecnologías y técnicas relacionadas con los sistemas de posicionamiento en interiores. Para ello, se describen las principales alternativas existentes, prestando especial atención a los sistemas basados en señales de radiofrecuencia, la tecnología BLE y las técnicas de localización por fingerprinting. Asimismo, se introducen la plataforma ROBOMAP y la herramienta IPSCampaign, utilizadas en el desarrollo del presente trabajo.

2.1. Estado actual del posicionamiento en interiores

El posicionamiento en exteriores dispone de soluciones ampliamente consolidadas, especialmente mediante el uso de sistemas GNSS. En cambio, el posicionamiento en interiores sigue siendo un área de investigación abierta, debido a la dificultad de obtener estimaciones precisas en entornos cerrados y a la variedad de condiciones que pueden afectar a las señales utilizadas para localizar personas, objetos o dispositivos [7, 17].

Las tecnologías empleadas en sistemas IPS pueden agruparse en distintas categorías según el tipo de señal o información utilizada para estimar la posición. De forma general, se distinguen sistemas basados en radiofrecuencia, luz, sonido, sensores inerciales, campo magnético, visión y sistemas híbridos, tal como se resume en la Tabla 1 [7, 19].

Cuadro 1: Clasificación de tecnologías empleadas en sistemas de posicionamiento en interiores

Categoría IPS	**Ejemplos de tecnologías**	**Principio de posicionamiento**
Basadas en radiofrecuencia	Wi-Fi, BLE, RFID, ZigBee, UWB, redes celulares	Medición de características de señales inalámbricas, como RSSI, ToA, TDoA, AoA o CSI.
Basadas en luz	Infrarrojos, VLC, Li-Fi	Uso de señales luminosas emitidas o recibidas para estimar la posición.
Basadas en sonido	Ultrasonidos, señales acústicas	Estimación de distancias mediante la propagación de ondas sonoras.
Basadas en sensores inerciales	Acelerómetro, giroscopio, magnetómetro, IMU	Estimación del desplazamiento a partir del movimiento del dispositivo.
Basadas en campo magnético	*Fingerprinting* magnético	Uso de variaciones espaciales del campo magnético interior como huella de localización.
Basadas en visión	Cámaras, visión artificial, SLAM	Reconocimiento del entorno mediante imágenes o reconstrucción espacial.
Sistemas híbridos	Combinación de varias tecnologías	Integración de varias fuentes de información para mejorar el rendimiento del sistema.

Dentro de las tecnologías de radiofrecuencia, Wi-Fi, BLE, RFID o UWB son algunas de las alternativas más habituales. Estas soluciones se apoyan en la medición de características de la señal, como RSSI, ToA, TDoA, AoA o CSI, para obtener información relacionada con la posición. No obstante, su rendimiento puede verse afectado por fenómenos propios de los entornos interiores, como el multitrayecto, la presencia de obstáculos o los cambios en la distribución del espacio.

Dentro de las soluciones de bajo coste y fácilmente desplegables, Wi-Fi y BLE han sido ampliamente utilizadas junto con técnicas de fingerprinting. En estos sistemas se construye previamente un mapa de huellas, normalmente a partir de valores de RSSI, que posteriormente se compara con las mediciones obtenidas en tiempo real para estimar la posición. En los últimos años, además, se han estudiado técnicas de ML y DL con el objetivo de mejorar la estimación de posición y adaptarse mejor a la variabilidad de las señales en interiores [18, 20, 3].

Por tanto, aunque existen múltiples alternativas para el posicionamiento en interiores, no hay una solución única válida para todos los escenarios. La elección de una tecnología depende de los requisitos de la aplicación. En este contexto, el presente trabajo se centra en sistemas basados en BLE y *fingerprinting*, por tratarse de una alternativa adecuada para escenarios experimentales de bajo consumo, bajo coste y despliegue flexible.

2.2. Tecnología Bluetooth Low Energy

La tecnología Bluetooth surge con el objetivo de establecer comunicaciones inalámbricas de corto alcance, sustituyendo el uso de cables por ondas de radio en la banda de 2,4 GHz, banda que también es utilizada por otras tecnologías como Wi-Fi. En este contexto, Bluetooth se caracteriza por permitir el intercambio de datos de forma sencilla entre dispositivos cercanos, con un coste energético y económico reducido.

Cuando la comunicación no requiere transmitir grandes cantidades de información de manera continua, aparece la variante BLE (Bluetooth Low Energy), orientada al envío de pequeños paquetes de datos de forma periódica y con bajo consumo energético. Esta característica hace que BLE resulte especialmente adecuada para dispositivos alimentados por batería y para aplicaciones que requieren comunicaciones eficientes y prolongadas en el tiempo, como ocurre en determinados sistemas de posicionamiento en interiores [2, 17, 15].

El principal interés del uso de BLE en este contexto es que cualquier dispositivo compatible con Bluetooth puede recibir paquetes BLE de forma periódica. A partir de estos paquetes, el dispositivo receptor puede medir la intensidad con la que recibe la señal inalámbrica. Este valor se denomina RSSI (Received Signal Strength Indicator) y normalmente se expresa en dBm.

El RSSI se utiliza como dato de entrada en sistemas de posicionamiento en interiores, ya que permite caracterizar el comportamiento de la señal en distintas zonas del entorno. No obstante, este valor no proporciona una distancia exacta entre emisor y receptor, debido a que puede verse afectado por obstáculos, interferencias, orientación del dispositivo y fenómenos de multitrayecto. Por este motivo, se considera una medida que aporta información indirecta sobre la posición o la proximidad del dispositivo [20, 3].

En un entorno interior, recibir un valor de RSSI procedente de un único emisor situado en una ubicación fija suele ser insuficiente para determinar de forma precisa la posición de un dispositivo. Una única señal puede ofrecer una indicación aproximada de cercanía respecto al emisor, pero no proporciona información suficiente sobre la dirección ni permite identificar de forma fiable una posición exacta. Además, la intensidad recibida puede verse afectada por obstáculos, reflexiones, interferencias y fenómenos de multitrayecto, lo que aumenta la ambigüedad en la estimación de la ubicación [20, 3].

A diferencia de una medición aislada, la recepción de señales procedentes de varios emisores distribuidos por el entorno permite obtener un patrón más representativo de la posición del receptor. Cada emisor aporta una medida de intensidad distinta, y la combinación de todas ellas reduce la ambigüedad espacial, ya que es menos probable que dos puntos diferentes presenten exactamente el mismo conjunto de valores. En este contexto, las balizas BLE actúan como pequeños dispositivos de bajo consumo que emiten señales periódicas. Cuando se distribuyen de forma adecuada en el entorno interior, permiten recopilar varios valores de RSSI desde diferentes puntos de referencia, facilitando la construcción de un patrón de señal más representativo para la estimación de la posición [15, 3].

A partir de lo anterior, el uso de BLE en posicionamiento en interiores no se basa únicamente en la recepción de señales individuales, sino en el análisis conjunto de los valores de RSSI obtenidos desde varias balizas distribuidas por el entorno. Esta idea da lugar al uso de técnicas basadas en patrones de señal, entre las que destaca el fingerprinting, que se describe en el siguiente apartado.

2.3. Técnicas de fingerprinting

El término *fingerprint*, traducido al español como "huella dactilar", hace referencia, en el contexto del posicionamiento en interiores, al conjunto de datos que permite caracterizar un punto de referencia dentro de un entorno. Esta huella de señal suele incluir la posición real del punto y los valores de RSSI medidos desde dicho punto respecto a los emisores disponibles. De este modo, cada zona del espacio puede quedar representada mediante un patrón de señal propio, lo que permite diferenciar unos puntos de otros a partir del comportamiento de las señales recibidas [18, 20].

El RSSI no es un valor fijo, incluso aunque el receptor se encuentre exactamente en la misma posición. En entornos interiores, una misma baliza puede proporcionar valores distintos en mediciones consecutivas debido a la presencia de obstáculos, reflexiones, interferencias, orientación del receptor, personas en movimiento, puertas abiertas o cerradas, mobiliario y ruido propio de la señal. Por esta razón, en lugar de almacenar una única medición por punto, suelen registrarse varias muestras tomadas en diferentes instantes. A partir de estas muestras pueden calcularse valores representativos, como la media, la mediana o la desviación típica, o bien conservar varias lecturas para que los algoritmos puedan tener en cuenta la variabilidad de la señal.

El funcionamiento del fingerprinting se divide habitualmente en dos fases principales. La primera es la fase fase offline, también conocida como fase de calibración. En esta etapa se recorre previamente el entorno y se toman varias mediciones de RSSI en posiciones conocidas. Con estos datos se construye una base de datos o mapa de huellas, donde cada posición queda asociada a un patrón de señales y no a una única lectura aislada.

Una vez construido el mapa de huellas, comienza la fase fase online, o fase de posicionamiento. En esta etapa, el receptor obtiene en tiempo real los valores de RSSI desde una posición desconocida. Posteriormente, el sistema compara esa medición actual con las huellas de señal almacenadas en la base de datos y estima la posición más probable del dispositivo dentro del entorno.

Los algoritmos de posicionamiento intervienen principalmente durante la fase *online*. A partir del vector de características de valores de RSSI medido en una posición desconocida, el algoritmo compara dicha información con las huellas de señal almacenadas y genera una estimación de la posición. Dependiendo del método utilizado, el sistema puede presentar distintos niveles de precisión, exactitud, coste computacional y capacidad de adaptación a la variabilidad de las señales interiores.[3, 20].

2.4. Algoritmos de posicionamiento basados en fingerprinting

Una vez construido el mapa de huellas durante la fase offline, es necesario disponer de un método capaz de estimar la posición del dispositivo durante la fase online. En esta etapa, el receptor obtiene una nueva medición formada por valores de RSSI procedentes de los emisores disponibles. El algoritmo de posicionamiento es el encargado de comparar esta medición con las huellas de señal almacenadas en la base de datos, o bien de aplicar un modelo previamente entrenado, con el objetivo de determinar la ubicación más probable del dispositivo.

Uno de los algoritmos más utilizados en sistemas de posicionamiento basados en *fingerprinting* es WKNN (Weighted k-Nearest Neighbors). Este método parte de la idea de comparar la medición actual con las huellas registradas durante la fase de calibración y seleccionar aquellas que presentan mayor similitud. A diferencia de KNN (k-Nearest Neighbors), donde los vecinos seleccionados suelen contribuir de forma equivalente a la estimación, WKNN asigna mayor peso a las huellas más similares y menor peso a aquellas más alejadas. De este modo, la posición estimada se obtiene como una combinación ponderada de las posiciones asociadas a las huellas más próximas [18, 20, 3].

La popularidad de WKNN se debe a su sencillez, facilidad de implementación e interpretación directa. Además, no requiere una fase de entrenamiento compleja, ya que trabaja directamente sobre la base de datos de huellas. Sin embargo, su rendimiento depende de aspectos como la calidad del mapa de huellas, la métrica de distancia empleada, el número de vecinos considerados y la variabilidad de las señales en el entorno.

Además de los métodos basados en vecinos cercanos, en los últimos años se han aplicado técnicas de ML (Machine Learning) y DL (Deep Learning) al posicionamiento en interiores. Estos enfoques resultan interesantes porque pueden aprender relaciones más complejas entre los patrones de señal y las posiciones del entorno. En lugar de limitarse a comparar una medición actual con huellas almacenadas, los modelos de aprendizaje pueden entrenarse con los datos disponibles para capturar regularidades o relaciones no lineales presentes en las mediciones de RSSI.

No obstante, el uso de técnicas de ML y DL también presenta retos. Estos modelos suelen requerir una base de datos suficientemente representativa, un preprocesamiento adecuado y una correcta selección de parámetros. Además, pueden presentar mayor coste computacional y riesgo de sobreajuste si el volumen de datos no es suficiente o si el modelo no se ajusta correctamente al problema.

La comparación entre algoritmos debe realizarse mediante métricas que permitan evaluar la calidad de las estimaciones obtenidas. En posicionamiento en interiores, resulta habitual comparar la posición estimada con la posición real y analizar el error de posicionamiento cometido. A partir de estos errores pueden estudiarse aspectos como la exactitud y la precisión. En este contexto, el presente trabajo toma WKNN como algoritmo de referencia y estudia alternativas basadas en DL, con el objetivo de analizar su comportamiento sobre una base de datos obtenida mediante ROBOMAP.

Capítulo 3

Objetivos

En este capítulo se presentan el objetivo general y los objetivos específicos del presente Trabajo de Fin de Grado. Estos objetivos sirven como guía para el desarrollo del proyecto y permiten delimitar las tareas principales que se llevan a cabo a lo largo de la memoria.

3.1. Objetivo general

El objetivo general de este Trabajo de Fin de Grado es estudiar, implementar y analizar técnicas de posicionamiento en interiores basadas en fingerprinting, empleando señales BLE y una base de datos obtenida mediante la plataforma robótica ROBOMAP.

Para alcanzar este objetivo, el trabajo parte de una campaña de toma de datos en un entorno interior controlado, donde se recopilan medidas de RSSI en distintos puntos de referencia y orientaciones. A partir de estas mediciones, se construye y prepara una base de datos de huellas que permita representar el comportamiento de las señales en el espacio de estudio.

Sobre dicha base de datos se plantea el análisis de algoritmos de posicionamiento capaces de estimar la ubicación de un dispositivo a partir de los patrones de señal recibidos. En particular, se toma el algoritmo WKNN (Weighted k-Nearest Neighbors) como método de referencia, debido a su uso habitual en sistemas basados en *fingerprinting*, y se estudian alternativas basadas en DL (Deep Learning) con el fin de evaluar su comportamiento frente a este enfoque clásico.

Finalmente, el trabajo tiene como objetivo integrar los métodos desarrollados en la herramienta IPSCampaign y comparar los resultados obtenidos mediante métricas relacionadas con la precisión y la exactitud del posicionamiento. De esta forma, se busca valorar la utilidad de las técnicas de aprendizaje profundo en el contexto del posicionamiento en interiores basado en señales BLE.

3.2. Objetivos específicos

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

- ✔ Estudiar el funcionamiento de la plataforma ROBOMAP y su papel en la toma de datos para sistemas de posicionamiento en interiores.
- ✔ Estudiar la herramienta IPSCampaign y su utilidad para el procesamiento, integración y evaluación de campañas de posicionamiento.
- ✔ Diseñar y realizar una campaña de toma de datos mediante ROBOMAP, obteniendo mediciones de señales BLE en distintos puntos y orientaciones del entorno.
- ✔ Construir y preparar una base de datos de huellas a partir de las mediciones obtenidas durante la campaña.
- ✔ Realizar el tratamiento y preprocesamiento de los datos adquiridos, con el objetivo de limpiar, organizar y preparar las mediciones para su uso posterior.
- ✔ Analizar el algoritmo WKNN como método de referencia en sistemas de posicionamiento basados en *fingerprinting*.
- ✔ Implementar y evaluar algoritmos alternativos basados en DL, utilizando la librería PyTorch.
- ✔ Integrar los algoritmos desarrollados en la herramienta IPSCampaign.
- ✔ Parametrizar los métodos implementados y analizar los resultados obtenidos mediante métricas relacionadas con la precisión y la exactitud del posicionamiento.

Capítulo 4

Aportaciones del trabajo

En este capítulo se describen las principales aportaciones del presente Trabajo de Fin de Grado, tanto desde el punto de vista técnico como académico. Asimismo, se relaciona el trabajo desarrollado con los Objetivos de Desarrollo Sostenible.

4.1. Principales aportaciones

El presente Trabajo de Fin de Grado aporta una contribución al estudio de los sistemas de posicionamiento en interiores basados en señales BLE y técnicas de fingerprinting. En concreto, el trabajo se centra en el uso de datos obtenidos mediante una plataforma robótica de adquisición, su posterior tratamiento y la evaluación de algoritmos de posicionamiento.

Una de las principales aportaciones consiste en la realización de una campaña de toma de datos en un entorno interior controlado mediante la plataforma ROBOMAP. Esta campaña aporta una base de datos útil para el análisis de técnicas de posicionamiento basadas en huellas de señal.

Otra aportación relevante es el tratamiento y preparación de los datos adquiridos. Esta fase resulta fundamental para transformar las mediciones obtenidas durante la campaña en una estructura adecuada para su posterior uso por parte de los algoritmos de posicionamiento.

Además, el trabajo contribuye al análisis comparativo de algoritmos de posicionamiento. Para ello, se toma como referencia el algoritmo WKNN, ampliamente utilizado en sistemas basados en *fingerprinting*, y se estudian alternativas basadas en DL. Esta comparación permite valorar el comportamiento de distintos enfoques a partir de una misma base de datos experimental.

Por último, el trabajo aporta la integración de los métodos desarrollados en la herramienta IPSCampaign, facilitando la ejecución de pruebas, la obtención de métricas y la comparación de resultados. De este modo, se favorece la reutilización de la herramienta para futuras campañas o para la incorporación de nuevos métodos de posicionamiento.

4.2. Objetivos de Desarrollo Sostenible

Cuadro 2: Grado de relación del TFT con los objetivos de desarrollo sostenible.

ODS	Grado de relación			
	0 No procede	**1 Bajo**	**2 Medio**	**3 Alto**
1 Fin de la Pobreza	✔			
2 Hambre cero	✔			
3 Salud y Bienestar			✔	
4 Educación de calidad	✔			
5 Igualdad de género	✔			
6 Agua limpia y saneamiento	✔			
7 Energía Asequible y no contaminante	✔			
8 Trabajo decente y crecimiento económico	✔			
9 Industria, Innovación e Infraestructuras				✔
10 Reducción de las desigualdades	✔			
11 Ciudades y comunidades sostenibles	✔			
12 Producción y consumo sostenibles	✔			
13 Acción por el clima	✔			
14 Vida submarina	✔			
15 Vida de ecosistemas terrestres	✔			
16 Paz, justicia e instituciones sólidas	✔			
17 Alianzas para lograr objetivos	✔			

De acuerdo con la Tabla 2, el presente Trabajo de Fin de Grado presenta una relación alta con el ODS 9, Industria, Innovación e Infraestructuras. El proyecto se centra en el estudio de tecnologías aplicadas al posicionamiento en interiores, mediante el uso de señales BLE, técnicas de *fingerprinting*, una plataforma robótica de toma de datos y algoritmos de posicionamiento basados en DL. Por tanto, se enmarca dentro del desarrollo y evaluación de soluciones tecnológicas innovadoras aplicadas a entornos interiores.

Asimismo, se considera una relación media con el ODS 3, Salud y Bienestar. Aunque el trabajo no se desarrolla específicamente en un entorno sanitario, los sistemas de posicionamiento en interiores pueden tener aplicaciones relevantes en hospitales, residencias, centros asistenciales o situaciones de emergencia, donde la localización de personas, pacientes, equipos médicos o recursos puede contribuir a mejorar la seguridad y la eficiencia de la atención.

El resto de los Objetivos de Desarrollo Sostenible se han marcado con grado 0, al no existir una relación directa entre su ámbito de actuación y los objetivos técnicos principales del presente trabajo.

Capítulo 5

Competencias específicas desarrolladas

En este capítulo se describen las competencias específicas desarrolladas durante la realización del presente Trabajo de Fin de Grado. Estas competencias se relacionan con el análisis de algoritmos, el tratamiento de datos, la aplicación de sistemas inteligentes, el uso de metodologías de ingeniería del software y la integración de los conocimientos adquiridos a lo largo de la titulación.

CI6. Conocimiento y aplicación de los procedimientos algorítmicos básicos de las tecnologías informáticas para diseñar soluciones a problemas, analizando la idoneidad y complejidad de los algoritmos propuestos.

Esta competencia se desarrolla mediante el estudio, implementación y análisis de algoritmos de posicionamiento en interiores basados en fingerprinting. En particular, el trabajo toma como referencia el algoritmo WKNN y estudia alternativas basadas en DL, analizando su comportamiento sobre una base de datos de señales BLE.

El desarrollo de esta competencia se refleja en la comparación entre distintos enfoques algorítmicos, considerando aspectos como la precisión, la exactitud, el coste computacional, la parametrización de los métodos y su adecuación al problema de posicionamiento en interiores.

CI12. Conocimiento y aplicación de las características, funcionalidades y estructura de las bases de datos, que permitan su adecuado uso, y el diseño y el análisis e implementación de aplicaciones basadas en ellos.

Esta competencia se trabaja a través de la construcción, tratamiento y preparación de la base de datos obtenida a partir de las campañas de toma de datos realizadas mediante la plataforma ROBOMAP. Las mediciones recopiladas deben organizarse de forma adecuada para representar correctamente las huellas de señal asociadas a los distintos puntos de referencia del entorno.

Además, el trabajo requiere comprender la estructura de los datos generados, realizar tareas de limpieza y preprocesamiento, y adaptar la información al formato necesario para su uso posterior en algoritmos de posicionamiento. Esta fase resulta fundamental para garantizar que los métodos implementados puedan utilizar los datos de forma coherente y fiable.

CI15. Conocimiento y aplicación de los principios fundamentales y técnicas básicas de los sistemas inteligentes y su aplicación práctica.

Esta competencia se desarrolla mediante la aplicación de técnicas de ML y DL al problema del posicionamiento en interiores. El trabajo estudia la posibilidad de emplear modelos capaces de aprender patrones a partir de los valores de RSSI registrados en el entorno y relacionarlos con posiciones conocidas.

La aplicación práctica de esta competencia se refleja en el uso de modelos de aprendizaje profundo implementados mediante PyTorch, así como en su comparación con un método clásico como WKNN. De este modo, se evalúa la capacidad de los sistemas inteligentes para estimar posiciones en escenarios interiores a partir de datos reales.

CI16. Conocimiento y aplicación de los principios, metodologías y ciclos de vida de la ingeniería del software.

Esta competencia se aborda mediante la planificación y desarrollo estructurado del trabajo, siguiendo una metodología adecuada para proyectos centrados en datos y modelado. En particular, el desarrollo del proyecto se organiza en fases que incluyen la comprensión del problema, la adquisición de datos, la preparación de la información, el modelado, la evaluación de resultados y la documentación.

Asimismo, la integración de los algoritmos desarrollados en la herramienta IPSCampaign requiere aplicar principios de diseño, implementación, prueba y evaluación de software. Esto permite incorporar nuevos métodos de posicionamiento dentro de un entorno ya existente, manteniendo una estructura coherente y reutilizable.

TFG. Ejercicio original a realizar individualmente y presentar y defender ante un tribunal universitario, consistente en un proyecto en el ámbito de las tecnologías específicas de la Ingeniería en Informática de naturaleza profesional en el que se sinteticen e integren las competencias adquiridas en las enseñanzas.

El presente Trabajo de Fin de Grado integra competencias adquiridas durante la titulación mediante el desarrollo de un proyecto aplicado al ámbito de la Ingeniería Informática. El trabajo combina el estudio de un problema real, la adquisición y tratamiento de datos, la implementación de algoritmos, el uso de técnicas de aprendizaje profundo, la evaluación experimental y la documentación de los resultados obtenidos.

Además, la memoria recoge de forma estructurada el proceso seguido, las decisiones tomadas y el análisis de los resultados, permitiendo sintetizar los conocimientos técnicos y metodológicos adquiridos durante la formación académica.

Capítulo 6

Metodología y planificación

este capítulo se describe la metodología seguida durante el desarrollo del trabajo, así como la planificación general de las tareas realizadas. Debido a la naturaleza del proyecto, centrado en la adquisición, preparación, análisis y evaluación de datos, se ha tomado como referencia la metodología CRISP-DM (Cross Industry Standard Process for Data Mining), ampliamente utilizada en proyectos relacionados con minería de datos y aprendizaje automático.

6.1. Metodología CRISP-DM



Ilustración 1: Fases de la metodología CRISP-DM. Fuente: DataSolut [4].

La metodología CRISP-DM proporciona un modelo de proceso orientado al desarrollo de proyectos basados en datos. Esta metodología organiza el trabajo en distintas fases: comprensión del negocio o problema, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue.

En el contexto de este trabajo, la metodología se adapta al estudio de técnicas de posicionamiento en interiores basadas en fingerprinting. El proyecto parte de la comprensión del problema del posicionamiento en interiores, continúa con la adquisición y análisis de datos obtenidos mediante ROBOMAP, sigue con la preparación de la base de datos de huellas, y finaliza con la implementación, evaluación y comparación de algoritmos de posicionamiento.

6.2. Aplicación de la metodología al trabajo

La primera fase se corresponde con la comprensión del problema. En esta etapa se estudia el contexto del posicionamiento en interiores, las limitaciones de los sistemas GNSS en espacios cerrados, el uso de señales BLE y la técnica de *fingerprinting*. Esta fase permite delimitar el problema y justificar la necesidad de emplear métodos alternativos para estimar la posición en entornos interiores.

La segunda fase se centra en la comprensión de los datos. Para ello, se analiza el tipo de información que proporciona la plataforma ROBOMAP, prestando especial atención a las mediciones de RSSI, los puntos de referencia, las orientaciones consideradas y la estructura de los datos generados durante las campañas de adquisición.

A continuación, se desarrolla la fase de preparación de los datos. En esta etapa se organizan, limpian y transforman las mediciones obtenidas con el objetivo de construir una base de datos adecuada para su uso en algoritmos de posicionamiento. Esta fase resulta especialmente importante, ya que la calidad del mapa de huellas influye directamente en el rendimiento de los métodos evaluados.

La fase de modelado consiste en el estudio e implementación de algoritmos capaces de estimar la posición a partir de los patrones de señal. En este trabajo se toma como referencia el algoritmo WKNN y se estudian alternativas basadas en DL, implementadas mediante PyTorch.

Por último, la fase de evaluación permite comparar los resultados obtenidos por los distintos métodos. Para ello, se utilizan métricas relacionadas con la precisión y la exactitud del posicionamiento, analizando la diferencia entre las posiciones reales y las posiciones estimadas por los algoritmos.

Capítulo 7

Tecnologías y herramientas utilizadas

En este capítulo se describen las principales tecnologías y herramientas empleadas durante el desarrollo del Trabajo.

7.1. Plataforma ROBOMAP

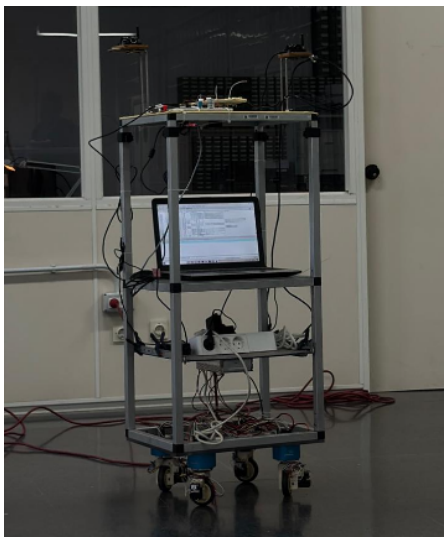


Ilustración 2: Plataforma ROBOMAP

Como se ha expuesto en el Capítulo 2, las técnicas de posicionamiento basadas en fingerprinting requieren una fase previa de calibración en la que se recopilan mediciones en distintos puntos del entorno. Este proceso puede resultar costoso si se realiza de forma manual, ya que exige recorrer el espacio de estudio, situarse en cada punto de referencia y registrar las señales recibidas desde los emisores disponibles.

Con el objetivo de automatizar y facilitar este proceso, el IUCES desarrolló, con la colaboración de estudiantes de la Universidad de Las Palmas de Gran Canaria, la plataforma robótica ROBOMAP. Esta plataforma está diseñada para realizar campañas de toma de datos en entornos interiores, siguiendo una ruta previamente definida y deteniéndose en los puntos establecidos para registrar la información necesaria.

Durante la adquisición, ROBOMAP permite recopilar datos procedentes de señales BLE en diferentes orientaciones, lo que resulta especialmente útil para estudiar la influencia de la orientación del receptor en los valores de RSSI. Además, la plataforma puede registrar información adicional relacionada con las condiciones del entorno, que puede ser relevante en el análisis posterior de las señales inalámbricas.

Los datos recopilados durante la campaña se almacenan en el controlador de la plataforma, permitiendo su posterior extracción, tratamiento y análisis. De este modo, ROBOMAP contribuye a mejorar la repetibilidad del proceso de adquisición, reducir el esfuerzo manual y generar bases de datos más estructuradas para sistemas de posicionamiento en interiores basados en *fingerprinting*.

7.2. Sistema Marvelmind y balizas de ultrasonido

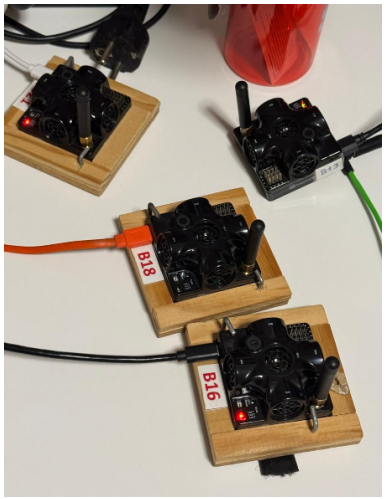


Ilustración 3: Balizas de ultrasonido Marvelmind

Marvelmind es un sistema de posicionamiento en interiores orientado al seguimiento de objetos, robots, vehículos, drones o personas en entornos donde los sistemas de navegación por satélite no resultan adecuados. Este sistema se basa en el uso de balizas distribuidas por el entorno, que permiten estimar la posición de un dispositivo móvil a partir de las señales recibidas. Según la documentación del fabricante, el sistema está diseñado para aplicaciones de posicionamiento preciso en interiores y puede alcanzar precisiones del orden de centímetros en condiciones adecuadas de despliegue [9].

En el contexto del presente Trabajo de Fin de Grado, el sistema Marvelmind se utiliza como herramienta de apoyo durante el proceso de adquisición de datos. Su función principal es proporcionar información espacial asociada al recorrido realizado por la plataforma ROBOMAP, permitiendo relacionar las mediciones de señales BLE con posiciones dentro del entorno de estudio.

El sistema se compone de balizas de ultrasonido distribuidas en posiciones conocidas y de un dispositivo móvil asociado a la plataforma robótica. Las balizas actúan como referencias espaciales, mientras que el dispositivo móvil permite obtener información de posicionamiento durante el desplazamiento. Esta información resulta útil para complementar el proceso de toma de datos y facilitar la construcción de una base de datos de huellas correctamente asociada a posiciones del entorno.

De este modo, Marvelmind contribuye a mejorar la organización espacial de las campañas de medición y sirve como apoyo para el registro de posiciones durante la adquisición de datos. Su uso resulta especialmente relevante en escenarios donde es necesario automatizar el proceso de captura y garantizar que las mediciones obtenidas puedan vincularse posteriormente con puntos de referencia o coordenadas del espacio interior.

7.3. Balizas BLE Kontakt.io



Ilustración 4: Balizas BLE Kontakt.io

Las balizas BLE de Kontakt.io son dispositivos inalámbricos de bajo consumo diseñados para emitir señales Bluetooth de forma periódica. Estas señales pueden ser detectadas por dispositivos receptores compatibles, permitiendo identificar la presencia de la baliza y medir la intensidad con la que se recibe su señal. Según la documentación de Kontakt.io, una baliza Bluetooth es un pequeño dispositivo basado en BLE que transmite una señal constante en intervalos regulares, la cual puede ser detectada por otros dispositivos cercanos [8].

En el contexto del presente Trabajo de Fin de Grado, estas balizas actúan como emisores de referencia distribuidos en el entorno interior.

Durante las campañas de adquisición, la plataforma ROBOMAP recoge los paquetes emitidos por las balizas y registra los valores de RSSI asociados a cada una de ellas. Estos valores permiten construir el patrón de señal correspondiente a cada punto de referencia del entorno.

El uso de balizas BLE resulta especialmente adecuado para sistemas de posicionamiento basados en fingerprinting, ya que permite desplegar varios emisores en posiciones conocidas y recopilar medidas de intensidad de señal desde diferentes puntos del espacio. De este modo, cada posición puede quedar caracterizada por un conjunto de valores de RSSI procedentes de las balizas disponibles.

Además, las balizas Kontakt.io permiten configurar parámetros relevantes para la adquisición de datos, como la potencia de transmisión o el intervalo de emisión, dependiendo del modelo utilizado. Estos parámetros influyen en la cobertura, la frecuencia de recepción de paquetes y el comportamiento de las señales en el entorno, por lo que deben tenerse en cuenta durante el diseño de las campañas de medida.

7.4. Blender y Robotcontrol Editor Toolbox

Blender es una herramienta software de modelado y edición 3D que, en el contexto del presente trabajo, se utiliza para representar digitalmente el escenario donde se realizan las campañas de toma de datos. Esta representación permite ubicar la plataforma ROBOMAP dentro del espacio de estudio, diseñar rutas de desplazamiento y comprobar previamente posibles colisiones o problemas asociados al recorrido [1].

Para su integración con ROBOMAP, se emplea la extensión Robotcontrol Editor Toolbox, desarrollada por Alberto Ramos. Esta extensión añade a Blender funcionalidades específicas para diseñar escenarios en 3D y controlar de forma remota plataformas robóticas, siendo compatible con versiones superiores a la 2.8 de Blender [13].

Mediante esta herramienta es posible diseñar o importar una escena en formato `.blend`, que actúa como representación virtual del entorno físico donde se lleva a cabo la campaña. A partir de dicha escena, se pueden definir los puntos y orientaciones que debe seguir la plataforma durante el proceso de adquisición de datos. De este modo, Blender no se utiliza únicamente como herramienta de modelado, sino también como parte del sistema de planificación y control de las campañas de medición.

Además, la extensión permite establecer la conexión con la plataforma y enviar instrucciones de movimiento, siempre que las direcciones IP y los puertos configurados coincidan con los definidos en el equipo principal de ROBOMAP. Por tanto, Blender y Robotcontrol Editor Toolbox constituyen una herramienta clave para el diseño del escenario, la planificación de rutas y el control de la plataforma durante las campañas experimentales.

7.5. Herramienta IPSCampaign

IPSCampaign es una herramienta software desarrollada por Simon Teodor Rusu Stratulat, exalumno de la Universidad de Las Palmas de Gran Canaria. Esta herramienta surge como resultado de su Trabajo de Fin de Grado, planteado como una continuación del proyecto ROBOMAP, y tiene como objetivo agilizar y optimizar el procesamiento de los datos capturados mediante señales BLE en escenarios de posicionamiento en interiores [14].

Su uso permite transformar los datos brutos recogidos durante las campañas de medición en información estructurada y preparada para la posterior aplicación de métodos de posicionamiento. De este modo, IPSCampaign facilita el flujo de trabajo asociado al tratamiento de campañas, evitando la necesidad de emplear varios scripts o herramientas externas para convertir la información inicial en ficheros intermedios.

En el contexto del presente Trabajo de Fin de Grado, IPSCampaign se emplea como herramienta auxiliar para el tratamiento de las nueve campañas experimentales realizadas con ROBOMAP. Estas campañas contienen capturas de señales BLE procedentes de diferentes balizas o *beacons*, junto con la información espacial asociada a los puntos de referencia y puntos aleatorios utilizados durante el proceso de medición.

La herramienta permite importar las campañas generadas por ROBOMAP y preparar los datos necesarios para la aplicación de métodos de posicionamiento. Esta preparación consiste en organizar las señales recibidas, asociarlas a sus correspondientes puntos físicos y generar una representación adecuada para ser utilizada por los algoritmos IPS. En trabajos anteriores, este proceso requería la utilización de varios scripts y herramientas externas; IPSCampaign centraliza y simplifica dicho flujo de trabajo.

En este proyecto, IPSCampaign se utiliza como punto de partida para la implementación de un nuevo método de posicionamiento basado en DL. El objetivo es entrenar un modelo capaz de aprender la relación entre las intensidades de señal BLE recibidas y las coordenadas reales del receptor. Una vez obtenidas las predicciones del modelo, estas se comparan con las generadas por el método WKNN, que constituye uno de los métodos clásicos de posicionamiento utilizados en el contexto de ROBOMAP.

La comparación entre ambos métodos se realiza mediante métricas de exactitud y precisión. La exactitud permite analizar el error entre las coordenadas reales y las coordenadas estimadas, mientras que la precisión se evalúa a partir de la distribución del error, permitiendo estudiar el comportamiento global de cada método en las distintas campañas. Estas métricas forman parte del flujo de evaluación contemplado por IPSCampaign, donde los resultados de los métodos aplicados pueden representarse mediante gráficas comparativas.

7.6. Python

Python es un lenguaje de programación interpretado, de alto nivel y orientado a objetos, ampliamente utilizado en el desarrollo de aplicaciones científicas, análisis de datos y aprendizaje automático. Su sintaxis clara, la disponibilidad de numerosas librerías especializadas y su integración con herramientas de procesamiento de datos lo convierten en una opción adecuada para proyectos basados en experimentación y modelado [11].

En el contexto del presente Trabajo de Fin de Grado, Python se utiliza como lenguaje base para el tratamiento de los datos obtenidos durante las campañas, la implementación de algoritmos de posicionamiento, la preparación de conjuntos de entrenamiento y prueba, y la evaluación de los resultados obtenidos.

7.6.1. PyTorch

PyTorch es una librería de aprendizaje profundo basada en tensores, diseñada para facilitar la construcción, entrenamiento y evaluación de modelos de redes neuronales. Según su documentación oficial, PyTorch proporciona una biblioteca optimizada de tensores para aprendizaje profundo que puede ejecutarse tanto en CPU como en GPU [12].

En este trabajo, PyTorch se emplea para implementar modelos basados en DL. Estos modelos reciben como entrada los patrones de señal obtenidos a partir de los valores de RSSI y se entrenan con el objetivo de aprender la relación entre dichas señales y la posición real del receptor. De este modo, PyTorch constituye la herramienta principal para el desarrollo de las alternativas basadas en aprendizaje profundo que se comparan posteriormente con el algoritmo WKNN.

7.6.2. Scikit-learn

Scikit-learn es una librería de aprendizaje automático para Python que proporciona herramientas para análisis predictivo, preprocesamiento de datos, selección de modelos y evaluación de resultados. La documentación oficial la describe como una herramienta simple y eficiente para análisis predictivo, construida sobre NumPy, SciPy y Matplotlib [16].

En el contexto del presente trabajo, Scikit-learn resulta útil para tareas asociadas al tratamiento y evaluación de datos, como la división de conjuntos de entrenamiento y prueba, el cálculo de métricas, la normalización o transformación de variables y el apoyo en la comparación de métodos de posicionamiento. Su uso complementa la implementación realizada con PyTorch, facilitando distintas etapas del flujo de trabajo experimental.

Capítulo 8

Diseño de la campaña de toma de datos

En este capítulo se describe todo el proceso relacionado con la toma de datos, incluyendo el diseño de la campaña, la elección del escenario de pruebas y la forma de proceder durante la adquisición. Asimismo, se explican las decisiones tomadas respecto a la disposición y configuración de los dispositivos empleados, la configuración de la plataforma ROBOMAP y la organización general de las mediciones.

El propósito de este capítulo es recoger de manera ordenada los aspectos necesarios para comprender cómo se diseñó y ejecutó la campaña experimental utilizada para construir la base de datos de fingerprinting.

8.1. Escenario

Para llevar a cabo una recogida de datos orientada al posicionamiento en interiores, resulta fundamental seleccionar un entorno adecuado que permita obtener medidas representativas y consistentes. En este sentido, es recomendable disponer de un espacio interior lo más diáfano posible, de manera que la propagación de las señales y el desplazamiento de la plataforma ROBOMAP no se vean condicionados en exceso por obstáculos presentes en el escenario.

Asimismo, el entorno seleccionado debe presentar un alto grado de estabilidad durante el proceso experimental. Esto implica minimizar la aparición de factores externos que puedan introducir variaciones significativas entre distintas tomas de datos. Entre estos factores se encuentran, por ejemplo, el desplazamiento de objetos presentes inicialmente en el laboratorio, el tránsito de personas por la zona de medida o la apertura y cierre frecuente de puertas próximas al escenario experimental.

Teniendo en cuenta estos requisitos, considerados esenciales para garantizar la repetibilidad y fiabilidad de las medidas obtenidas, el IUCES consiguió acceso al laboratorio 2.4 del Edificio de Informática y Matemáticas. Dicho espacio reunía las condiciones necesarias para ser utilizado como escenario experimental en la toma de datos. En la Figura 5 se muestra una imagen del laboratorio utilizado.

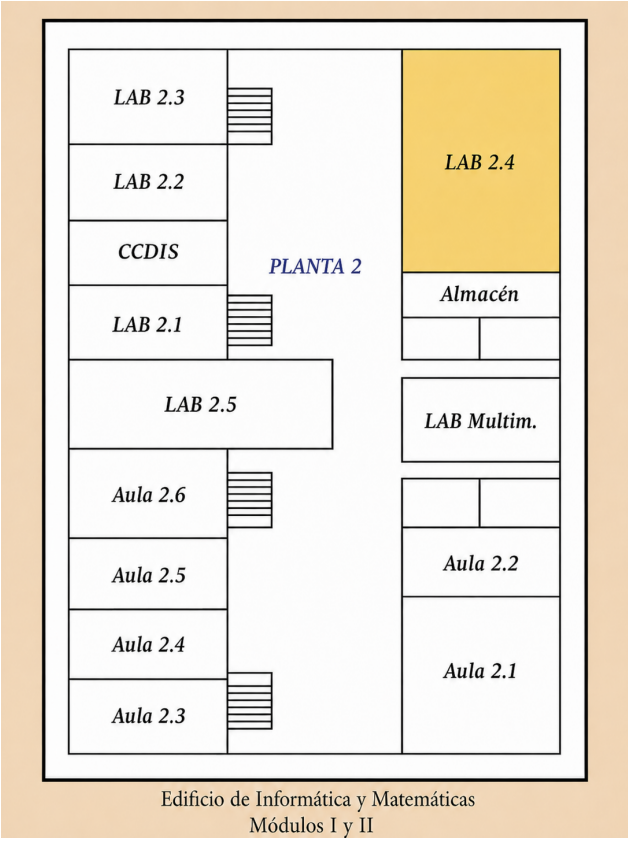


Ilustración 5: Laboratorio 2.4. Fuente: DIS de la ULPGC [5].

Una vez asignado el espacio para el desarrollo del proyecto, fue necesario acondicionar el laboratorio para garantizar unas condiciones adecuadas durante la toma de datos. Para ello, se despejó la zona central del laboratorio, retirando los obstáculos que pudieran interferir en el desplazamiento de la plataforma ROBOMAP o alterar la propagación de las señales durante las mediciones.

Además, con el objetivo de reducir posibles variaciones en el entorno experimental, se limitó el acceso al laboratorio. De las tres puertas disponibles, se mantuvo habilitada únicamente una de ellas, situada al fondo del laboratorio. En esa zona se concentraron los materiales necesarios para el desarrollo del proyecto y aquellos elementos que no formaban parte directa del área de medición.

Como consecuencia de esta organización, el laboratorio se dividió funcionalmente en dos zonas. La primera correspondía a la zona de acceso y almacenamiento de material, ocupando aproximadamente un tercio del espacio total. La segunda constituía el área principal de experimentación, ocupando los dos tercios restantes del laboratorio. Esta zona fue delimitada con un margen preventivo con el fin de reducir la influencia de posibles anomalías externas y garantizar una mayor estabilidad durante las campañas de adquisición.

Una vez definido el espacio real disponible para el desarrollo de la campaña, se diseñó una rejilla de puntos equiespaciados sobre el área experimental. Esta decisión permitió dividir el entorno en posiciones conocidas y distribuidas de forma regular, facilitando tanto la planificación de la ruta de ROBOMAP como la posterior asociación entre las mediciones de señal y sus coordenadas reales.

Para establecer un sistema de referencia común, se tomó una de las esquinas del entorno como origen O de coordenadas. A partir de este punto se midieron todas las posiciones del escenario, lo que permitió expresar de forma homogénea la ubicación de los puntos de medida, las balizas y la posición inicial de la plataforma. Esta elección simplifica el tratamiento posterior de los datos, ya que todas las mediciones quedan asociadas a coordenadas definidas dentro de un mismo sistema espacial.

La rejilla se diseñó con una separación de 1 m entre puntos consecutivos. Esta distancia permite obtener una distribución suficientemente densa para caracterizar la variación espacial de las señales BLE, sin aumentar en exceso el número de puntos de medida ni el tiempo necesario para realizar cada campaña. De este modo, se busca un equilibrio entre la resolución espacial del mapa de huellas y el coste temporal de la adquisición de datos.

Además de la posición, se consideró necesario registrar las mediciones en distintas orientaciones del receptor: norte, sur, este y oeste. Esta decisión se debe a que los valores de RSSI pueden variar no solo en función de la posición del dispositivo, sino también de su orientación respecto a las balizas y a los obstáculos del entorno. Al tomar medidas en las cuatro orientaciones principales, se obtiene una representación más completa del comportamiento de la señal en cada punto de la rejilla, reduciendo la dependencia de una única orientación y mejorando la calidad de la base de datos de fingerprinting.

Sobre este diseño se establecieron también las ubicaciones de las balizas de ultrasonido y de las balizas BLE. Las balizas de ultrasonido se situaron en posiciones externas al área de medida, con el objetivo de proporcionar apoyo al sistema de posicionamiento de la plataforma durante la campaña. Por su parte, las balizas BLE se distribuyeron alrededor del área experimental para favorecer que los distintos puntos de la rejilla recibieran señales desde varias direcciones, aumentando así la diversidad de valores de RSSI disponibles para la construcción de las huellas.

La posición inicial de ROBOMAP se hizo coincidir con el origen del sistema de coordenadas. Esta decisión facilita la definición de la ruta inicial, la calibración del recorrido y la interpretación posterior de las posiciones registradas durante la campaña. Además, permite mantener una correspondencia directa entre el diseño del escenario y la ejecución real de la toma de datos.

La Figura 6 muestra el diseño general del escenario experimental, incluyendo la rejilla de puntos de medida, el origen de coordenadas, la posición inicial de ROBOMAP, las balizas BLE, las balizas de ultrasonido y las orientaciones consideradas durante la toma de datos.

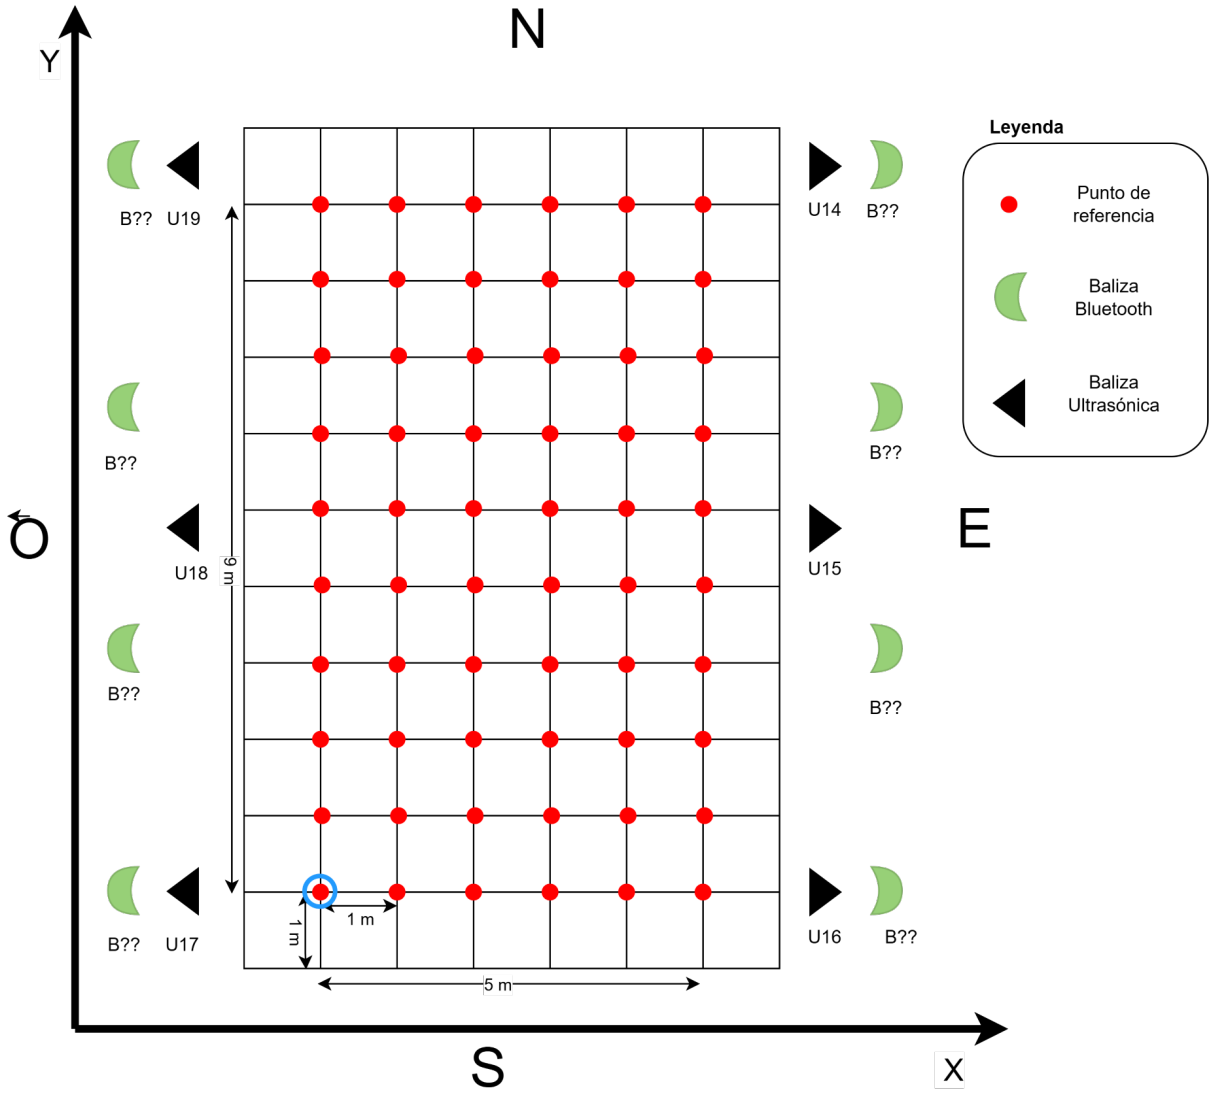


Ilustración 6: Diseño de la rejilla de puntos y sistema de coordenadas del escenario.

Además del diseño esquemático del escenario, se documentó el estado real del laboratorio durante la preparación de la campaña. En la Figura 7 se muestra el área experimental acondicionada, donde pueden observarse los puntos de medida marcados sobre el suelo, la zona despejada para el desplazamiento de ROBOMAP y la delimitación del espacio de trabajo. Esta imagen permite relacionar el diseño teórico de la rejilla con su implementación física en el laboratorio.

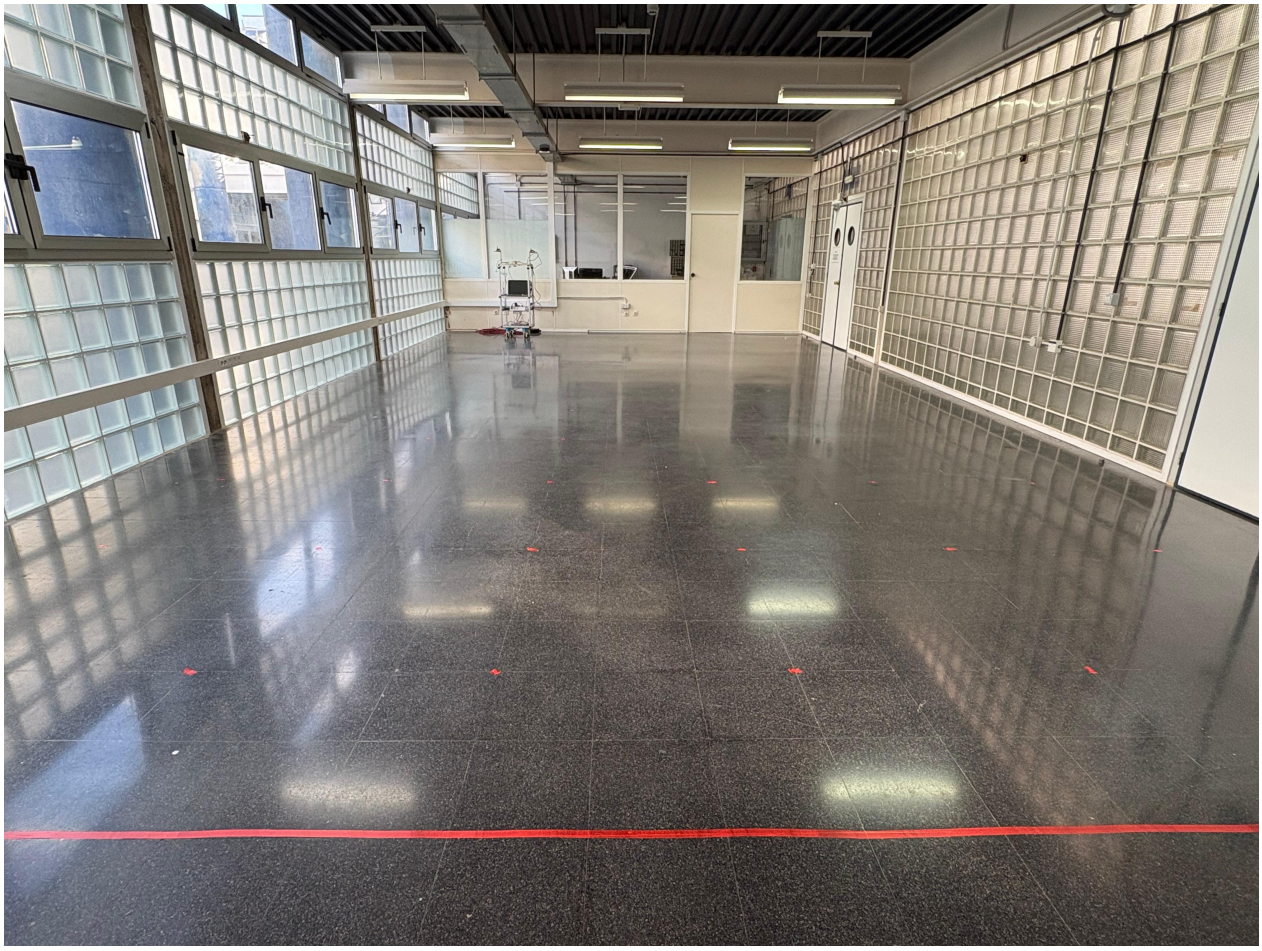


Ilustración 7: Escenario real utilizado durante la campaña de toma de datos.

8.2. Diseño de las campañas

Antes de describir el procedimiento seguido durante la adquisición, conviene diferenciar tres conceptos que aparecen a lo largo del presente trabajo: toma de datos, campaña y base de datos de fingerprinting.

En este contexto, se entiende por toma de datos cada proceso individual de adquisición realizado por ROBOMAP en un punto concreto del escenario y con una orientación de medida determinada. Durante cada toma se registran los paquetes BLE recibidos desde las balizas disponibles, junto con los valores de RSSI asociados y la información necesaria para identificar la posición y orientación en la que se ha realizado la medición.

Una campaña está formada por el conjunto organizado de tomas de datos realizadas siguiendo una ruta previamente definida. En cada campaña, la plataforma recorre los puntos de referencia establecidos en el escenario experimental y realiza las mediciones correspondientes en las orientaciones consideradas. De este modo, una campaña representa una ejecución completa del proceso de adquisición sobre el entorno de estudio.

Finalmente, la base de datos de fingerprinting se construye a partir de los datos obtenidos en todas las campañas realizadas. Esta base de datos recoge de forma estructurada las mediciones asociadas a cada punto, orientación y baliza, permitiendo disponer de un mapa de huellas que posteriormente será utilizado por los algoritmos de posicionamiento.

Con el objetivo de obtener una base de datos suficientemente representativa, se diseñó un conjunto de nueve campañas experimentales. Todas ellas se plantearon siguiendo el mismo diseño de escenario, la misma distribución de puntos de referencia, las mismas orientaciones de medida y la misma disposición de los dispositivos empleados.

Cada campaña se realizó en un día diferente, limitando la adquisición a una campaña diaria. Esta decisión permitió recoger variaciones temporales en las señales BLE, ya que los valores de RSSI pueden cambiar entre diferentes días incluso aunque la posición, la orientación y la configuración de los dispositivos permanezcan constantes. De esta forma, se buscó que la base de datos no dependiera de una única sesión experimental, sino que incorporase variabilidad real propia de los entornos interiores.

A partir del diseño definido, cada campaña quedó formada por 60 puntos de referencia. En cada uno de estos puntos se realizaron mediciones en cuatro orientaciones: norte, sur, este y oeste. Por tanto, cada campaña generó un total de 240 tomas de datos. Al repetirse este procedimiento durante nueve campañas realizadas en días diferentes, la base de datos de fingerprinting quedó formada por un total de 2160 tomas de datos, tal como se resume en la Tabla 3.

Cuadro 3: Resumen del diseño de las campañas de toma de datos

Elemento	**Valor**
Base de datos de *fingerprinting* generada	1
Número total de campañas	9
Número de campañas por día	1
Puntos de referencia por campaña	60
Orientaciones medidas por punto	Norte, Sur, Este y Oeste
Número de orientaciones por punto	4
Tomas de datos por campaña	240
Tomas de datos totales en la base de datos	2160

En los apartados siguientes se describen con mayor detalle los puntos de referencia definidos en el escenario, las orientaciones consideradas durante la adquisición y el procedimiento seguido para realizar cada campaña.

8.3. Puntos de referencia

Los puntos de referencia constituyen las posiciones conocidas del entorno en las que se realizan las mediciones durante cada campaña. Estos puntos forman la base espacial del mapa de huellas, ya que cada uno de ellos queda asociado a un conjunto de valores de RSSI obtenidos desde las balizas BLE disponibles.

Para definirlos, se utilizó una rejilla de puntos equiespaciados sobre el área experimental. Esta distribución permite cubrir el espacio de forma ordenada y homogénea, facilitando tanto la planificación de la ruta de ROBOMAP como la asociación posterior entre cada medición y sus coordenadas reales.

La separación entre puntos se estableció en 1 m, buscando un equilibrio entre la resolución espacial del mapa de huellas y el tiempo necesario para completar cada campaña. Una separación menor habría permitido obtener una caracterización más densa del entorno, pero habría incrementado considerablemente el número de tomas de datos. Por el contrario, una separación mayor habría reducido el tiempo de adquisición, pero también la capacidad de distinguir entre posiciones próximas.

8.4. Orientaciones de medida

Además de la posición, durante la toma de datos se consideró la orientación de la plataforma. En cada punto de referencia se realizaron mediciones en las orientaciones norte, sur, oeste y este.

La inclusión de distintas orientaciones se debe a que los valores de RSSI pueden variar no solo en función de la posición del receptor, sino también de su orientación respecto a las balizas y a los obstáculos del entorno. La propia estructura de ROBOMAP, la disposición del receptor y la relación angular con los emisores pueden influir en la intensidad de señal recibida.

Por este motivo, registrar medidas en varias orientaciones permite obtener una representación más completa del comportamiento de la señal en cada punto. Esto contribuye a construir una base de datos de fingerprinting más rica y menos dependiente de una única orientación de medida.

8.5. Procedimiento de adquisición

El procedimiento de adquisición se diseñó para que cada campaña siguiera una secuencia ordenada y repetible. En primer lugar, se preparaba el escenario experimental, comprobando la disposición de las balizas, el estado de la plataforma ROBOMAP y la ruta definida para la campaña.

Una vez iniciada la campaña, ROBOMAP se desplazaba hasta cada uno de los puntos de referencia establecidos en la rejilla. En cada punto, la plataforma se detenía y realizaba la captura de paquetes BLE en las orientaciones consideradas. Finalizada la toma correspondiente, continuaba hacia el siguiente punto de la ruta hasta completar el recorrido definido.

Este procedimiento permitió automatizar gran parte de la adquisición, reduciendo la intervención manual y favoreciendo la repetibilidad entre campañas. Al mantener el mismo recorrido, los mismos puntos y las mismas orientaciones en todas las campañas, fue posible comparar posteriormente los datos obtenidos en distintos días bajo una estructura común.

Capítulo 9

Tratamiento y preparación de los datos

En este capítulo se describe el proceso seguido para transformar los datos obtenidos durante las campañas de adquisición en conjuntos adecuados para la aplicación y evaluación de los algoritmos de posicionamiento. El tratamiento parte de los datos brutos generados por la plataforma ROBOMAP y comprende la importación de las bases SQLite, la revisión de la calidad de las campañas, la normalización de las coordenadas, la selección de las balizas y la construcción de las matrices utilizadas por WKNN y por los modelos basados en DL.

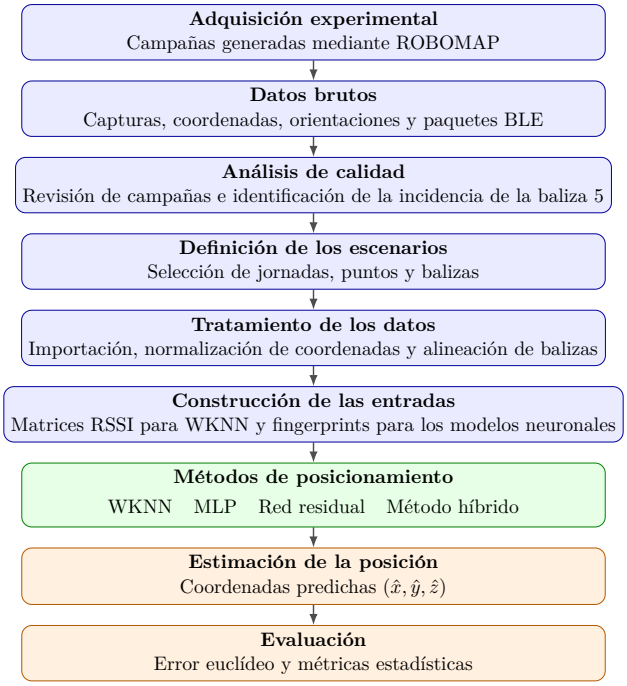


Ilustración 8: Flujo general seguido desde la adquisición hasta la evaluación.

9.1. Bases de datos generadas

Como resultado de las campañas realizadas con la plataforma ROBOMAP, se obtuvo un conjunto de bases de datos independientes en formato SQLite. Cada una almacena de forma estructurada la información espacial asociada a las capturas y los paquetes BLE recibidos desde las balizas desplegadas en el escenario.

Las campañas de puntos de referencia contienen 240 capturas, correspondientes a 60 posiciones medidas en cuatro orientaciones: 0°, 90°, 180° y 270°. Por tanto, cada punto queda representado mediante cuatro tomas de datos. Además, se adquirió una campaña independiente de 15 puntos aleatorios, también medidos en las cuatro orientaciones, que formaba parte del planteamiento experimental inicial.

En total se realizaron nueve campañas de puntos de referencia en jornadas diferentes. Todas ellas utilizaron el mismo escenario, la misma rejilla de posiciones y la misma disposición inicial de balizas. Esta repetición permitió observar la variabilidad temporal de las señales, aunque posteriormente fue necesario comprobar qué jornadas presentaban una calidad suficiente para ser utilizadas en los experimentos finales.

La información generada por ROBOMAP se organiza en distintas tablas dentro de cada base de datos SQLite. La Tabla 4 resume las tablas principales y la función de cada una de ellas.

Cuadro 4: Tablas principales de las bases de datos SQLite generadas por ROBOMAP

Tabla	**Descripción**
`Capture`	Almacena cada toma de datos realizada durante la campaña. Incluye la fecha de adquisición, las condiciones ambientales registradas, la posición de la plataforma y la orientación del receptor.
`Beacon_BLE_Signal`	Almacena los paquetes BLE recibidos durante cada captura. Incluye la baliza emisora, el canal de recepción, el valor de RSSI y otros campos asociados al paquete.
`Beacon_Configuration`	Contiene la información de configuración de las balizas detectadas, como la dirección MAC, la potencia calibrada, la frecuencia de actualización y su identificador.
`Dongle_Receptor`	Identifica el dispositivo receptor empleado durante la campaña de adquisición.
`Alert`	Registra avisos o eventos generados durante la ejecución de la campaña.

Las tablas más relevantes para la construcción de la base de datos de fingerprinting son `Capture` y `Beacon_BLE_Signal`. La primera permite conocer dónde y con qué orientación se realizó cada toma, mientras que la segunda contiene las señales recibidas durante ella. Ambas se relacionan mediante el campo `Id_capture`.

La Tabla 5 recoge las columnas principales utilizadas durante el tratamiento de los datos.

Cuadro 5: Columnas más relevantes de las bases de datos SQLite generadas por ROBOMAP

Tabla	**Columna**	**Descripción**
`Capture`	`Id`	Identificador único de la captura o toma de datos.
`Capture`	`Date`	Fecha y hora de realización de la captura.
`Capture`	`Light`	Valor de luminosidad registrado durante la toma.
`Capture`	`Temperature`	Temperatura registrada durante la captura.
`Capture`	`Relative_humidity`	Humedad relativa registrada durante la captura.
`Capture`	`Absolute_humidity`	Humedad absoluta registrada durante la captura.
`Capture`	`Position_x`	Coordenada x de la posición de la plataforma.
`Capture`	`Position_y`	Coordenada y de la posición de la plataforma.
`Capture`	`Position_z`	Coordenada z de la posición de la plataforma.
`Capture`	`Platform_angle`	Ángulo de la plataforma durante la captura.
`Capture`	`Dongle_rotation`	Orientación del receptor Bluetooth durante la toma de datos.
`Beacon_BLE_Signal`	`Id`	Identificador único del paquete BLE.
`Beacon_BLE_Signal`	`Id_capture`	Identificador de la captura a la que pertenece la señal recibida.
`Beacon_BLE_Signal`	`N_reading`	Número de lectura dentro de la captura.
`Beacon_BLE_Signal`	`Date_hour`	Instante temporal en el que se registra la señal.
`Beacon_BLE_Signal`	`Mac`	Dirección MAC de la baliza emisora.
`Beacon_BLE_Signal`	`Pack_size`	Tamaño del paquete recibido.
`Beacon_BLE_Signal`	`Channel`	Canal de recepción del paquete. En las señales publicitarias BLE se utilizan los canales 37, 38 y 39.
`Beacon_BLE_Signal`	`RSSI`	Intensidad de señal recibida. Constituye la información principal utilizada para construir las huellas.
`Beacon_BLE_Signal`	`PDU_type`	Tipo de unidad de datos asociada al paquete recibido.
`Beacon_BLE_Signal`	`CRC`	Campo de comprobación del paquete.
`Beacon_BLE_Signal`	`Protocol`	Protocolo asociado al paquete detectado.
`Beacon_BLE_Signal`	`Identificator`	Identificador adicional asociado a la baliza o al paquete.

La tabla `Capture` representa el nivel de la toma de datos, mientras que `Beacon_BLE_Signal` representa el nivel de paquete. Una captura no equivale, por tanto, a una única medida de RSSI, ya que durante ella se reciben numerosos paquetes procedentes de distintas balizas y canales. Este nivel de detalle permite analizar el comportamiento de las señales, pero requiere una transformación posterior antes de aplicar los algoritmos de posicionamiento.

9.2. Análisis de calidad y definición de los escenarios

Una vez finalizada la adquisición, se realizó una revisión conjunta de las campañas con el objetivo de comprobar su coherencia estructural y la disponibilidad de las balizas. Este análisis se llevó a cabo antes de construir las matrices de referencia, entrenamiento y evaluación, evitando que una incidencia de la infraestructura condicionara de forma diferente los conjuntos comparados.

Durante esta revisión se detectó un funcionamiento anómalo de la baliza 5 en la mayoría de las jornadas. La incidencia también afectaba a la campaña de puntos aleatorios prevista inicialmente para la evaluación. El uso directo de esa campaña habría provocado que los datos de referencia y evaluación no compartieran las mismas condiciones de adquisición ni el mismo conjunto fiable de señales.

Por este motivo, la campaña de puntos aleatorios se conserva como parte del proceso de adquisición descrito en el capítulo anterior, pero no se utiliza en la evaluación final. En su lugar, se definieron los dos escenarios recogidos en la Tabla 6.

Cuadro 6: Escenarios experimentales definidos tras el análisis de las campañas

Escenario	**Referencia o entrenamiento**	**Evaluación**	**Balizas**
Escenario 1	Puntos impares de la campaña del 16 de abril.	Puntos pares de la campaña del 16 de abril.	Todas las balizas disponibles.
Escenario 2	Puntos impares de las campañas válidas de los días 9, 10, 13, 16, 17, 20 y 22 de abril.	Puntos pares de la campaña del 16 de abril.	Todas excepto la baliza 5.

En el primer escenario se emplean exclusivamente datos del 16 de abril, jornada en la que todas las balizas funcionaron correctamente. Los puntos impares forman el conjunto de referencia o entrenamiento y los puntos pares se reservan para la evaluación.

En el segundo escenario se combinan las campañas válidas en las que la única incidencia relevante estaba asociada a la baliza 5. Antes de aplicar los algoritmos se elimina completamente la información de dicha baliza tanto de las campañas de referencia como de los puntos pares utilizados para evaluar. Las coordenadas de las distintas jornadas se normalizan respecto a la rejilla del 16 de abril, de forma que las mediciones de un mismo punto físico quedan asociadas a una posición común.

La división entre puntos impares y pares evita que una misma coordenada aparezca simultáneamente en los datos utilizados para construir los modelos y en los datos reservados para la evaluación. Ambos subconjuntos permanecen espacialmente intercalados, pero representan posiciones físicas distintas. Además, el uso de los mismos puntos pares del 16 de abril en los dos escenarios permite comparar sus resultados sobre un conjunto de evaluación común.

9.3. Limpieza y normalización de los datos

El primer paso del tratamiento consiste en importar las bases SQLite generadas durante las campañas a la base de datos principal de IPSCampaign. Cada base se monta temporalmente como una base auxiliar, desde la que se copian las capturas, las señales BLE, las configuraciones de las balizas y la información del receptor.

Durante este proceso se remapean las claves internas de las capturas para conservar la relación entre cada toma y los paquetes recibidos. Cada señal almacenada en `Beacon_BLE_Signal` debe quedar asociada a una captura existente mediante `Id_capture`. Esta comprobación garantiza que cada valor de RSSI mantenga la posición y orientación en la que fue adquirido.

Las coordenadas registradas en las bases originales se sustituyen por las coordenadas canónicas definidas en la configuración de la campaña. Esta normalización corrige pequeñas desviaciones de adquisición y permite combinar jornadas distintas sobre una misma rejilla espacial. Si una base contiene una estructura de puntos incompatible con la configuración esperada, la importación se considera inconsistente.

En el escenario sin la baliza 5, sus registros se eliminan antes de construir los conjuntos utilizados por los métodos. Se trata de una exclusión permanente de una fuente de información y no de una ausencia puntual dentro de una captura. Las ausencias ocasionales de las balizas restantes se conservan y se representan posteriormente mediante un valor controlado.

También se realiza un saneamiento numérico antes de aplicar los algoritmos. Los valores no finitos, como `NaN`, $+\infty$ o $-\infty$, se sustituyen por valores válidos para evitar errores durante el cálculo de distancias, el escalado o el entrenamiento de los modelos.

No se aplica un filtrado específico de valores atípicos de RSSI ni se descartan paquetes en función de campos como `CRC` o `PDU_type`. La limpieza se centra en la coherencia estructural, la normalización de coordenadas, la integridad de las relaciones entre tablas, la exclusión de la baliza defectuosa cuando corresponde y el tratamiento de valores no numéricos.

9.4. Transformación de los datos

Las bases generadas por ROBOMAP almacenan información a nivel de captura y de paquete recibido, por lo que no pueden emplearse directamente como entrada de los métodos. Para facilitar su procesamiento se genera una estructura intermedia, denominada *predatos*, que combina la información espacial de `Capture` con las señales de `Beacon_BLE_Signal`.

Cada registro intermedio conserva la campaña, la fecha de la captura, la posición, la orientación, la dirección `MAC`, el canal, el protocolo y el valor de RSSI. A partir de esta estructura se agrupan las lecturas y se construyen las matrices específicas de cada familia de métodos.

Antes de crear estas matrices se identifican las balizas presentes tanto en los datos de referencia como en los de evaluación. Se conserva únicamente la intersección de sus direcciones `MAC`:

$$\mathcal{B} = \mathcal{B}_{\text{ref}} \cap \mathcal{B}_{\text{eval}}, \tag{9.1}$$

donde $\mathcal{B}_{\text{ref}}$ y $\mathcal{B}_{\text{eval}}$ representan los conjuntos de balizas observados en cada parte del experimento. Esta alineación garantiza que las matrices tengan la misma dimensión y que cada columna represente la misma baliza y ocupe la misma posición.

Cuando una baliza no se detecta en una muestra concreta, su ausencia se representa mediante $-110\,\text{dBm}$. Este valor permite conservar matrices completas y diferenciar una ausencia de las intensidades recibidas habitualmente.

9.4.1. Construcción de las matrices para WKNN

Para la aplicación de WKNN, las bases seleccionadas como referencia se integran dentro de una misma campaña lógica. Todas las lecturas asociadas a una posición pueden consultarse conjuntamente, con independencia de la jornada en la que fueron adquiridas. La fecha no se utiliza como característica ni se conserva una huella independiente por día.

La matriz de referencia contiene una única fila por punto impar y canal. Para cada punto p, baliza b, orientación r y canal c, se recuperan todas las lecturas disponibles y se selecciona el valor de mayor intensidad:

$$m_{p,b,r,c} = \text{máx}\left\{RSSI^{(1)}_{p,b,r,c}, RSSI^{(2)}_{p,b,r,c}, \ldots, RSSI^{(N)}_{p,b,r,c}\right\}, \tag{9.2}$$

donde N representa el número de paquetes asociados a esa combinación. Al utilizarse la opción sin límite de muestras, se consideran todas las lecturas disponibles.

A continuación se calcula la media de los máximos obtenidos en las orientaciones para las que existe información:

$$f_{p,b,c} = \frac{1}{|\mathcal{R}_{p,b,c}|} \sum_{r \in \mathcal{R}_{p,b,c}} m_{p,b,r,c}, \tag{9.3}$$

donde $\mathcal{R}_{p,b,c}$ es el conjunto de orientaciones con lecturas disponibles. Si una baliza no aparece en ninguna orientación del punto, se asigna $-110\,\text{dBm}$.

El vector de referencia de un punto queda definido como:

$$\mathbf{f}_{p,c} = \left[f_{p,1,c}, f_{p,2,c}, \ldots, f_{p,B,c}\right], \tag{9.4}$$

al que se añaden las coordenadas reales X, Y y Z. Como se utilizan 30 puntos impares, cada canal genera 30 huellas de referencia, independientemente del número de jornadas incorporadas. Cuando se combinan varias campañas, los máximos se calculan sobre el conjunto completo de lecturas y una huella puede integrar valores procedentes de días distintos.

La matriz de evaluación conserva una muestra independiente para cada punto par, orientación y canal. Para cada baliza se selecciona el mayor RSSI observado dentro de la captura y se utiliza $-110\,\text{dBm}$ cuando no existe ninguna lectura. Por tanto, cada canal genera inicialmente:

$$30 \text{ puntos} \times 4 \text{ orientaciones} = 120 \text{ muestras}. \tag{9.5}$$

Las matrices de referencia y evaluación emplean directamente los valores absolutos de RSSI. No se aplica escalado, cálculo de valores relativos ni incorporación de máscaras de ausencia. El cálculo de las distancias, la selección de los vecinos y la estimación ponderada de la posición se describen en el capítulo dedicado a la implementación de los algoritmos.

9.4.2. Construcción de fingerprints para los modelos neuronales

Los métodos basados en DL utilizan una representación diferente. En lugar de resumir todas las mediciones de un punto en una única huella, conservan las capturas válidas como ejemplos independientes. De este modo, las capturas realizadas en diferentes jornadas permanecen separadas y permiten que los modelos aprendan parte de la variabilidad temporal de las señales.

Para cada captura i, baliza b y canal c, se selecciona el valor de mayor intensidad entre todas las lecturas disponibles:

$$r_{i,b,c} = \text{máx}\left\{RSSI^{(1)}_{i,b,c}, RSSI^{(2)}_{i,b,c}, \ldots, RSSI^{(N)}_{i,b,c}\right\}. \tag{9.6}$$

Con la opción sin límite de muestras se consideran todos los paquetes de la captura. Cuando una baliza no se detecta, se utiliza $-110\,\text{dBm}$.

No todos los fingerprints generados se conservan. Una captura debe contener observaciones de, al menos:

$$B_{\min} = \text{máx}\left(1, \left\lfloor \frac{B}{3} \right\rfloor\right), \tag{9.7}$$

donde B es el número total de balizas consideradas. Este criterio permite eliminar huellas excesivamente dispersas y con poca información útil. Con siete u ocho balizas se requieren, como mínimo, dos balizas observadas.

A partir de los valores absolutos se construyen tres grupos de características:

- ✔ valores absolutos de RSSI;
- ✔ valores relativos respecto a la intensidad media de las balizas observadas en la captura;
- ✔ una máscara de ausencias binaria que indica qué balizas han sido detectadas.

La representación de una captura puede expresarse como:

$$\mathbf{x}_{i,c} = \left[\mathbf{r}_{i,c}, \mathbf{r}_{i,c}^{\mathrm{rel}}, \mathbf{m}_{i,c}\right], \tag{9.8}$$

donde $\mathbf{r}_{i,c}$ contiene los valores absolutos, $\mathbf{r}_{i,c}^{\mathrm{rel}}$ los valores relativos y $\mathbf{m}_{i,c}$ la máscara binaria. Por tanto, cada fingerprint monocanal contiene $3B$ características: 24 cuando se utilizan ocho balizas y 21 cuando se utilizan siete.

Esta preparación es común a los modelos neuronales evaluados. Las diferencias entre ellos se encuentran en la arquitectura, el procedimiento de entrenamiento y la forma de combinar sus predicciones, aspectos que se describen en el capítulo siguiente.

En la configuración multicanal se construye la misma representación para los canales 37, 38 y 39 y se concatenan sus características:

$$\mathbf{x}_i^{\mathrm{multi}} = \left[\mathbf{x}_{i,37}, \mathbf{x}_{i,38}, \mathbf{x}_{i,39}\right]. \tag{9.9}$$

El vector resultante contiene $9B$ características: 72 cuando se utilizan ocho balizas y 63 cuando se utilizan siete. Esta representación se emplea en el método híbrido, mientras que los demás modelos trabajan de forma monocanal.

9.5. Preparación de los conjuntos de referencia, entrenamiento y evaluación

Una vez construidas las matrices, los datos se organizan según la función que desempeñan dentro de cada método. En WKNN, los puntos impares constituyen el conjunto de referencia y forman directamente el mapa de huellas. En los métodos basados en DL, las capturas asociadas a esos mismos puntos se utilizan como conjunto de entrenamiento.

Los puntos pares del 16 de abril forman el conjunto de evaluación común a los dos escenarios. No se utilizan para construir las huellas de referencia ni para ajustar los modelos. De este modo, ninguna coordenada física aparece simultáneamente como referencia o entrenamiento y como evaluación.

Antes de ejecutar los métodos se comprueba que las matrices de referencia y evaluación estén alineadas por dirección `MAC`, canal y protocolo. En el escenario sin la baliza 5, la exclusión se aplica a ambos conjuntos antes de construir las características. Así se evita que el fallo de la baliza genere una dimensión diferente o un patrón de ausencias exclusivo de una parte del experimento.

Las muestras de evaluación conservan inicialmente las cuatro orientaciones de cada punto. Por tanto, cada método genera cuatro estimaciones para cada una de las 30 posiciones pares. Las predicciones se combinan posteriormente mediante la mediana de cada coordenada:

$$\hat{x}_p = \text{mediana}\left(\hat{x}_{p,0^\circ}, \hat{x}_{p,90^\circ}, \hat{x}_{p,180^\circ}, \hat{x}_{p,270^\circ}\right), \tag{9.10}$$

$$\hat{y}_p = \text{mediana}\left(\hat{y}_{p,0^\circ}, \hat{y}_{p,90^\circ}, \hat{y}_{p,180^\circ}, \hat{y}_{p,270^\circ}\right), \tag{9.11}$$

$$\hat{z}_p = \text{mediana}\left(\hat{z}_{p,0^\circ}, \hat{z}_{p,90^\circ}, \hat{z}_{p,180^\circ}, \hat{z}_{p,270^\circ}\right). \tag{9.12}$$

9.6. Formato final de los datos

Tras las fases de limpieza, transformación y preparación, los datos quedan representados mediante matrices numéricas. La estructura concreta depende del método, pero en todos los casos las columnas de señal se ordenan según las direcciones `MAC` seleccionadas y las coordenadas reales se conservan como valores objetivo.

La Tabla 7 resume las representaciones utilizadas.

Cuadro 7: Estructura final de los datos utilizados por los métodos

Representación	**Unidad de muestra**	**Características**	**Valores objetivo**
Referencia de WKNN	Un punto impar por canal	B valores absolutos de RSSI	Coordenadas X, Y y Z del punto.
Evaluación de WKNN	Un punto par y orientación por canal	B valores absolutos de RSSI	Coordenadas X, Y y Z del punto.
Modelos neuronales monocanal	Una captura válida	$3B$: RSSI absoluto, RSSI relativo y máscara de ausencias	Coordenadas X, Y y Z de la captura.
Modelo híbrido multicanal	Una captura válida alineada entre los canales 37, 38 y 39	$9B$: concatenación de las características de los tres canales	Coordenadas X, Y y Z de la captura.

Capítulo 10

Implementación de algoritmos de posicionamiento

En este capítulo se describen los algoritmos de posicionamiento empleados en el presente Trabajo de Fin de Grado, atendiendo tanto a su fundamento como a las decisiones adoptadas para integrarlos en IPSCampaign.

En primer lugar, se presenta el algoritmo WKNN (Weighted k-Nearest Neighbors), empleado como método clásico de referencia y ya disponible en IPSCampaign a partir del trabajo desarrollado por Simon Teodor Rusu Stratulat [14]. A continuación, se describen tres propuestas basadas en redes neuronales: un perceptrón multicapa implementado mediante Scikit-learn, una red residual desarrollada con PyTorch y un método híbrido que combina información de los tres canales publicitarios de BLE.

10.1. Algoritmo WKNN

El algoritmo WKNN es una variante ponderada de KNN utilizada habitualmente en sistemas de posicionamiento basados en fingerprinting. Su funcionamiento se apoya en la comparación entre una muestra cuya posición se desconoce y un conjunto de huellas de señal asociadas a posiciones conocidas del entorno [18, 20, 3].

Cada huella de referencia contiene un patrón de valores de RSSI y las coordenadas reales del punto en el que fue obtenida. La muestra de evaluación debe estar representada mediante las mismas balizas y en el mismo orden. En este trabajo, el algoritmo utiliza directamente los valores absolutos de RSSI preparados en el capítulo anterior:

$$\mathbf{x} = [RSSI_1, RSSI_2, \ldots, RSSI_B]\,, \tag{10.1}$$

donde B representa el número de balizas disponibles en el escenario analizado. Los valores de señal se emplean sin estandarización, por lo que las diferencias se calculan directamente en dBm. Las ausencias puntuales, representadas mediante $-110\,\mathrm{dBm}$, también forman parte de la comparación entre huellas.

El algoritmo calcula una métrica de distancia entre la muestra de evaluación y cada una de las huellas del conjunto de referencia. Esta distancia actúa como una medida de disimilitud: cuanto menor es su valor, más parecidos son los patrones de señal.

En la implementación se consideran cuatro métricas. La distancia euclídea calcula la raíz cuadrada de la suma de las diferencias al cuadrado:

$$d_{\text{Euclidea}}(\mathbf{x}, \mathbf{z}) = \sqrt{\sum_{j=1}^{B} (x_j - z_j)^2}. \tag{10.2}$$

Esta métrica penaliza con mayor intensidad las diferencias grandes, ya que cada discrepancia se eleva al cuadrado antes de agregarse.

La distancia Manhattan suma las diferencias absolutas de todas las componentes:

$$d_{\text{Manhattan}}(\mathbf{x}, \mathbf{z}) = \sum_{j=1}^{B} |x_j - z_j| \,. \tag{10.3}$$

En el contexto de las huellas de señal, representa la discrepancia acumulada entre los valores de RSSI de todas las balizas.

La distancia Chebyshev considera únicamente la mayor diferencia absoluta:

$$d_{\text{Chebyshev}}(\mathbf{x}, \mathbf{z}) = \max_{j} |x_j - z_j| \,. \tag{10.4}$$

Por tanto, dos huellas se consideran alejadas cuando existe al menos una baliza con una discrepancia elevada, aunque el resto de las componentes sean parecidas.

Finalmente, la distancia Minkowski proporciona una formulación general:

$$d_{\text{Minkowski}}(\mathbf{x}, \mathbf{z}) = \left(\sum_{j=1}^{B} |x_j - z_j|^p \right)^{1/p} . \tag{10.5}$$

Esta familia incluye casos habituales, como Manhattan para $p = 1$ y la distancia euclídea para $p = 2$. La elección de la métrica modifica el orden de proximidad entre las huellas y puede producir vecinos diferentes incluso cuando se mantiene el mismo valor de k.

Una vez calculadas las distancias, se seleccionan las k huellas más cercanas. El parámetro k determina cuántos vecinos intervienen en la estimación. Un valor pequeño da mayor importancia a las diferencias locales del mapa de huellas, pero también puede aumentar la sensibilidad al ruido o a una huella atípica. Un valor elevado suaviza la predicción al combinar más puntos, aunque puede introducir posiciones menos próximas y reducir la capacidad de distinguir zonas cercanas.

En los experimentos se evalúan valores de k comprendidos entre 1 y 20. El límite superior se mantiene por debajo del número de huellas disponibles, evitando solicitar más vecinos de los que contiene la referencia.

La principal diferencia entre KNN y WKNN se encuentra en la combinación de los vecinos. En KNN, todos los vecinos seleccionados suelen contribuir de forma equivalente. En WKNN, cada vecino recibe un peso inversamente proporcional a su distancia:

$$w_i = \frac{1}{d_i}, \tag{10.6}$$

donde d_i representa la distancia entre la muestra y el vecino i. De esta forma, una huella muy cercana tiene mayor influencia que otra situada a una distancia superior.

La posición estimada se obtiene mediante la media ponderada de las coordenadas de los vecinos:

$$\hat{\mathbf{p}} = \frac{\sum_{i=1}^{k} w_i \mathbf{p}_i}{\sum_{i=1}^{k} w_i}, \tag{10.7}$$

donde $\mathbf{p}_i$ es la posición real asociada a la huella i.

Debe considerarse el caso en el que una huella presente una distancia exactamente igual a cero. Aplicar directamente la inversión produciría una división por cero. Por este motivo, cuando existe una o varias coincidencias exactas, únicamente participan en la estimación esos vecinos. Si hay varias coincidencias, todas reciben el mismo peso. Cuando no existen distancias nulas, se utiliza la ponderación inversa habitual.

La implementación utiliza el regresor de vecinos más próximos proporcionado por Scikit-learn, configurado como un problema de regresión multisalida. Esta configuración permite predecir simultáneamente X, Y y Z, en lugar de entrenar un estimador separado para cada coordenada.

Además de la métrica y del valor de k, la herramienta permite seleccionar la estrategia utilizada para localizar los vecinos. Estas estrategias no modifican la formulación matemática de WKNN; determinan cómo se organiza y recorre el conjunto de referencia durante la búsqueda.

La búsqueda exhaustiva compara la muestra con todas las huellas. Es la alternativa más directa y resulta adecuada cuando el mapa de referencia tiene un tamaño reducido. La estructura *KD tree*, o árbol k-dimensional, divide recursivamente el espacio de características para descartar regiones que no pueden contener vecinos cercanos. El *ball tree*, o árbol de bolas, organiza las muestras en regiones aproximadamente esféricas y puede resultar útil para determinadas métricas o distribuciones. La selección automática permite que la librería escoja internamente la estrategia que considera más apropiada.

En este trabajo, la métrica y el número de vecinos influyen directamente en la predicción. La estrategia de búsqueda afecta principalmente al procedimiento computacional empleado para recuperar los vecinos. Debido al tamaño limitado del mapa de huellas, el coste de evaluar las distintas alternativas se mantiene controlado.

El algoritmo se ejecuta de forma independiente para cada canal publicitario seleccionado. Para cada combinación de canal, métrica, estrategia de búsqueda y valor de k, se generan las coordenadas estimadas de las muestras de evaluación. Esta exploración permite identificar qué configuración se adapta mejor al comportamiento de las señales del entorno y proporciona una referencia frente a los modelos neuronales.

10.2. Algoritmos basados en Deep Learning

Los métodos basados en DL amplían IPSCampaign mediante modelos capaces de aprender relaciones no lineales entre los patrones de RSSI y las coordenadas reales. Esta capacidad resulta relevante en interiores, donde las señales pueden variar debido a obstáculos, reflexiones, multitrayecto, orientación del receptor, interferencias o cambios temporales en el escenario.

A diferencia de WKNN, estos métodos no conservan el conjunto de referencia como una tabla sobre la que buscar vecinos. Durante el entrenamiento ajustan los parámetros de una función:

$$\hat{\mathbf{p}} = f_{\boldsymbol{\theta}}(\mathbf{x}), \tag{10.8}$$

donde $\mathbf{x}$ representa el vector de características, $\boldsymbol{\theta}$ los parámetros aprendidos y $\hat{\mathbf{p}}$ la posición estimada.

La entrada monocanal contiene los tres bloques construidos en el capítulo anterior: RSSI absoluto, RSSI relativo y máscara de ausencias. Con B balizas, el vector contiene $3B$ características. El método híbrido concatena esta representación para los canales 37, 38 y 39, obteniendo $9B$ características.

Antes de describir cada modelo, conviene introducir varias operaciones comunes. La estandarización transforma una variable para que presente una escala adecuada para el aprendizaje. En este trabajo se estandarizan tanto las características de entrada como las coordenadas objetivo. Esta transformación facilita la optimización y evita que una variable tenga mayor influencia únicamente por su magnitud numérica.

Una vez generadas las predicciones, se aplica un recorte espacial. Para cada dimensión $d \in \{x, y, z\}$, la coordenada se limita al intervalo observado durante el entrenamiento:

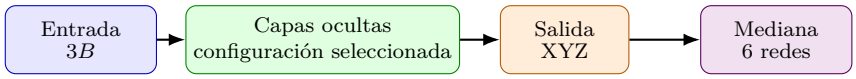
$$\hat{p}_d^{\text{rec}} = \text{mín}\left(p_d^{\text{máx}}, \text{máx}\left(p_d^{\text{mín}}, \hat{p}_d\right)\right). \tag{10.9}$$

Este recorte evita estimaciones físicamente fuera del espacio conocido. No obstante, también impide la extrapolación más allá de la región medida, por lo que debe considerarse al interpretar los errores extremos.

Otro elemento común es el uso de ensembles. Un ensemble combina varios modelos entrenados de manera independiente para reducir la dependencia de una única inicialización o trayectoria de aprendizaje. Las redes pueden producir resultados ligeramente diferentes aunque utilicen el mismo conjunto de datos. Al combinar sus salidas mediante la mediana, las predicciones anómalas tienen menor influencia que en una media aritmética.

La Figura 9 resume las dos arquitecturas monocanal desarrolladas.

(a) Perceptrón multicapa



(b) Red residual

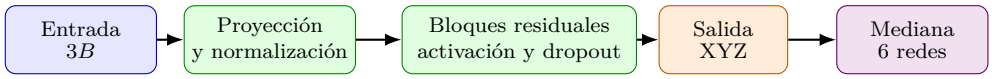


Ilustración 9: Arquitecturas monocanal utilizadas para la estimación de posiciones. B representa el número de balizas disponibles.

10.2.1. Perceptrón multicapa con Scikit-learn

El primer modelo neuronal utiliza un perceptrón multicapa, también denominado MLP por sus siglas en inglés. Una red neuronal de este tipo está formada por una capa de entrada, una o varias capas ocultas y una capa de salida. Cada capa oculta combina linealmente las entradas y aplica una función de activación, introduciendo la no linealidad necesaria para representar relaciones complejas.

La capa de entrada recibe las $3B$ características de cada *fingerprint*. La salida contiene tres neuronas, correspondientes a las coordenadas X, Y y Z. Durante el entrenamiento, el modelo ajusta sus pesos para reducir la diferencia entre las posiciones predichas y las posiciones reales.

No se adopta una única arquitectura fija. Se consideran tres configuraciones candidatas, mostradas en la Tabla 8.

Cuadro 8: Configuraciones candidatas del perceptrón multicapa

Capas ocultas	**Función de activación**	**Regularización**
128×64	ReLU	0,001
$256 \times 128 \times 64$	ReLU	0,001
$128 \times 128 \times 64$	tanh	0,003

La activación ReLU conserva los valores positivos y anula los negativos. Su simplicidad facilita el entrenamiento de redes multicapa. La activación hiperbólica, o tanh, transforma la salida al intervalo comprendido entre -1 y 1, proporcionando una respuesta suave y centrada alrededor de cero.

El parámetro de regularización penaliza pesos excesivamente grandes. Esta regularización reduce la tendencia del modelo a memorizar detalles particulares del conjunto de entrenamiento y ayuda a limitar el sobreajuste. Una arquitectura demasiado pequeña puede no aprender la relación entre señal y posición, mientras que una arquitectura excesivamente compleja puede adaptarse al ruido y perder capacidad de generalización.

La selección se realiza mediante validación cruzada agrupada. La validación cruzada divide los datos en varios subconjuntos, entrena con una parte y valida con la restante, repitiendo el proceso con distintas particiones. En este caso, las capturas se agrupan según sus coordenadas reales, de modo que todas las muestras de una misma posición permanecen en el mismo subconjunto.

Esta agrupación evita que capturas muy similares de un mismo punto aparezcan simultáneamente en entrenamiento y validación. Sin esta precaución, el resultado interno podría ser excesivamente optimista, especialmente en el escenario multijornada, donde existen varias capturas de una misma posición adquiridas en días diferentes.

Cuando el número de posiciones lo permite, se utilizan hasta cuatro particiones. Cada arquitectura se ordena mediante una función que combina el error medio con el percentil 90:

$$J = \overline{e} + 0{,}5 \cdot P90(e). \tag{10.10}$$

El error medio resume el comportamiento general, mientras que el percentil 90 indica el valor por debajo del cual se encuentra el 90 % de los errores. La combinación penaliza configuraciones que ofrecen una media reducida, pero producen fallos elevados en una fracción de las muestras.

Se conservan las dos configuraciones mejor valoradas y se entrenan seis redes con distintas semillas. La semilla controla los procesos aleatorios, como la inicialización de los pesos, permitiendo obtener modelos diferentes a partir de la misma arquitectura y los mismos datos.

Las características y las coordenadas se someten a estandarización. Después, cada red se entrena mediante uno de dos optimizadores, dependiendo del tamaño del conjunto. Para conjuntos suficientemente grandes se utiliza Adam. Este optimizador adapta el tamaño de las actualizaciones de cada parámetro a partir del historial de sus gradientes. Además, se utiliza *early stopping*, que detiene el entrenamiento cuando el rendimiento deja de mejorar y reduce el riesgo de sobreajuste.

Cuando el conjunto es pequeño se utiliza L-BFGS, un optimizador que aproxima información de segundo orden para buscar una solución con pocas muestras. Su coste por actualización puede ser superior, pero puede converger adecuadamente en problemas de tamaño reducido.

Cada red genera una predicción independiente. La salida del ensemble se calcula mediante la mediana por coordenada:

$$\hat{p}_d = \text{mediana}\left\{\hat{p}_d^{(1)}, \hat{p}_d^{(2)}, \ldots, \hat{p}_d^{(6)}\right\}, \tag{10.11}$$

donde $d \in \{x, y, z\}$. Esta agregación reduce la influencia de una red aislada que produzca una estimación alejada del resto.

El modelo se entrena y evalúa de forma independiente para cada canal publicitario. Esta separación permite estudiar si los canales 37, 38 o 39 proporcionan patrones de señal con diferente capacidad de localización.

10.2.2. Red neuronal residual con PyTorch

El segundo modelo neuronal utiliza una arquitectura multicapa con conexiones residuales. Una conexión residual combina la entrada de un bloque con la transformación aprendida por dicho bloque:

$$\mathbf{h}_{l+1} = \text{SiLU}\left(\mathbf{h}_l + \mathcal{F}_l(\mathbf{h}_l)\right). \tag{10.12}$$

El término $\mathbf{h}_l$ representa la entrada del bloque y $\mathcal{F}_l$ la transformación formada por capas lineales, normalización y regularización. Esta estructura permite que el bloque aprenda una corrección sobre la representación existente, en lugar de reconstruirla completamente. Los bloques residuales facilitan el flujo del gradiente y contribuyen a la estabilidad de redes con varias capas.

Antes de los bloques se aplica una proyección lineal que transforma las $3B$ características al ancho interno de la red. Después se utiliza normalización por capa. Esta técnica normaliza las activaciones dentro de cada muestra, evitando diferencias excesivas de escala entre las componentes internas.

La función de activación utilizada es SiLU. Esta función multiplica la entrada por una versión sigmoide de ella misma, produciendo una transición suave entre valores negativos y positivos. Frente a activaciones con cambios bruscos, puede favorecer actualizaciones más estables durante el aprendizaje.

Dentro de los bloques también se aplica *dropout*. Esta técnica desactiva aleatoriamente una parte de las activaciones durante el entrenamiento. Su objetivo es impedir que la red dependa en exceso de un conjunto reducido de neuronas y actuar como mecanismo de regularización.

Se consideran tres configuraciones candidatas:

Cuadro 9: Arquitecturas candidatas de la red residual

Anchura interna	**Bloques residuales**	**Dropout**
64	2	0,05
128	2	0,10
128	3	0,15

La anchura indica el número de características internas procesadas por cada bloque. Aumentar la anchura o el número de bloques incrementa la capacidad de representación, pero también el coste y el riesgo de sobreajuste.

La selección se realiza mediante validación cruzada agrupada por posición, utilizando hasta tres particiones cuando existen suficientes huellas y posiciones distintas. Se aplica la misma función de valoración que en el modelo anterior:

$$J = \overline{e} + 0{,}5 \cdot P90(e). \tag{10.13}$$

Tras seleccionar las dos arquitecturas con mejor comportamiento, se entrena un ensemble de seis redes con semillas diferentes. Las características de entrada y las coordenadas se estandarizan antes del entrenamiento y se recupera la escala original al generar las posiciones.

El entrenamiento utiliza AdamW. Este optimizador conserva el ajuste adaptativo de Adam e incorpora decaimiento de pesos. El decaimiento penaliza parámetros demasiado grandes y constituye una forma de regularización.

La tasa de aprendizaje inicial controla la magnitud de las actualizaciones. En lugar de mantenerla constante, se utiliza un planificador cosenoidal, que la reduce progresivamente siguiendo una curva suave. Durante las primeras épocas se permiten cambios mayores y, conforme avanza el entrenamiento, las actualizaciones se hacen más pequeñas para refinar la solución.

El entrenamiento se limita a un máximo de 1200 épocas. Una época corresponde a una pasada completa por el conjunto de entrenamiento. También se aplica *early stopping*: si la mejora se detiene durante un número prolongado de épocas, se conserva el mejor estado alcanzado y finaliza el proceso.

Para evitar actualizaciones inestables se utiliza recorte del gradiente. Esta operación limita la norma máxima del gradiente antes de modificar los parámetros. Así se reducen los saltos bruscos que podrían aparecer cuando una muestra genera un error elevado.

La función de pérdida se define sobre la distancia física entre la posición real y la predicha:

$$d_i = \sqrt{(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 + (z_i - \hat{z}_i)^2}. \tag{10.14}$$

Sobre esta distancia se aplica la pérdida Huber. Para errores pequeños se comporta de forma cuadrática, favoreciendo ajustes precisos, mientras que para errores grandes pasa a un crecimiento lineal y reduce la influencia de valores extremos:

$$H_\delta(d) = \begin{cases} \dfrac{d^2}{2\delta}, & d \leq \delta, \\ d - \dfrac{\delta}{2}, & d > \delta. \end{cases} \tag{10.15}$$

En la configuración empleada, $\delta = 0{,}75$ metros. Además, se añade una penalización sobre el 20 % de las muestras con mayor error. La pérdida total puede representarse como:

$$\mathcal{L} = \frac{1}{n}\sum_{i=1}^{n} H_\delta(d_i) + \lambda \cdot \text{media}\left(\text{Top}_{20\,\%}\left\{d_1, \ldots, d_n\right\}\right), \tag{10.16}$$

donde $\lambda = 0{,}35$. El segundo término busca que la red no se limite a mejorar la media, sino que también reduzca los errores más elevados.

El aprendizaje se realiza en modo *full-batch*. Esto significa que cada actualización utiliza todo el conjunto de entrenamiento, en lugar de dividirlo en minilotes. Dado el tamaño de los datos, este procedimiento permite calcular una pérdida estable. Cuando el equipo dispone de una unidad gráfica compatible, PyTorch puede emplearla para acelerar las operaciones; en caso contrario, el mismo entrenamiento se ejecuta sobre el procesador principal.

La salida del ensemble vuelve a calcularse mediante la mediana de las seis redes. Al igual que el perceptrón multicapa, este modelo se ejecuta de forma independiente para cada canal publicitario.

10.2.3. Método híbrido multicanal

El tercer método combina la información de los canales 37, 38 y 39. Su objetivo es aprovechar la complementariedad entre canales, ya que una misma baliza puede presentar valores distintos de RSSI en función de la frecuencia, las interferencias, las reflexiones y la orientación del receptor.

Para cada canal se dispone de un vector de $3B$ características. Los tres bloques se concatenan:

$$\mathbf{x}_{\text{multi}} = [\mathbf{x}_{37} \mid \mathbf{x}_{38} \mid \mathbf{x}_{39}]\,. \tag{10.17}$$

La entrada resultante contiene $9B$ características. Antes de realizar la concatenación se comprueba que las muestras de los tres canales correspondan a las mismas coordenadas objetivo. El método necesita información suficiente en los tres canales; si falta uno de ellos, no puede construirse la representación esperada.

La arquitectura contiene dos ramas. La principal utiliza la representación multicanal y un ensemble de redes residuales. La secundaria emplea únicamente el canal 37 y un ensemble de perceptrones multicapa. Esta segunda rama aporta una estimación auxiliar obtenida mediante una representación monocanal.

La rama principal utiliza 48 redes residuales. El uso de un número elevado de modelos busca reducir la dependencia de una sola inicialización y aprovechar configuraciones con comportamientos ligeramente diferentes. El entrenamiento puede alcanzar hasta 1800 épocas, aunque la parada anticipada puede finalizarlo antes.

Cada red genera una posición y la salida de la rama principal se calcula mediante la mediana:

$$\hat{\mathbf{p}}_{\text{res}} = \text{mediana}\left\{\hat{\mathbf{p}}_{\text{res}}^{(1)}, \ldots, \hat{\mathbf{p}}_{\text{res}}^{(48)}\right\}. \tag{10.18}$$

La rama auxiliar está formada por seis perceptrones multicapa entrenados con las características del canal 37. Su salida se obtiene de la misma manera:

$$\hat{\mathbf{p}}_{\text{MLP}} = \text{mediana}\left\{\hat{\mathbf{p}}_{\text{MLP}}^{(1)}, \ldots, \hat{\mathbf{p}}_{\text{MLP}}^{(6)}\right\}. \tag{10.19}$$

Las dos predicciones se combinan mediante una media ponderada:

$$\hat{\mathbf{p}}_{\text{hibrida}} = 0{,}85 \cdot \hat{\mathbf{p}}_{\text{res}} + 0{,}15 \cdot \hat{\mathbf{p}}_{\text{MLP}}. \tag{10.20}$$

La rama multicanal aporta el 85 % de la estimación y la rama auxiliar el 15 %. Estos pesos y las configuraciones de producción se fijaron después de una calibración previa sobre huellas de referencia. No se vuelven a seleccionar cada vez que se ejecuta el método.

La predicción combinada se limita posteriormente a los rangos espaciales observados durante el entrenamiento. La Figura 10 resume el flujo completo.

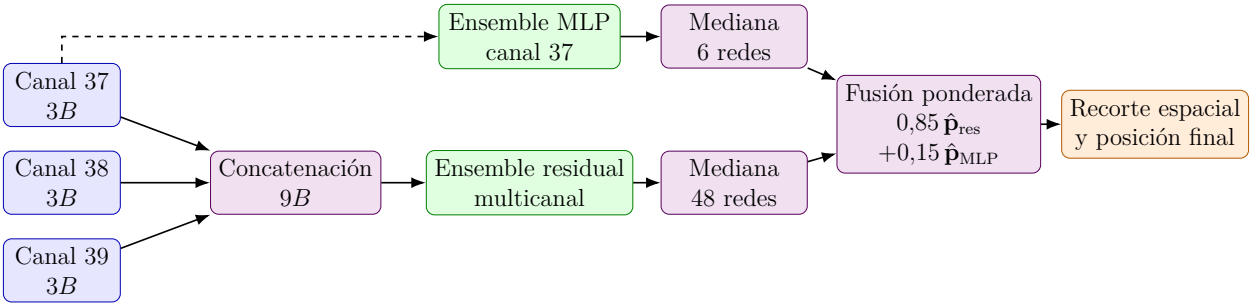


Ilustración 10: Arquitectura general del método híbrido multicanal.

El método híbrido recibe más información que los modelos monocanal y presenta un coste de entrenamiento superior. Por ello, una mejora frente a los otros métodos puede deberse tanto a la arquitectura como al uso conjunto de los tres canales. Esta diferencia debe tenerse en cuenta durante el análisis de los resultados.

10.3. Integración de los métodos en IPSCampaign

Los cuatro métodos se integran dentro de un flujo común. La herramienta recupera las matrices construidas durante el tratamiento de los datos, aplica la configuración seleccionada y genera las coordenadas estimadas.

En WKNN, el usuario configura el canal, la métrica de distancia, la estrategia de búsqueda y el intervalo de valores de k. La herramienta ejecuta todas las combinaciones solicitadas y conserva sus resultados de forma independiente.

Los modelos monocanal reciben la matriz correspondiente al canal seleccionado. Primero se realiza la selección interna de configuraciones cuando corresponde; después se entrenan los integrantes del ensemble, se agregan sus predicciones y se aplica el recorte espacial. El método híbrido recibe simultáneamente los tres canales y combina sus dos ramas antes de devolver la posición.

Cada método produce inicialmente una estimación por orientación. La fusión de las cuatro orientaciones mediante la mediana y la organización de las posiciones finales se realizan siguiendo el procedimiento descrito en el capítulo anterior. De este modo, todos los métodos se comparan con el mismo conjunto de evaluación y con el mismo criterio de agregación.

El error de posicionamiento se calcula como la distancia euclídea tridimensional entre la posición real y la estimada:

$$e = \sqrt{(x - \hat{x})^2 + (y - \hat{y})^2 + (z - \hat{z})^2}. \tag{10.21}$$

Las predicciones, los errores y la descripción de cada configuración quedan disponibles para el módulo de métricas de IPSCampaign. El capítulo siguiente presenta las medidas utilizadas para resumir estas distribuciones y comparar el rendimiento de WKNN, el perceptrón multicapa, la red residual y el método híbrido.

10.4. Comparación de los métodos implementados

La Tabla 10 resume las principales diferencias entre los métodos.

Cuadro 10: Comparación de los métodos de posicionamiento implementados

Método	**Entrada**	**Uso de canales**	**Agregación interna**	**Aspectos principales**
WKNN	B valores absolutos de RSSI	Un canal por ejecución	Media ponderada de k vecinos	No requiere entrenamiento; depende de la métrica, k y el mapa de huellas.
Perceptrón multicapa	$3B$ características	Un canal por ejecución	Mediana de seis redes	Estandarización, validación agrupada y selección entre varias arquitecturas.
Red residual	$3B$ características	Un canal por ejecución	Mediana de seis redes	Bloques residuales, pérdida Huber y penalización de los errores más altos.
Método híbrido	$9B$ características	Canales 37, 38 y 39	Fusión de 48 redes residuales y seis MLP	Combina información multicanal con una rama auxiliar monocanal.

En conjunto, WKNN representa una solución sencilla e interpretable que utiliza directamente el mapa de huellas. Los modelos neuronales requieren una fase de entrenamiento, pero pueden aprender relaciones no lineales y aprovechar las variaciones presentes en las capturas. El método híbrido añade información multicanal y una combinación más amplia de modelos, a cambio de un coste computacional superior.

Capítulo 11

Métricas de evaluación

En este capítulo se describen las métricas y representaciones utilizadas para evaluar los métodos de posicionamiento integrados en IPSCampaign. Una vez obtenida una posición estimada, es necesario cuantificar su separación respecto a la posición real y analizar cómo se distribuyen los errores en el conjunto de evaluación.

11.1. Obtención de las posiciones finales

Cada punto de evaluación dispone de cuatro capturas, correspondientes a las orientaciones 0°, 90°, 180° y 270°. Los métodos generan inicialmente una predicción para cada orientación. Por tanto, antes de la agregación se obtienen:

$$30 \text{ puntos} \times 4 \text{ orientaciones} = 120 \text{ predicciones.} \tag{11.1}$$

Las cuatro estimaciones asociadas a un mismo punto se fusionan mediante la mediana de cada coordenada:

$$\hat{x}_i = \text{mediana}\left\{\hat{x}_{i,0^\circ}, \hat{x}_{i,90^\circ}, \hat{x}_{i,180^\circ}, \hat{x}_{i,270^\circ}\right\}, \tag{11.2}$$

$$\hat{y}_i = \text{mediana}\left\{\hat{y}_{i,0^\circ}, \hat{y}_{i,90^\circ}, \hat{y}_{i,180^\circ}, \hat{y}_{i,270^\circ}\right\}, \tag{11.3}$$

$$\hat{z}_i = \text{mediana}\left\{\hat{z}_{i,0^\circ}, \hat{z}_{i,90^\circ}, \hat{z}_{i,180^\circ}, \hat{z}_{i,270^\circ}\right\}. \tag{11.4}$$

Esta operación reduce la influencia de una orientación que produzca una estimación claramente alejada del resto. Después de la fusión se obtiene una única posición predicha para cada punto:

$$\hat{\mathbf{p}}_i = [\hat{x}_i, \hat{y}_i, \hat{z}_i], \qquad i = 1, \ldots, 30. \tag{11.5}$$

A partir de estas 30 posiciones finales se calculan los errores y las representaciones utilizadas en la evaluación.

11.2. Error de posicionamiento

El error principal se calcula mediante la distancia euclídea tridimensional entre la posición real y la posición estimada:

$$e_i^{3D} = \sqrt{(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 + (z_i - \hat{z}_i)^2}. \tag{11.6}$$

En esta expresión, (x_i, y_i, z_i) representa la posición real del punto i, $(\hat{x}_i, \hat{y}_i, \hat{z}_i)$ la posición estimada y e_i^{3D} su error de posicionamiento. Si las coordenadas están expresadas en metros, el error también se expresa en metros.

Con 30 posiciones de evaluación se obtiene el conjunto:

$$\mathcal{E}^{3D} = \left\{ e_1^{3D}, e_2^{3D}, \ldots, e_{30}^{3D} \right\}. \tag{11.7}$$

Un valor menor indica una estimación más próxima a la posición real. El valor cero corresponde a una coincidencia exacta.

La interfaz también calcula un error euclídeo bidimensional para la representación espacial:

$$e_i^{2D} = \sqrt{(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2}. \tag{11.8}$$

Este error considera únicamente las coordenadas representadas en la planta del escenario. En el entorno utilizado, todos los puntos se encuentran en el mismo plano y la coordenada Z permanece constante. Por ello, los errores bidimensional y tridimensional deberían presentar valores iguales o muy próximos siempre que el método no produzca una desviación apreciable en Z.

No obstante, ambas magnitudes deben distinguirse metodológicamente:

- ✔ el error e_i^{2D} se utiliza en el resumen asociado a la gráfica de exactitud;
- ✔ el error e_i^{3D} se utiliza para construir la gráfica de precisión y sus métricas resumen.

11.3. Gráfica de exactitud

La gráfica denominada exactitud representa espacialmente los 30 puntos reales y los 30 puntos estimados después de fusionar las cuatro orientaciones. Su finalidad es mostrar dónde se producen los errores y si existe algún patrón espacial en las predicciones.

Esta representación permite observar, entre otros aspectos:

- ✔ puntos correctamente localizados;
- ✔ zonas del escenario con errores sistemáticamente mayores;
- ✔ desplazamientos de las predicciones hacia una región concreta;
- ✔ agrupamientos de posiciones estimadas;
- ✔ puntos aislados con errores especialmente elevados.

La gráfica se construye sobre las coordenadas X e Y. Por tanto, las métricas mostradas junto a ella se calculan a partir de los errores en planta definidos en la Ecuación 11.8.

11.3.1. Media del error

La media aritmética resume la separación promedio entre las posiciones reales y estimadas:

$$\overline{e}^{\,2D} = \frac{1}{N}\sum_{i=1}^{N} e_i^{2D}, \qquad N = 30. \tag{11.9}$$

Por ejemplo, una media de 1,5 m indica que las posiciones estimadas se encuentran, en promedio, a 1,5 m de las posiciones reales. Cuanto menor sea este valor, mayor será la exactitud media del método.

La media utiliza todos los errores y puede verse afectada por unos pocos puntos con desviaciones muy elevadas. Por este motivo debe analizarse junto con la mediana, el RMSE, el percentil 90 y el máximo.

11.3.2. Mediana

La mediana describe el error central del conjunto ordenado y resulta menos sensible a los valores extremos. La implementación utiliza el método del rango más próximo. Si los errores ordenados son:

$$e_{(1)} \le e_{(2)} \le \cdots \le e_{(N)}, \tag{11.10}$$

la mediana se calcula como:

$$P50 = e_{(\lceil 0{,}5N \rceil)}. \tag{11.11}$$

Con $N = 30$, se selecciona el error situado en la posición 15 del conjunto ordenado. Esta definición difiere de la convención que promedia los elementos situados en las posiciones 15 y 16 cuando el número de observaciones es par. Conviene mantener esta particularidad al reproducir o comparar los resultados de la aplicación.

11.3.3. Raíz del error cuadrático medio

El RMSE se calcula sobre las distancias bidimensionales:

$$RMSE^{2D} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(e_i^{2D})^2}. \tag{11.12}$$

Al elevar los errores al cuadrado, esta métrica penaliza con mayor intensidad los puntos con desviaciones grandes. Si un método presenta varios errores elevados, el RMSE aumentará más que la media aritmética.

No debe confundirse esta expresión con un RMSE calculado de forma independiente para cada coordenada. En IPSCampaign se aplica sobre las distancias euclídeas bidimensionales ya obtenidas.

11.3.4. Percentil 90

El percentil 90 indica el error por debajo del cual se sitúa aproximadamente el 90 % de los puntos:

$$P90 = e_{(\lceil 0{,}9N \rceil)}. \tag{11.13}$$

Con $N = 30$, el índice utilizado es:

$$\lceil 30 \cdot 0{,}9 \rceil = 27. \tag{11.14}$$

Por tanto, se selecciona el error situado en la posición 27 del conjunto ordenado. Un valor de $P90 = 3{,}2\,\text{m}$ significa que aproximadamente el 90 % de los puntos presenta un error igual o inferior a 3,2 m.

Esta métrica permite valorar la fiabilidad del sistema más allá del comportamiento medio. Un método puede presentar una media reducida y, al mismo tiempo, un $P90$ elevado si una parte de sus predicciones produce errores considerables.

11.3.5. Error máximo y número de puntos

El error máximo representa el peor resultado observado:

$$e^{2D}_{\text{máx}} = \text{máx}\left\{e^{2D}_1, e^{2D}_2, \ldots, e^{2D}_N\right\}. \tag{11.15}$$

Este valor permite detectar fallos extremos, aunque puede estar condicionado por un único punto problemático. Por ello no debe utilizarse como única medida para decidir qué método ofrece un mejor comportamiento.

La interfaz muestra además el número de puntos utilizados en el cálculo. En los experimentos de este trabajo se espera:

$$N = 30. \tag{11.16}$$

Mostrar N permite verificar que todas las configuraciones se han evaluado sobre el mismo número de posiciones finales.

11.4. Gráfica de precisión

La gráfica denominada precisión utiliza los errores tridimensionales calculados mediante la Ecuación 11.6. A partir de ellos se construye una CDF empírica, que representa la proporción acumulada de puntos cuyo error es inferior o igual a un umbral determinado.

Si los errores se ordenan de menor a mayor:

$$e^{3D}_{(1)} \leq e^{3D}_{(2)} \leq \cdots \leq e^{3D}_{(N)}, \tag{11.17}$$

la función acumulada asociada al error $e^{3D}_{(i)}$ es:

$$F\left(e^{3D}_{(i)}\right) = \frac{i}{N}. \tag{11.18}$$

El eje horizontal representa el error en metros y el eje vertical la proporción acumulada de puntos. Con $N = 30$, cada incremento de la curva equivale a:

$$\frac{1}{30} = 0{,}0333 = 3{,}33\,\%. \tag{11.19}$$

Una curva situada más arriba y hacia la izquierda representa un mejor comportamiento, ya que alcanza proporciones elevadas con umbrales de error menores.

Por ejemplo, si para un error de 2 m se obtiene:

$$F_A(2) = 0{,}80, \qquad F_B(2) = 0{,}60, \tag{11.20}$$

significa que el 80 % de los puntos del método A presenta un error igual o inferior a 2 m, mientras que en el método B esta proporción es del 60 %. Para ese umbral, el método A presenta un mejor comportamiento.

La CDF permite analizar la distribución completa sin reducirla a un único indicador. Dos métodos pueden presentar una media similar y, sin embargo, mostrar comportamientos diferentes en los errores bajos o en la cola de la distribución. Si las curvas se cruzan, uno de los métodos puede ser mejor para determinados umbrales y peor para otros.

Junto a la gráfica se muestran las siguientes métricas calculadas sobre los errores tridimensionales:

- ✔ media;
- ✔ mediana mediante rango más próximo;
- ✔ $P90$;
- ✔ error máximo.

Estas métricas se calculan mediante las mismas definiciones utilizadas en la gráfica de exactitud, sustituyendo e_i^{2D} por e_i^{3D}. Aunque el RMSE puede calcularse internamente a partir de los errores tridimensionales, no se muestra en la tabla asociada a la gráfica de precisión.

11.5. Métricas incorporadas y métricas existentes

Antes de la realización de este trabajo, IPSCampaign ya permitía calcular el error euclídeo por predicción y representar su distribución mediante una CDF. También incluía diferentes métricas de distancia para la ejecución de WKNN, como la distancia euclídea, la distancia Manhattan, la distancia Chebyshev y la distancia Minkowski.

Estas últimas no deben confundirse con las métricas de evaluación. En WKNN, las distancias entre vectores de RSSI se utilizan para seleccionar las huellas de señal más próximas. En cambio, las métricas de este capítulo comparan las coordenadas reales y estimadas después de aplicar el método.

Durante el desarrollo del proyecto se amplió el resumen de resultados mediante la incorporación o exposición conjunta de:

- ✔ media del error;
- ✔ mediana;
- ✔ RMSE en la gráfica de exactitud;

- ✔ $P90$;
- ✔ error máximo;
- ✔ número de puntos evaluados.

Esta combinación proporciona una visión más completa que un único valor promedio. La media resume el comportamiento general, la mediana representa un caso central robusto, el RMSE penaliza los errores elevados, el $P90$ describe la fiabilidad de la mayoría de los puntos y el máximo permite identificar el peor caso.

11.6. Comparación de los métodos

Para comparar dos configuraciones, ambas deben evaluarse sobre las mismas posiciones físicas y bajo el mismo escenario experimental. En este trabajo, todos los métodos utilizan los 30 puntos pares del 16 de abril y fusionan las cuatro orientaciones mediante el mismo procedimiento.

Dentro de cada escenario también debe mantenerse el mismo conjunto de balizas. En el escenario 1 se utilizan las ocho balizas disponibles, mientras que en el escenario 2 se elimina la baliza 5 tanto de la referencia o entrenamiento como de la evaluación. Debido a esta diferencia, las métricas permiten comparar métodos dentro de cada escenario, pero el cambio entre escenarios no debe atribuirse exclusivamente al algoritmo.

Las comparaciones entre los métodos monocanal deben realizarse manteniendo fijo el canal publicitario. WKNN, el perceptrón multicapa y la red residual se ejecutan de forma independiente para los canales 37, 38 y 39.

El método híbrido utiliza simultáneamente los tres canales. Por tanto, una posible mejora frente a un método monocanal puede deberse tanto a su arquitectura como a la mayor cantidad de información disponible. Esta diferencia debe indicarse al interpretar los resultados.

En general, valores menores de media, mediana, RMSE, $P90$ y máximo indican un mejor comportamiento. Sin embargo, ninguna métrica debe analizarse de forma aislada. Un método puede presentar una media reducida y un máximo elevado, o una mediana favorable y una cola de errores considerable. Por este motivo, el análisis debe combinar las métricas resumen, la CDF y la representación espacial.

Cuando se desea expresar la mejora relativa de un método A frente a un método B, puede utilizarse:

$$\text{Mejora relativa} = \frac{M_B - M_A}{M_B} \cdot 100, \tag{11.21}$$

donde M_A y M_B representan la misma métrica calculada sobre el mismo conjunto de puntos. Un resultado positivo indica que el método A reduce la métrica respecto al método B.

Esta expresión solo es válida cuando las condiciones experimentales son comparables. No debe utilizarse para presentar como mejora exclusivamente algorítmica una diferencia obtenida entre escenarios con distinto número de jornadas, distinto conjunto de balizas o diferente cantidad de información de entrada.

11.7. Resumen del procedimiento de evaluación

El procedimiento seguido para evaluar cada configuración puede resumirse en las siguientes etapas:

1. Se generan cuatro predicciones por punto, una para cada orientación.
2. Las cuatro estimaciones se fusionan mediante la mediana de X, Y y Z.
3. Se obtienen 30 posiciones finales.
4. El sistema calcula el error euclídeo tridimensional de cada punto.
5. La gráfica de precisión construye una CDF y muestra la media, la mediana, el $P90$ y el máximo de esos errores.
6. La gráfica de exactitud representa los puntos reales y predichos en el plano XY y muestra la media, la mediana, el RMSE, el $P90$, el máximo y el número de puntos.

De este modo, la evaluación combina una representación espacial, una distribución acumulada y varias métricas resumen. Este conjunto de indicadores permite estudiar el comportamiento medio, el caso central, los errores elevados y los fallos extremos de cada método bajo los dos escenarios experimentales.

Capítulo 12

Resultados y análisis

En este capítulo se presentan y analizan los resultados obtenidos con los métodos de posicionamiento integrados en IPSCampaign. Se trata del núcleo experimental del trabajo, ya que permite comprobar si las técnicas desarrolladas son capaces de estimar correctamente la posición del receptor y, especialmente, si mantienen su comportamiento cuando cambian las condiciones de adquisición.

El análisis se centra principalmente en la exactitud, entendida como la distancia entre la posición real y la posición estimada en el plano del escenario. La precisión, representada mediante la CDF del error tridimensional, se utiliza como una comprobación complementaria de la distribución de los errores.

La separación entre ambos conceptos se mantiene de forma explícita durante todo el capítulo:

- ✔ las **gráficas de exactitud** muestran espacialmente los puntos reales y estimados y proporcionan las métricas principales del análisis;
- ✔ las **gráficas de precisión** muestran la distribución acumulada de los errores y se emplean para comprobar la presencia de colas de error o fallos extremos.

Se comparan dos escenarios. El primero representa unas condiciones controladas o próximas al funcionamiento ideal: todas las balizas están operativas y la referencia y la evaluación pertenecen a la misma jornada. El segundo aproxima el experimento a unas condiciones más realistas: la referencia incorpora mediciones obtenidas en días diferentes y se elimina la baliza 5 debido a su funcionamiento anómalo.

Esta diferencia permite estudiar no solo cuál es el método más exacto, sino también cuál mantiene una mayor estabilidad cuando las señales presentan variaciones temporales y disminuye la información disponible.

12.1. Criterio de evaluación

Cada punto de evaluación dispone de cuatro predicciones, correspondientes a las orientaciones 0°, 90°, 180° y 270°. Estas predicciones se fusionan mediante la mediana de cada coordenada, obteniéndose una posición final por punto.

La exactitud en planta se calcula mediante:

$$e_i^{XY} = \sqrt{(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2}, \tag{12.1}$$

donde (x_i, y_i) representa la posición real y $(\hat{x}_i, \hat{y}_i)$ la posición estimada.

Las métricas utilizadas para describir la exactitud son:

- ✔ la media, que indica la separación promedio entre las posiciones reales y estimadas;
- ✔ la mediana, que representa el error habitual y es menos sensible a valores extremos;
- ✔ el RMSE, que penaliza especialmente los errores elevados;
- ✔ el $P90$, que indica el error por debajo del cual se encuentra aproximadamente el 90 % de los puntos;
- ✔ el máximo, que permite identificar el peor caso observado.

En todos los casos, un valor menor representa un mejor comportamiento.

La gráfica de precisión utiliza el error tridimensional:

$$e_i^{XYZ} = \sqrt{(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 + (z_i - \hat{z}_i)^2}. \tag{12.2}$$

Como el escenario es plano y la coordenada Z permanece constante, los errores bidimensional y tridimensional presentan valores iguales o muy próximos. No obstante, en este capítulo las conclusiones principales se formulan a partir de la exactitud espacial.

12.2. Escenarios experimentales

La Tabla 11 resume las condiciones de los dos escenarios.

Cuadro 11: Escenarios utilizados en el análisis de resultados

Escenario	**Referencia o entrenamiento**	**Evaluación**	**Balizas**
Escenario 1	Puntos impares de la campaña del 16 de abril.	Puntos pares del 16 de abril.	Ocho.
Escenario 2	Puntos impares de los días 9, 10, 13, 16, 17, 20 y 22 de abril.	Puntos pares del 16 de abril.	Siete, tras eliminar la baliza 5.

El escenario 1 representa unas condiciones controladas. Todas las balizas funcionan correctamente y no existe variabilidad entre jornadas. La referencia y la evaluación se obtienen bajo unas condiciones temporales homogéneas, aunque ocupan posiciones físicas diferentes.

El escenario 2 representa una situación más exigente y más próxima al funcionamiento real. Las señales proceden de días diferentes, por lo que incorporan variaciones temporales, y se trabaja con una baliza menos. En un despliegue prolongado resulta razonable esperar cambios en el entorno radioeléctrico, diferencias entre campañas y posibles fallos de infraestructura.

El uso de los mismos puntos pares del 16 de abril permite comparar directamente los dos escenarios. Sin embargo, en el segundo cambian simultáneamente el número de jornadas y la cantidad de balizas. Por tanto, el efecto de ambos factores no puede aislarse.

Además, los puntos impares del 16 de abril forman parte de la referencia en ambos escenarios. El experimento evalúa generalización espacial hacia posiciones no utilizadas durante la calibración, pero no una generalización temporal completa hacia una jornada desconocida.

12.3. Resultados del escenario 1: condiciones controladas

En el primer escenario las ocho balizas están disponibles y todas las mediciones pertenecen al 16 de abril. Estas condiciones favorecen la estabilidad de las huellas y permiten analizar el rendimiento de cada método cuando la referencia y la evaluación se obtienen bajo circunstancias semejantes.

12.3.1. WKNN

El comportamiento de WKNN se analizó para las distancias euclídea, Manhattan y Chebyshev, utilizando valores de k comprendidos entre 1 y 5. La Figura 11 muestra las estimaciones obtenidas con distancia euclídea en el canal 37.



Ilustración 11: Gráfica de exactitud de WKNN con distancia euclídea en el canal 37 del escenario 1.

Cuadro 12: Exactitud de WKNN euclídeo en el canal 37 del escenario 1

k	**Media (m)**	**Mediana (m)**	**RMSE (m)**	**P90 (m)**	**Máximo (m)**
1	1,25	1,01	1,37	2,05	3,07
2	**1,06**	**1,00**	1,19	**1,62**	2,27
3	1,06	1,07	**1,18**	1,83	**1,99**
5	1,19	1,12	1,29	1,78	2,32

El valor $k = 1$ presenta una mayor sensibilidad a la huella más próxima y produce el máximo más alto. Al utilizar dos o tres vecinos, la estimación se estabiliza y disminuyen tanto la media como los errores extremos.

Con $k = 2$ se obtiene la menor media y el mejor $P90$, mientras que $k = 3$ reduce el máximo a 1,99 m. Esto demuestra que no existe una única configuración óptima para todas las métricas. Si se prioriza la exactitud media, $k = 2$ resulta la opción más adecuada; si se prioriza el peor caso, $k = 3$ ofrece una ligera ventaja.

La distribución espacial muestra que WKNN reproduce correctamente la estructura general de la rejilla, aunque varias predicciones se desplazan hacia posiciones intermedias. Este efecto es coherente con la media ponderada de las coordenadas de los vecinos.

En condiciones controladas, el método clásico obtiene resultados competitivos. La referencia procede de la misma jornada que la evaluación y las ocho balizas están disponibles, por lo que las diferencias entre huellas se mantienen suficientemente representativas.

12.3.2. Perceptrón multicapa

El perceptrón multicapa se evaluó de forma independiente en cada canal. Las Figuras 12 y 13 muestran los resultados espaciales de los canales 37 y 38.



Ilustración 12: Gráfica de exactitud del perceptrón multicapa en el canal 37 del escenario 1.



Ilustración 13: Gráfica de exactitud del perceptrón multicapa en el canal 38 del escenario 1.

La Tabla 13 resume los valores verificados en las capturas de exactitud.

Cuadro 13: Exactitud del perceptrón multicapa en el escenario 1

Canal	Media (m)	Mediana (m)	RMSE (m)	P90 (m)	Máximo (m)
37	1,22	1,35	1,35	1,89	2,58
38	1,15	1,16	1,31	2,08	**2,49**

El canal 38 mejora la media y la mediana respecto al canal 37, aunque presenta un $P90$ algo superior. Esto indica que la mayoría de sus predicciones se aproxima más a la posición real, pero existe una cola ligeramente más amplia.

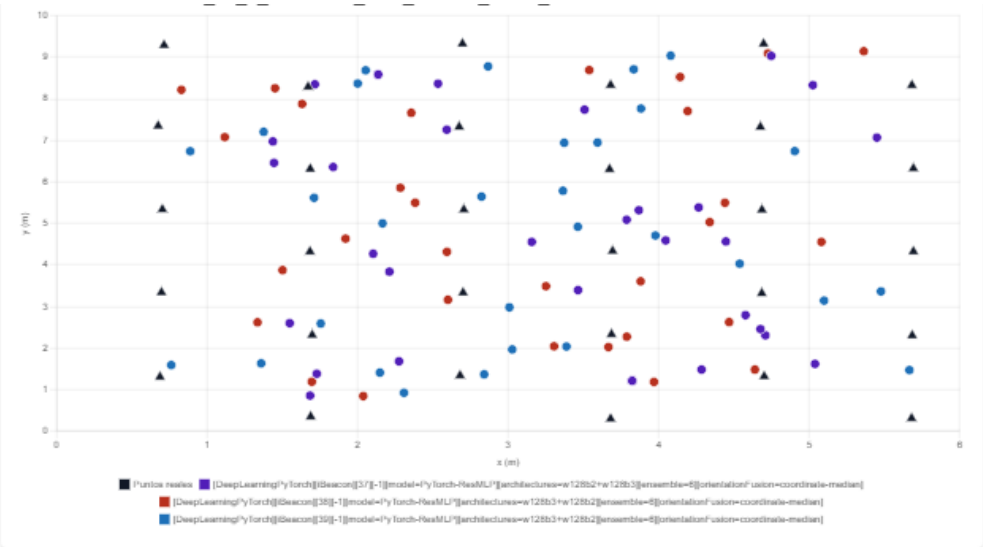
Las predicciones siguen la forma general de la rejilla, pero muestran una contracción apreciable hacia el interior. Las posiciones periféricas tienden a desplazarse hacia zonas con mayor densidad de puntos de entrenamiento. Este comportamiento es frecuente en problemas de regresión cuando el modelo aprende una solución suavizada.

La captura de exactitud correspondiente al canal 39 aparece duplicada o mal etiquetada, ya que repite los valores del canal 38. Por este motivo no se utiliza como fuente principal de exactitud. No obstante, la gráfica de precisión del canal 39 presenta una media tridimensional de 0,98 m, una mediana de 0,90 m y un $P90$ de 1,56 m. Debido a que el entorno es plano, estos valores sugieren que el canal 39 es el más favorable, aunque la captura de exactitud debería regenerarse para confirmarlo visualmente.

En conjunto, el perceptrón multicapa alcanza una exactitud semejante a la de WKNN. La ventaja depende del canal y no se observa una superioridad uniforme en todas las métricas.

12.3.3. Red residual

La red residual se evaluó en los tres canales. La Figura 14 permite comparar simultáneamente las tres distribuciones espaciales.



Error de posicionamiento en planta

Distancia euclídea entre cada punto real y el estimado. La media es la magnitud comparable con la exactitud indicada en el Excel.

Serie	Exactitud media	Mediana	RMSE	P90	Máximo	N
[DeepLearningPyTorch][iBeacon][37][-1][model=PyTorch-ResMLP][architectures=w128b2+w128b3][ensemble=6][orientationFusion=coordinate-median]	**1.1569 m**	1.09 m	1.31 m	2.04 m	2.58 m	30
[DeepLearningPyTorch][iBeacon][38][-1][model=PyTorch-ResMLP][architectures=w128b3+w128b2][ensemble=6][orientationFusion=coordinate-median]	**1.3196 m**	1.22 m	1.46 m	2.09 m	2.94 m	30
[DeepLearningPyTorch][iBeacon][39][-1][model=PyTorch-ResMLP][architectures=w128b3+w128b2][ensemble=6][orientationFusion=coordinate-median]	**1.0874 m**	0.94 m	1.18 m	1.63 m	2.31 m	30

Ilustración 14: Gráficas de exactitud de la red residual en los canales 37, 38 y 39 del escenario 1.

Cuadro 14: Exactitud de la red residual en el escenario 1

Canal	Media (m)	Mediana (m)	RMSE (m)	P90 (m)	Máximo (m)
37	1,16	1,09	1,31	2,04	2,58
38	1,32	1,22	1,46	2,09	2,94
39	**1,09**	**0,94**	**1,18**	**1,63**	**2,31**

El canal 39 ofrece el mejor comportamiento en todas las métricas. La media de 1,09 m es similar a la de WKNN con $k = 2$, mientras que la mediana y el $P90$ son ligeramente mejores.

El canal 38 es el menos favorable, con una media de 1,32 m y un máximo de 2,94 m. Esta diferencia confirma que, incluso en una misma jornada, la información proporcionada por cada canal no es equivalente.

La red residual no supera de forma clara al resto de los métodos en el escenario ideal. Su arquitectura más compleja no produce una ventaja automática cuando los datos son homogéneos y el número de posiciones de entrenamiento es limitado.

12.3.4. Método híbrido

El método híbrido combina los canales 37, 38 y 39 y utiliza las dos ramas descritas en el capítulo anterior. La Figura 15 muestra su distribución espacial.

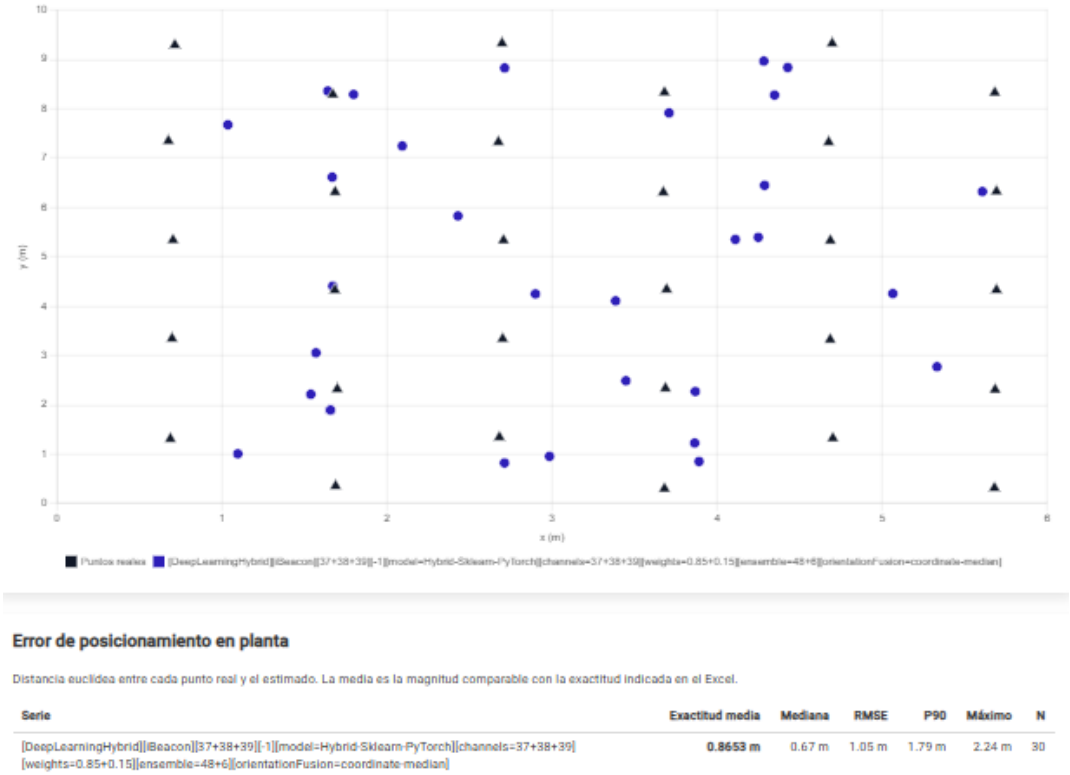


Ilustración 15: Gráfica de exactitud del método híbrido en el escenario 1.

Cuadro 15: Exactitud del método híbrido en el escenario 1

Media (m)	**Mediana (m)**	**RMSE (m)**	**P90 (m)**	**Máximo (m)**	N
0,8653	**0,67**	**1,05**	1,79	**2,24**	30

El híbrido obtiene la mejor media y la mejor mediana del escenario. La proximidad entre la media y el RMSE indica que la mayoría de los errores se mantiene en un intervalo reducido, aunque existen algunos puntos que elevan moderadamente el valor cuadrático.

Su $P90$ no es el menor entre todas las configuraciones analizadas. El perceptrón multicapa del canal 39 presenta un mejor valor tridimensional. Por tanto, el híbrido ofrece el mejor comportamiento general, pero no domina necesariamente cada indicador.

La gráfica muestra una buena reproducción de la rejilla y una menor dispersión global. La combinación de canales parece reducir la dependencia de un canal concreto y compensensar parte de sus variaciones.

12.3.5. Síntesis del escenario 1

La Tabla 16 compara configuraciones representativas de cada método.

Cuadro 16: Comparación representativa en el escenario 1

Método y configuración	**Media (m)**	**Mediana (m)**	**P90 (m)**	**Máximo (m)**
WKNN, euclídea, canal 37, $k = 2$	1,06	1,00	1,62	2,27
Perceptrón multicapa, canal 39[1]	0,98	0,90	**1,56**	2,39
Red residual, canal 39	1,09	0,94	1,63	2,31
Método híbrido	**0,87**	**0,67**	1,79	**2,24**

El resultado principal es que WKNN continúa siendo competitivo en el escenario controlado. El híbrido mejora la media y la mediana, pero la diferencia no es suficientemente amplia como para afirmar que todos los modelos neuronales superen siempre al método clásico.

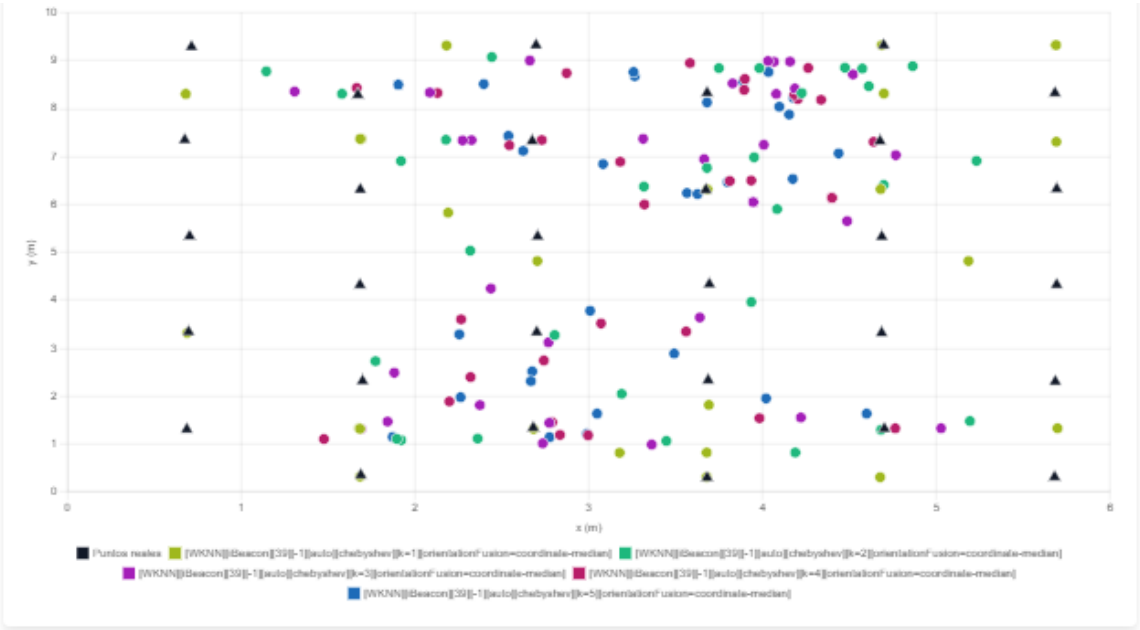
Estas condiciones favorecen especialmente a WKNN: la referencia y la evaluación pertenecen a la misma jornada, las ocho balizas están operativas y las huellas se construyen con mediciones temporalmente homogéneas.

12.4. Resultados del escenario 2: condiciones más realistas

El segundo escenario combina siete jornadas y elimina la baliza 5. Las señales de referencia presentan una mayor diversidad temporal y los métodos disponen de una fuente de información menos.

12.4.1. WKNN

La Figura 16 muestra las configuraciones de WKNN con distancia Chebyshev en el canal 39.



Error de posicionamiento en planta

Distancia euclídea entre cada punto real y el estimado. La media es la magnitud comparable con la exactitud indicada en el Excel.

Serie	Exactitud media	Mediana	RMSE	P90	Máximo	N
[WKNN][iBeacon][39][-1][auto][chebyshev][k=1][orientationFusion=coordinate-median]	**1.7224 m**	1.02 m	2.24 m	3.16 m	6.38 m	30
[WKNN][iBeacon][39][-1][auto][chebyshev][k=2][orientationFusion=coordinate-median]	**1.5517 m**	1.23 m	1.86 m	3.09 m	4.15 m	30
[WKNN][iBeacon][39][-1][auto][chebyshev][k=3][orientationFusion=coordinate-median]	**1.5526 m**	1.38 m	1.81 m	2.92 m	3.84 m	30
[WKNN][iBeacon][39][-1][auto][chebyshev][k=4][orientationFusion=coordinate-median]	**1.5235 m**	1.43 m	1.77 m	2.90 m	3.28 m	30
[WKNN][iBeacon][39][-1][auto][chebyshev][k=5][orientationFusion=coordinate-median]	**1.5293 m**	1.47 m	1.77 m	2.86 m	3.25 m	30

Ilustración 16: Gráfica de exactitud de WKNN con distancia Chebyshev en el canal 39 del escenario 2.

Cuadro 17: Exactitud de WKNN Chebyshev en el canal 39 del escenario 2

k	**Media (m)**	**Mediana (m)**	**RMSE (m)**	**P90 (m)**	**Máximo (m)**
1	1,72	**1,02**	2,24	3,16	6,38
2	1,55	1,23	1,86	3,09	4,15
3	1,55	1,38	1,81	2,92	3,84
4	**1,52**	1,43	1,77	2,90	3,28
5	1,53	1,47	**1,77**	**2,86**	**3,25**

El valor $k = 1$ produce un máximo de 6,38 m, lo que evidencia una elevada sensibilidad a la huella seleccionada. Al aumentar k, disminuyen el RMSE, el $P90$ y el máximo.

La media más baja se obtiene con $k = 4$, mientras que $k = 5$ reduce ligeramente el $P90$ y el máximo. En ambos casos, los errores son claramente superiores a los del escenario 1.

La gráfica muestra una mayor dispersión de las posiciones estimadas y varias predicciones desplazadas hacia el interior. El deterioro no se limita a uno o dos puntos, sino que afecta al conjunto de la distribución.

La explicación principal se encuentra en la construcción de la referencia. WKNN combina todas las jornadas y conserva una única huella por posición. Los máximos correspondientes a distintas balizas y orientaciones pueden proceder de días diferentes, dando lugar a una huella que no representa ninguna captura real.

Además, eliminar la baliza 5 reduce la dimensión del vector de señal. Con una característica menos, algunas posiciones pueden resultar más difíciles de diferenciar.

12.4.2. Perceptrón multicapa

Las Figuras 17, 18 y 19 muestran los resultados del perceptrón multicapa.



Ilustración 17: Gráfica de exactitud del perceptrón multicapa en el canal 37 del escenario 2.



Error de posicionamiento en planta

Distancia euclídea entre cada punto real y el estimado. La media es la magnitud comparable con la exactitud indicada en el Excel.

Serie	Exactitud media	Mediana	RMSE	P90	Máximo	N
[DeepLearning][iBeacon][38][-1][layers=256x128x64+128x64][ensemble=6]	**1.3173 m**	1.21 m	1.43 m	2.13 m	2.68 m	30
[DeepLearning][iBeacon][38][-1][layers=128x128x64+256x128x64][ensemble=6][orientationFusion=coordinate-median]	**1.0996 m**	1.01 m	1.25 m	1.74 m	2.82 m	30

Ilustración 18: Gráfica de exactitud del perceptrón multicapa en el canal 38 del escenario 2.



Ilustración 19: Gráfica de exactitud del perceptrón multicapa en el canal 39 del escenario 2.

Cuadro 18: Exactitud del perceptrón multicapa en el escenario 2

Canal	Media (m)	Mediana (m)	RMSE (m)	P90 (m)	Máximo (m)
37	1,11	1,14	1,23	**1,58**	2,85
38	**1,10**	**1,01**	1,25	1,74	2,82
39	1,10	1,03	**1,21**	1,75	**2,49**

Las medias se concentran entre 1,10 y 1,11 m. Esta uniformidad entre canales contrasta con el escenario 1 y sugiere que el entrenamiento multijornada reduce la dependencia de una frecuencia concreta.

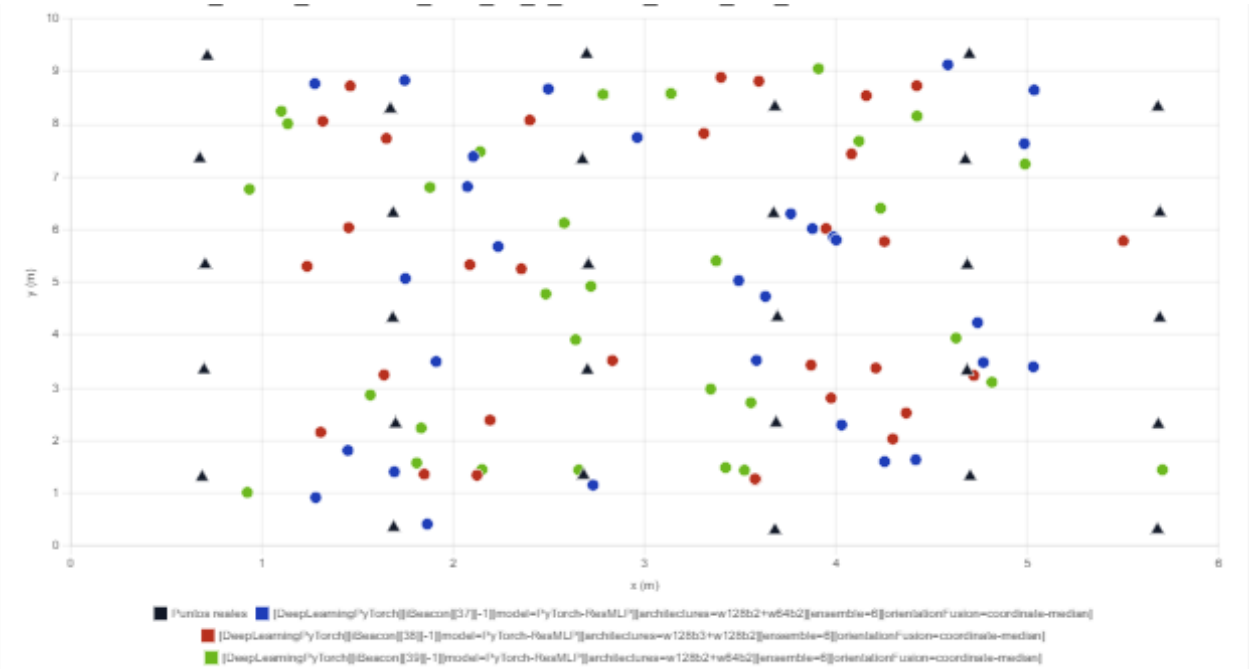
El canal 37 presenta el mejor $P90$, el canal 38 la mejor mediana y el canal 39 el menor máximo y el menor RMSE. Ningún canal domina todas las métricas.

Las gráficas muestran una distribución coherente con la rejilla. Aunque existen desplazamientos en algunos puntos periféricos, la dispersión es inferior a la observada en WKNN. El modelo conserva una exactitud estable a pesar de trabajar con una baliza menos.

La razón es que las capturas de cada jornada permanecen como ejemplos independientes. La variabilidad temporal no se elimina, sino que forma parte del conjunto de entrenamiento.

12.4.3. Red residual

La Figura 20 representa las tres configuraciones por canal.



Error de posicionamiento en planta

Distancia euclídea entre cada punto real y el estimado. La media es la magnitud comparable con la exactitud indicada en el Excel.

Serie	Exactitud media	Mediana	RMSE	P90	Máximo	N
[DeepLearningPyTorch][iBeacon][37][-1][model=PyTorch-ResMLP][architectures=w128b2+w64b2][ensemble=6][orientationFusion=coordinate-median]	**1.1435 m**	1.13 m	1.25 m	1.65 m	2.80 m	30
[DeepLearningPyTorch][iBeacon][38][-1][model=PyTorch-ResMLP][architectures=w128b3+w128b2][ensemble=6][orientationFusion=coordinate-median]	**1.1411 m**	1.12 m	1.27 m	1.89 m	2.53 m	30
[DeepLearningPyTorch][iBeacon][39][-1][model=PyTorch-ResMLP][architectures=w128b2+w64b2][ensemble=6][orientationFusion=coordinate-median]	**1.0709 m**	0.92 m	1.20 m	1.67 m	2.56 m	30

Ilustración 20: Gráficas de exactitud de la red residual en los canales 37, 38 y 39 del escenario 2.

Cuadro 19: Exactitud de la red residual en el escenario 2

Canal	Media (m)	Mediana (m)	RMSE (m)	P90 (m)	Máximo (m)
37	1,14	1,13	1,25	**1,65**	2,80
38	1,14	1,12	1,27	1,89	**2,53**
39	**1,07**	**0,92**	**1,20**	1,67	2,56

El canal 39 vuelve a ser el más favorable en media, mediana y RMSE. El canal 37 obtiene un $P90$ ligeramente menor, mientras que el canal 38 reduce el máximo.

La red residual mantiene prácticamente la misma exactitud media que en el escenario controlado. Este resultado es relevante porque indica que la variabilidad entre jornadas y la pérdida de una baliza no producen un deterioro general.

La arquitectura residual, la pérdida robusta y la penalización de errores altos pueden contribuir a esta estabilidad. Sin embargo, los resultados no permiten atribuir la mejora a un componente concreto de forma aislada.

12.4.4. Método híbrido

La Figura 21 muestra la distribución espacial obtenida por el método híbrido.

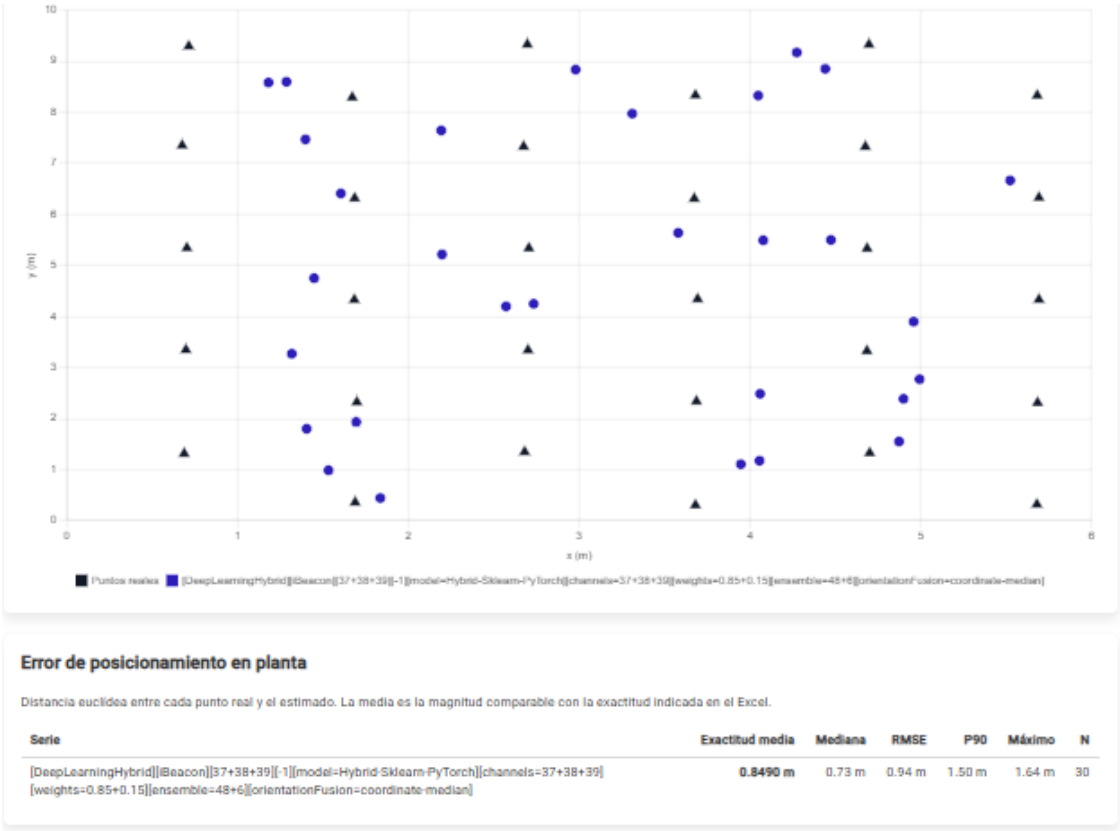


Ilustración 21: Gráfica de exactitud del método híbrido en el escenario 2.

Cuadro 20: Exactitud del método híbrido en el escenario 2

Media (m)	**Mediana (m)**	**RMSE (m)**	**P90 (m)**	**Máximo (m)**	N
0,8490	**0,73**	**0,94**	**1,50**	**1,64**	30

El híbrido obtiene el mejor resultado en todas las métricas. La exactitud media es inferior a un metro y el máximo se mantiene en 1,64 m.

La diferencia entre el RMSE y la media es reducida, lo que indica que los errores altos están controlados. La gráfica espacial confirma que las posiciones estimadas siguen de forma consistente la estructura de la rejilla.

La combinación de los tres canales proporciona redundancia frente a la variación de una frecuencia concreta. Además, la rama auxiliar monocanal puede corregir parcialmente las estimaciones de la rama principal.

El resultado debe interpretarse con cuidado porque el híbrido recibe más información de entrada que los métodos monocanal. Su ventaja puede proceder tanto de la arquitectura como de la disponibilidad simultánea de los canales 37, 38 y 39.

12.4.5. Síntesis del escenario 2

Cuadro 21: Comparación representativa en el escenario 2

Método y configuración	**Media (m)**	**Mediana (m)**	**P90 (m)**	**Máximo (m)**
WKNN, Chebyshev, canal 39, $k = 4$	1,52	1,43	2,90	3,28
Perceptrón multicapa, canal 39	1,10	1,03	1,75	2,49
Red residual, canal 39	1,07	0,92	1,67	2,56
Método híbrido	**0,85**	**0,73**	**1,50**	**1,64**

En este escenario, los tres modelos neuronales superan claramente a WKNN. Frente al método clásico, el híbrido reduce aproximadamente un 44,1 % la media, un 49 % la mediana, un 48,3 % el $P90$ y un 50 % el máximo.

La conclusión es más contundente que en el escenario 1. Cuando las señales proceden de jornadas diferentes y se pierde una baliza, conservar las capturas individuales permite a los modelos neuronales adaptarse mejor que una referencia formada por máximos globales.

12.5. Evolución de cada método entre escenarios

12.5.1. Evolución de WKNN

La exactitud media de la configuración representativa de WKNN pasa de 1,06 m en el escenario controlado a 1,52 m en el escenario multijornada. Esto supone un aumento aproximado del 43,4 %.

El $P90$ pasa de 1,62 a 2,90 m, mientras que el máximo aumenta de 2,27 a 3,28 m.

Este deterioro indica que WKNN depende en mayor medida de la homogeneidad entre referencia y evaluación. Cuando la referencia combina jornadas, la única huella almacenada por punto deja de representar adecuadamente todas las condiciones posibles.

12.5.2. Evolución del perceptrón multicapa

El perceptrón multicapa mantiene errores próximos a un metro. Tomando el canal 39 como referencia, la media pasa de 0,98 a 1,10 m, un aumento aproximado del 12,2 %.

El deterioro es moderado y el método continúa siendo claramente superior a WKNN en el escenario 2. La diversidad de capturas de entrenamiento permite conservar la relación entre patrones de señal y posición.

12.5.3. Evolución de la red residual

La red residual presenta una gran estabilidad. La media del canal 39 pasa de 1,09 a 1,07 m y la mediana de 0,94 a 0,92 m.

El máximo aumenta ligeramente, pero el comportamiento global se mantiene. Esto sugiere que la red es capaz de aprovechar la diversidad temporal sin perder exactitud.

12.5.4. Evolución del método híbrido

El híbrido mantiene la mejor exactitud en los dos escenarios. La media pasa de 0,8653 a 0,8490 m, mientras que el máximo se reduce de 2,24 a 1,64 m.

La mejora de la cola de errores es especialmente significativa. El método no solo mantiene la media, sino que reduce el peor caso cuando las condiciones son más variables.

Este resultado respalda la utilidad de la fusión multicanal. La combinación de varias fuentes de información permite compensar parte de la pérdida provocada por la eliminación de la baliza 5.

12.6. Análisis complementario de precisión

La precisión se utiliza para comprobar la distribución de los errores tridimensionales. Las Figuras 22 y 23 muestran las curvas CDF del método híbrido.

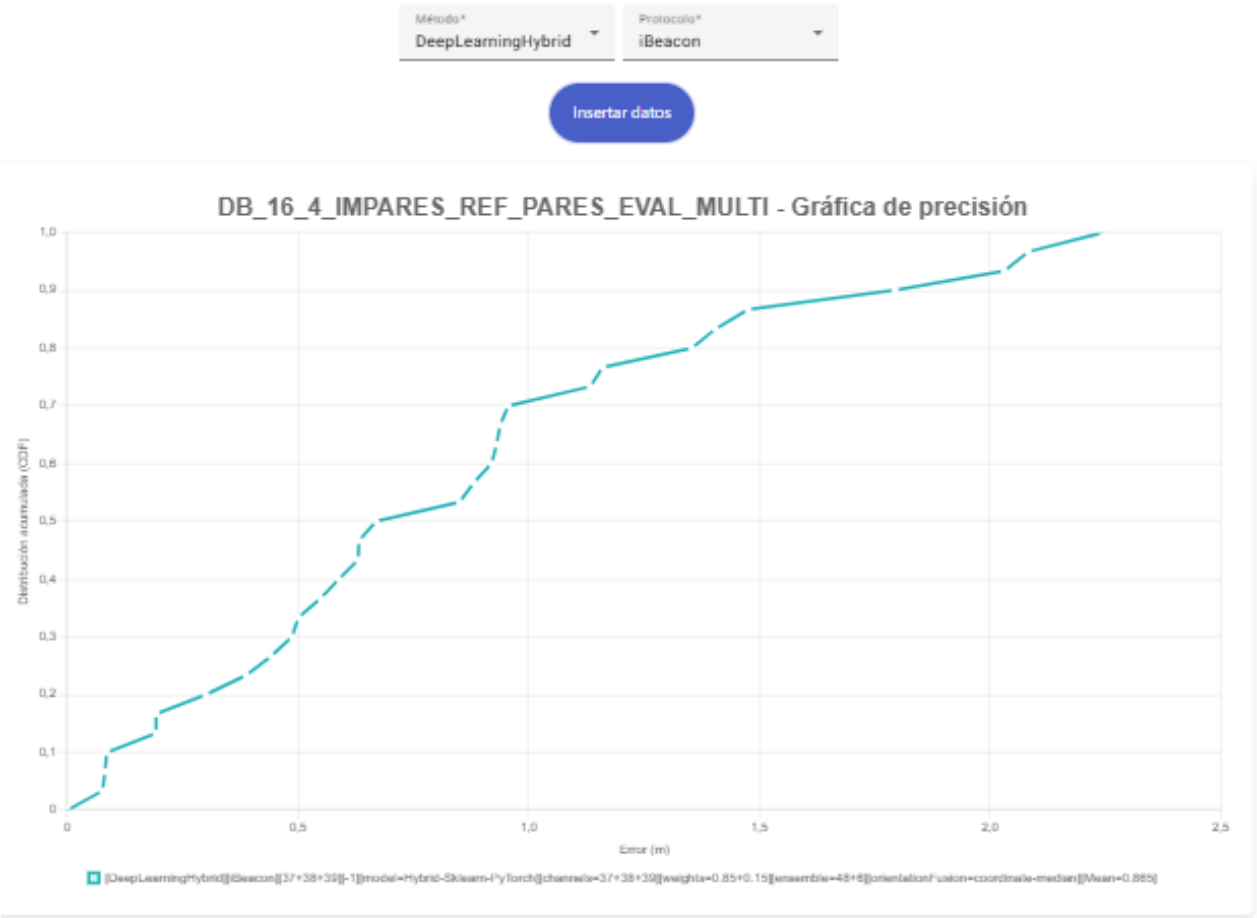


Ilustración 22: Gráfica de precisión del método híbrido en el escenario 1.

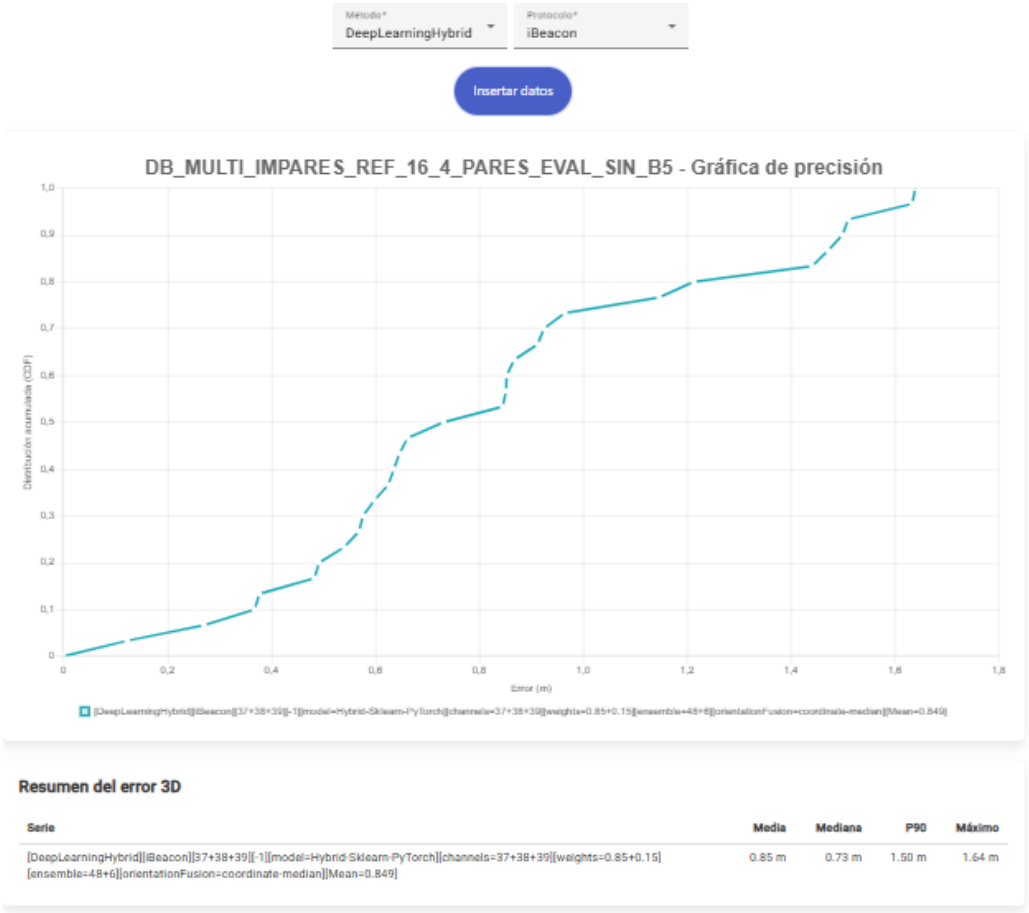


Ilustración 23: Gráfica de precisión del método híbrido en el escenario 2.

La curva del escenario 2 alcanza valores acumulados elevados con umbrales menores, lo que confirma la reducción del $P90$ y del máximo.

Estas gráficas respaldan el análisis de exactitud, pero no constituyen el criterio principal del capítulo. Su función es comprobar si una media baja se corresponde con un comportamiento generalizado o depende de unos pocos puntos favorables.

12.7. Análisis espacial conjunto

Las gráficas de exactitud muestran varios patrones comunes.

En primer lugar, diferentes métodos tienden a desplazar algunas posiciones periféricas hacia el interior. Este fenómeno es especialmente visible en configuraciones de WKNN con varios vecinos y en algunos modelos neuronales.

En segundo lugar, los canales no presentan la misma capacidad de localización. El canal 39 resulta especialmente favorable para los modelos neuronales, mientras que los resultados de WKNN dependen más de la combinación entre canal, métrica y valor de k.

En tercer lugar, el método híbrido produce las distribuciones más compactas. Aunque no elimina todos los desplazamientos, reduce la separación global entre los puntos reales y estimados y controla mejor los errores extremos.

No es posible atribuir un error concreto a una baliza determinada únicamente a partir de estas figuras. Para ello sería necesario disponer de un análisis por punto, por jornada y por baliza.

12.8. Síntesis final

En el escenario 1, próximo a unas condiciones ideales, WKNN sigue siendo competitivo. La distancia euclídea en el canal 37 con $k = 2$ alcanza una exactitud media de 1,06 m, próxima a la obtenida por los modelos neuronales.

El perceptrón multicapa puede mejorar determinados indicadores, especialmente en el canal 39, y el método híbrido obtiene la mejor media y mediana. Sin embargo, la ventaja de los modelos neuronales no es uniforme en todas las métricas.

En el escenario 2, más próximo a una aplicación real, la diferencia aumenta. Los tres modelos neuronales superan claramente a WKNN. El método híbrido alcanza una media de 0,85 m, un $P90$ de 1,50 m y un máximo de 1,64 m.

La evolución de cada método es el resultado más relevante. WKNN empeora aproximadamente un 43 % en media, mientras que la red residual y el método híbrido mantienen prácticamente la misma exactitud.

Por tanto, el principal valor de los modelos neuronales no consiste únicamente en obtener una media menor en condiciones controladas. Su aportación fundamental es mantener un comportamiento estable cuando las señales cambian entre jornadas y se pierde una baliza.

La precisión representada mediante las curvas CDF confirma estas conclusiones, pero el análisis principal se basa en la exactitud espacial y en la separación real entre los puntos evaluados y sus posiciones estimadas.

Capítulo 13

Conclusiones y trabajo futuro

En este capítulo se presentan las conclusiones generales del Trabajo de Fin de Grado, se revisa el grado de cumplimiento de los objetivos planteados, se exponen las principales aportaciones realizadas y se analizan las limitaciones que condicionan el alcance de los resultados. Finalmente, se proponen líneas de trabajo futuro orientadas tanto a mejorar la adquisición y el tratamiento de los datos como a ampliar la evaluación de los métodos de posicionamiento.

13.1. Conclusiones generales

El presente Trabajo de Fin de Grado confirma que el posicionamiento en interiores mediante señales BLE y valores de RSSI constituye un problema en el que el tratamiento de los datos resulta tan importante como el algoritmo utilizado. Las señales inalámbricas presentan variaciones debidas a reflexiones, multitrayecto, obstáculos, orientación del receptor, interferencias y cambios temporales del entorno. Como consecuencia, una misma posición no siempre produce un único patrón de señal estable.

El enfoque basado en fingerprinting permite abordar esta complejidad sin construir un modelo físico explícito de propagación. En lugar de estimar distancias a partir de una ecuación teórica, se utilizan huellas de señal adquiridas en el propio entorno para relacionar patrones de RSSI con posiciones conocidas. Los resultados obtenidos demuestran que esta estrategia puede alcanzar errores inferiores a un metro en determinadas configuraciones, aunque su rendimiento depende de la estabilidad de las campañas y de la forma en que se representa la variabilidad de las señales.

Una primera conclusión es que la construcción de los conjuntos de referencia, entrenamiento y evaluación condiciona de forma directa la interpretación de los resultados. La separación entre puntos impares y pares evita que una misma coordenada aparezca simultáneamente en referencia y evaluación, por lo que los experimentos estudian la capacidad de generalización espacial hacia posiciones no utilizadas durante la calibración.

No obstante, los puntos impares del 16 de abril forman parte del entrenamiento en los dos escenarios y los puntos pares de esa misma jornada se utilizan para evaluar. Por tanto, el experimento no representa una generalización temporal completa hacia un día desconocido. Esta distinción resulta especialmente importante al interpretar el segundo escenario: la referencia contiene varias jornadas, pero la evaluación sigue perteneciendo a una jornada parcialmente presente en el entrenamiento mediante otras posiciones.

Otra conclusión relevante es que la evaluación debe apoyarse en varias métricas. La exactitud media permite resumir la separación promedio entre las posiciones reales y estimadas, pero no describe por sí sola la presencia de errores elevados. La mediana representa mejor el comportamiento habitual, el RMSE penaliza los errores grandes, el $P90$ permite valorar la fiabilidad para la mayoría de los puntos y el máximo identifica el peor caso observado.

En este trabajo, las conclusiones principales se han formulado a partir de la exactitud en planta. Las curvas de precisión, construidas mediante la CDF del error tridimensional, se han utilizado como evidencia complementaria para comprobar si las mejoras se extienden al conjunto de los puntos o dependen únicamente de algunas estimaciones favorables.

13.1.1. Conclusiones sobre el escenario controlado

El escenario 1 representa unas condiciones favorables para el posicionamiento. Todas las balizas se encuentran operativas y las mediciones de referencia y evaluación pertenecen al 16 de abril. La ausencia de variabilidad entre jornadas hace que los patrones de señal utilizados para construir la referencia sean temporalmente homogéneos respecto a las muestras de evaluación.

En estas condiciones, WKNN continúa siendo una alternativa competitiva. La configuración con distancia euclídea, canal 37 y $k = 2$ obtiene una exactitud media de 1,06 m, una mediana de 1,00 m, un $P90$ de 1,62 m y un máximo de 2,27 m.

Estos resultados muestran que, cuando el mapa de huellas y la evaluación se adquieren bajo condiciones semejantes, un método clásico basado en vecinos puede representar correctamente la estructura espacial del escenario. Su sencillez no impide alcanzar valores próximos a los obtenidos por modelos neuronales de mayor complejidad.

El perceptrón multicapa mejora algunos indicadores. En el canal 39 alcanza una media de 0,98 m, una mediana de 0,90 m y un $P90$ de 1,56 m. Este último valor es el mejor entre las configuraciones representativas del escenario. Sin embargo, la ventaja no se mantiene de forma uniforme en todos los canales ni en todas las métricas.

La red residual obtiene en el canal 39 una media de 1,09 m, una mediana de 0,94 m y un $P90$ de 1,63 m. Su comportamiento es prácticamente equivalente al de WKNN. Por tanto, en el escenario controlado la arquitectura residual no proporciona una mejora clara que justifique por sí sola su mayor complejidad.

El método híbrido obtiene la menor media y la menor mediana, con 0,87 m y 0,67 m, respectivamente. También presenta el menor máximo entre las configuraciones representativas, con 2,24 m. Frente a WKNN, reduce la media aproximadamente un 17,9 % y la mediana un 33 %.

No obstante, el híbrido no obtiene el mejor $P90$, que corresponde al perceptrón multicapa del canal 39. Esto demuestra que una configuración puede ser superior en el comportamiento promedio y no dominar necesariamente la cola de la distribución.

La conclusión del primer escenario es, por tanto, matizada. Los modelos neuronales pueden mejorar la exactitud media y el error habitual, pero WKNN continúa siendo competitivo cuando las mediciones son estables, todas las balizas funcionan y la referencia y la evaluación pertenecen a la misma jornada. En estas condiciones no puede afirmarse que una mayor complejidad algorítmica garantice mejores resultados en todas las métricas.

13.1.2. Conclusiones sobre el escenario multijornada

El escenario 2 introduce dos modificaciones simultáneas. Por una parte, la referencia incorpora los días 9, 10, 13, 16, 17, 20 y 22 de abril, por lo que contiene variaciones temporales del RSSI. Por otra, se elimina completamente la baliza 5 debido a su funcionamiento anómalo. El escenario representa así una situación más próxima a un sistema utilizado durante un periodo prolongado, donde las señales pueden cambiar y parte de la infraestructura puede dejar de estar disponible.

En estas condiciones, WKNN pierde competitividad. La configuración representativa con distancia Chebyshev, canal 39 y $k = 4$ alcanza una media de 1,52 m, una mediana de 1,43 m, un $P90$ de 2,90 m y un máximo de 3,28 m.

El deterioro está relacionado con la forma en que se construye la referencia multijornada. Aunque se recuperan todas las lecturas disponibles, WKNN no conserva cada captura o cada jornada como una huella independiente. Para cada punto, baliza y orientación se seleccionan máximos globales y posteriormente se genera una única huella por posición.

Esta operación comprime la variabilidad temporal. Una misma huella puede combinar valores de distintas balizas procedentes de días diferentes y no tiene por qué corresponder a una captura real. Además, la selección de máximos desplaza la representación hacia señales especialmente fuertes. Como consecuencia, añadir jornadas no incrementa el número de ejemplos independientes disponibles para la búsqueda de vecinos.

El perceptrón multicapa mantiene un comportamiento más estable. En el canal 39 obtiene una media de 1,10 m, una mediana de 1,03 m, un $P90$ de 1,75 m y un máximo de 2,49 m. Los resultados de los canales 37, 38 y 39 son además muy próximos, lo que indica una menor dependencia de un canal concreto.

La red residual alcanza en el canal 39 una media de 1,07 m, una mediana de 0,92 m y un $P90$ de 1,67 m. Su exactitud se mantiene prácticamente igual a la obtenida en el escenario controlado. Este resultado sugiere que la representación de las capturas individuales permite aprovechar la diversidad temporal sin perder la relación espacial entre las señales y las coordenadas.

El método híbrido obtiene el mejor resultado en todas las métricas del segundo escenario. Su media es de 0,85 m, la mediana de 0,73 m, el $P90$ de 1,50 m y el máximo de 1,64 m.

Frente a la configuración representativa de WKNN, el híbrido reduce aproximadamente un 44,1 % la media, un 49 % la mediana, un 48,3 % el $P90$ y un 50 % el máximo. En este escenario, la superioridad de los métodos neuronales resulta mucho más clara que en el escenario controlado.

La explicación no se limita a la arquitectura. Los modelos neuronales conservan las capturas de jornadas diferentes como ejemplos independientes, por lo que el aumento de días incrementa realmente la cantidad y diversidad del conjunto de entrenamiento. El método híbrido añade además la información conjunta de los canales 37, 38 y 39, proporcionando redundancia frente a variaciones de una frecuencia concreta y frente a la pérdida de una baliza.

La conclusión del segundo escenario es que los modelos basados en aprendizaje presentan una mayor robustez ante condiciones de adquisición variables. Su principal aportación no consiste únicamente en obtener una media inferior, sino en mantener una exactitud estable cuando el sistema deja de funcionar bajo condiciones ideales.

13.1.3. Comparación de estabilidad entre escenarios

La comparación entre escenarios proporciona una de las conclusiones más importantes del trabajo. La exactitud media de la configuración representativa de WKNN pasa de 1,06 a 1,52 m, lo que supone un incremento aproximado del 43,4 %.

El perceptrón multicapa pasa de 0,98 a 1,10 m, con un deterioro aproximado del 12,2 %. A pesar de esta variación, continúa siendo claramente superior a WKNN en el escenario multijornada.

La red residual mantiene prácticamente la misma media, pasando de 1,09 a 1,07 m. El método híbrido también permanece estable y mejora ligeramente de 0,87 a 0,85 m. Además, su máximo disminuye de 2,24 a 1,64 m.

Estos resultados muestran que la estabilidad ante cambios en las condiciones de adquisición constituye una diferencia más importante que la mejora obtenida en el escenario ideal. Un método puede alcanzar una buena exactitud en una jornada concreta y, sin embargo, perder rendimiento cuando las señales varían. Los modelos neuronales, especialmente la red residual y el método híbrido, mantienen una mayor consistencia entre escenarios.

Debe tenerse en cuenta que la diferencia entre escenarios no puede atribuirse exclusivamente a la ausencia de la baliza 5. El segundo escenario también incorpora más jornadas de entrenamiento. Por tanto, los resultados reflejan el efecto conjunto de una mayor variabilidad temporal y una reducción de la información disponible.

13.2. Principales aportaciones

El trabajo realizado aporta mejoras en distintas etapas del flujo de posicionamiento.

La primera aportación es la definición de un tratamiento de datos capaz de trabajar con campañas de una o varias jornadas. Se han alineado las balizas, normalizado las coordenadas, tratado las ausencias de señal y separado los conjuntos de referencia, entrenamiento y evaluación sin solapamiento espacial.

La segunda aportación es la adaptación de los datos a dos familias de métodos. WKNN utiliza huellas formadas por valores absolutos de RSSI, mientras que los modelos neuronales emplean una representación enriquecida con valores absolutos, valores relativos y máscara de ausencias. Esta distinción permite que cada algoritmo reciba una estructura coherente con su forma de aprendizaje.

La tercera aportación es la ampliación de IPSCampaign mediante modelos neuronales. Se ha integrado un perceptrón multicapa, una red residual y un método híbrido multicanal. Estas alternativas permiten comparar dentro de una misma herramienta un método clásico basado en vecinos con modelos capaces de aprender relaciones no lineales.

La cuarta aportación es el desarrollo del método híbrido. La combinación de una rama residual multicanal y una rama auxiliar monocanal obtiene los mejores resultados globales, especialmente en el escenario más exigente. Su comportamiento demuestra el interés de combinar información procedente de varios canales publicitarios.

La quinta aportación es la ampliación del análisis de resultados. La herramienta permite estudiar la media, la mediana, el RMSE, el $P90$, el máximo, la nube espacial de posiciones y la CDF de los errores. Esto evita reducir la comparación a un único valor promedio.

Finalmente, el trabajo aporta una comparación entre un escenario controlado y otro con variabilidad temporal y pérdida de una baliza. Esta comparación permite analizar la robustez de los métodos, aspecto que no puede evaluarse mediante una única campaña homogénea.

13.3. Grado de cumplimiento de los objetivos

El objetivo general consistía en estudiar e integrar técnicas de ML y DL aplicadas al posicionamiento en interiores mediante fingerprinting de señales BLE. Este objetivo se considera cumplido, ya que se ha desarrollado un flujo completo desde la adquisición y transformación de los datos hasta la comparación experimental de diferentes métodos.

La Tabla 22 resume el grado de cumplimiento de los objetivos específicos.

Cuadro 22: Grado de cumplimiento de los objetivos

Objetivo	**Resultado alcanzado**
Estudiar el posicionamiento en interiores mediante señales BLE.	Se han analizado los fundamentos de los sistemas IPS, la variabilidad del RSSI y el uso de fingerprinting.
Procesar campañas reales adquiridas con ROBOMAP.	Se han transformado las bases SQLite, alineado las balizas, tratado las ausencias y normalizado las coordenadas.
Definir conjuntos de referencia, entrenamiento y evaluación.	Se han construido dos escenarios con separación espacial entre puntos impares y pares y sin solapamiento de coordenadas.
Analizar e integrar WKNN.	Se ha documentado y evaluado el método para distintas métricas, canales y valores de k.
Implementar métodos basados en aprendizaje.	Se han integrado un perceptrón multicapa, una red residual y un método híbrido multicanal.
Ampliar las métricas y representaciones de evaluación.	Se han utilizado exactitud media, mediana, RMSE, $P90$, máximo, gráficas espaciales y curvas CDF.
Comparar métodos en condiciones diferentes.	Se ha evaluado un escenario controlado y otro multijornada sin la baliza 5, analizando la estabilidad de cada método.

El trabajo no se ha limitado a implementar algoritmos. También se han identificado las condiciones bajo las que cada método resulta más adecuado. WKNN constituye una solución sencilla y competitiva en un entorno controlado, mientras que los modelos neuronales ofrecen una mayor robustez cuando las señales varían entre jornadas.

13.4. Limitaciones

Los resultados obtenidos deben interpretarse dentro de las condiciones concretas del experimento.

La primera limitación es el tamaño del conjunto de evaluación. Se utilizan 30 posiciones, lo que permite comparar los métodos y estudiar su distribución espacial, pero limita la generalización estadística. Métricas como el $P90$ o el máximo dependen de un número reducido de puntos y pueden cambiar si se amplía el entorno.

La segunda limitación es que todas las pruebas se realizan en un único escenario físico. Los resultados no permiten garantizar que las mismas configuraciones mantengan su comportamiento en edificios con una geometría, materiales, densidad de obstáculos o distribución de balizas diferentes.

La tercera limitación es que el segundo escenario modifica simultáneamente dos factores: el número de jornadas y la disponibilidad de la baliza 5. El diseño actual permite comparar los escenarios completos, pero no cuantificar por separado el efecto de la variabilidad temporal y el efecto de la pérdida de una baliza.

La cuarta limitación está relacionada con la generalización temporal. La evaluación utiliza los puntos pares del 16 de abril, mientras que los puntos impares de ese mismo día forman parte de la referencia o del entrenamiento. Por tanto, se evalúan posiciones desconocidas, pero no una jornada completamente independiente.

La quinta limitación es la selección de las configuraciones representativas de WKNN. Las combinaciones de métrica, canal y valor de k se comparan sobre el mismo conjunto utilizado para presentar los resultados. En consecuencia, la identificación de la mejor configuración es descriptiva y no constituye una selección validada sobre un tercer conjunto independiente.

La sexta limitación es la comparación entre métodos monocanal y multicanal. El método híbrido utiliza simultáneamente los canales 37, 38 y 39, mientras que WKNN, el perceptrón multicapa y la red residual se analizan de forma independiente por canal. La mejora del híbrido puede deberse tanto a su arquitectura como a la mayor cantidad de información disponible.

La séptima limitación está relacionada con el despliegue de las balizas. Durante la adquisición se observaron zonas con una recepción menos uniforme y no fue posible instalar balizas adicionales en altura. Una geometría de emisión diferente podría mejorar la diferenciación de los puntos periféricos.

La octava limitación es que el análisis se centra en la exactitud y no incluye una evaluación sistemática del coste computacional. Los métodos presentan diferencias importantes en tiempo de entrenamiento, memoria, número de modelos y velocidad de predicción. Estas diferencias resultan relevantes para una futura implantación.

13.5. Trabajo futuro

Las limitaciones identificadas permiten definir varias líneas de trabajo futuro.

13.5.1. Ampliación del diseño experimental

La primera línea consiste en ampliar el número de campañas y reservar una jornada completa para la evaluación. Un esquema de validación por jornadas permitiría entrenar con varios días y evaluar sobre uno completamente desconocido. De esta forma se mediría la generalización temporal real.

También sería conveniente diseñar un experimento factorial que separe el efecto de la variabilidad temporal y el de la baliza 5. Para ello podrían compararse cuatro condiciones:

- ✔ una jornada con ocho balizas;
- ✔ una jornada sin la baliza 5;
- ✔ varias jornadas con ocho balizas;
- ✔ varias jornadas sin la baliza 5.

Esta comparación permitiría determinar si el deterioro de WKNN se debe principalmente a la agregación multijornada, a la pérdida de información o a la combinación de ambos factores.

Otra mejora consiste en aumentar el número de posiciones y repetir las capturas en diferentes condiciones de ocupación, iluminación, mobiliario o circulación de personas. El objetivo sería comprobar si las conclusiones se mantienen fuera de la configuración concreta utilizada en este trabajo.

13.5.2. Mejora del tratamiento multijornada de WKNN

Los resultados indican que el tratamiento actual de WKNN no aprovecha adecuadamente las jornadas adicionales. Por ello, una línea prioritaria consiste en conservar varias huellas por posición en lugar de reducirlas a un único vector de máximos globales.

Podría almacenarse una huella por jornada, captura u orientación, permitiendo que el algoritmo seleccione vecinos entre ejemplos reales. Otra posibilidad sería utilizar agregaciones robustas, como la mediana, medias recortadas o percentiles, en lugar del máximo.

También podrían incorporarse pesos temporales que den mayor importancia a campañas recientes, o seleccionar dinámicamente las jornadas cuya distribución de señal sea más parecida a la muestra evaluada.

Estas modificaciones permitirían comprobar si el deterioro observado se debe al método de vecinos o a la forma concreta en que se construye su mapa de huellas multijornada.

13.5.3. Robustez ante fallos de balizas

La eliminación de la baliza 5 se realiza de forma completa y conocida antes del entrenamiento y la evaluación. En un sistema real, una baliza podría fallar sin aviso o presentar pérdidas intermitentes.

Por ello, sería útil simular la ausencia de cada baliza por separado y analizar qué emisores resultan más importantes para el posicionamiento. También podrían evaluarse fallos simultáneos de varias balizas.

Los modelos neuronales podrían entrenarse con técnicas de eliminación aleatoria de características, de forma que aprendieran a mantener la exactitud cuando algunas señales no estuvieran disponibles. El método híbrido podría incorporar mecanismos que ajustaran dinámicamente el peso de cada canal o baliza en función de su calidad.

13.5.4. Mejora de los modelos neuronales

El perceptrón multicapa y la red residual mantienen un comportamiento estable, pero todavía existen posiciones periféricas con errores superiores. Futuras versiones podrían explorar arquitecturas adaptadas a conjuntos pequeños, regularización adicional y procedimientos de selección de hiperparámetros completamente separados de la evaluación final.

También sería interesante estudiar modelos capaces de estimar su propia incertidumbre. Una predicción acompañada de un nivel de confianza permitiría detectar posiciones poco fiables y solicitar una nueva captura o aplicar un método alternativo.

El método híbrido podría sustituir los pesos fijos por una fusión adaptativa. En lugar de utilizar siempre la misma proporción, el sistema podría asignar pesos diferentes según el canal, el número de balizas observadas o la estabilidad de la muestra.

Otra posibilidad es combinar métodos clásicos y neuronales. Por ejemplo, una red podría generar una primera estimación y WKNN refinarla localmente, o el resultado de los vecinos podría incorporarse como característica adicional para el modelo.

13.5.5. Mejora del despliegue físico

La calidad de los *fingerprints* depende de la geometría y cobertura del despliegue. Sería conveniente realizar mapas previos de cobertura antes de iniciar una campaña definitiva y recolocar las balizas que presenten zonas de baja recepción.

La incorporación de balizas en altura podría mejorar la diversidad espacial de las señales y reducir la ambigüedad entre puntos periféricos. También resultaría útil estudiar el número mínimo de balizas necesario para mantener una exactitud determinada.

Un análisis de importancia por baliza permitiría identificar emisores redundantes y emisores críticos. Esta información podría utilizarse para diseñar despliegues más eficientes y

tolerantes a fallos.

13.5.6. Análisis espacial y temporal más detallado

Las métricas globales resumen el comportamiento del sistema, pero pueden ocultar zonas problemáticas. Una línea futura consiste en analizar el error por regiones, separando puntos centrales, periféricos y zonas con menor cobertura.

También debería estudiarse el error por orientación, jornada, canal y baliza. Este análisis permitiría identificar qué condiciones generan las mayores desviaciones y adaptar el tratamiento de los datos a esas situaciones.

La evolución temporal del RSSI podría modelarse explícitamente mediante estadísticas por día o mediante técnicas de aprendizaje continuo. Así, el sistema podría actualizarse cuando las condiciones del entorno cambiasen sin repetir completamente la campaña de calibración.

13.5.7. Coste computacional e integración operativa

Para valorar la aplicación práctica de los métodos sería necesario medir el tiempo de entrenamiento, el tiempo de predicción, el consumo de memoria y el uso de CPU o GPU.

WKNN no requiere una fase de entrenamiento compleja, pero debe buscar vecinos en el mapa de huellas durante cada predicción. Los modelos neuronales requieren un entrenamiento previo, aunque posteriormente pueden generar estimaciones mediante un número fijo de operaciones.

El método híbrido utiliza un número elevado de redes y ofrece la mejor exactitud, pero también presenta el mayor coste. Una futura optimización podría reducir el tamaño del ensemble, aplicar técnicas de compresión o seleccionar únicamente los modelos que aporten una mejora significativa.

Finalmente, IPSCampaign podría incorporar funciones automáticas para comparar escenarios, exportar tablas, detectar balizas inestables y generar informes de exactitud por zonas. Estas funciones facilitarían la repetición de los experimentos y mejorarían la trazabilidad de los resultados.

13.6. Conclusión final

El trabajo desarrollado demuestra que el posicionamiento en interiores mediante fingerprinting de señales BLE puede alcanzar una exactitud adecuada en el entorno estudiado, pero también evidencia que el rendimiento depende de las condiciones de adquisición y de la representación de los datos.

En un escenario controlado, con todas las balizas operativas y mediciones obtenidas en una misma jornada, WKNN constituye una alternativa sencilla y competitiva. Los modelos neuronales mejoran algunos indicadores, especialmente la media y la mediana, pero no dominan de forma absoluta todas las métricas.

Cuando se incorporan jornadas diferentes y se elimina una baliza, las diferencias aumentan. WKNN experimenta un deterioro notable, mientras que el perceptrón multicapa, la red residual y el método híbrido mantienen una mayor estabilidad. El método híbrido obtiene los mejores resultados, con una exactitud media de 0,85 m y un máximo de 1,64 m.

La principal conclusión no es únicamente que un modelo concreto alcance el menor error. El resultado más relevante es que conservar las capturas individuales de diferentes jornadas y combinar información multicanal proporciona una mayor capacidad de adaptación ante variaciones temporales y ante la pérdida de una baliza.

Por tanto, la robustez de un sistema IPS no depende solo de elegir un algoritmo más complejo. Requiere diseñar adecuadamente las campañas, representar la variabilidad de las señales, evaluar bajo condiciones realistas y mantener una infraestructura de balizas con cobertura suficiente. El conjunto de mejoras incorporadas en IPSCampaign proporciona una base sobre la que continuar desarrollando y evaluando sistemas de posicionamiento más estables y tolerantes a cambios del entorno.

13.7. Uso de la Inteligencia Artificial

Durante el desarrollo del presente Trabajo de Fin de Grado se ha utilizado Inteligencia Artificial generativa como herramienta de apoyo. Su uso se ha centrado principalmente en tareas de asistencia a la redacción, organización de contenidos, revisión de estilo, explicación de conceptos técnicos y apoyo en la estructuración de capítulos.

La Inteligencia Artificial se ha empleado como herramienta auxiliar, no como sustituto del trabajo desarrollado. Las decisiones técnicas, la implementación de los métodos, la ejecución de los experimentos, la interpretación de los resultados y la selección del contenido final han sido responsabilidad del autor del trabajo. Las respuestas generadas se han revisado, adaptado y contrastado antes de incorporarse a la memoria.

También se ha utilizado como apoyo para mejorar la claridad de algunos apartados, especialmente aquellos relacionados con la explicación de conceptos como *fingerprinting*, WKNN, modelos basados en DL, métricas de evaluación y análisis de resultados. En estos casos, el objetivo ha sido facilitar una redacción más comprensible y ordenada, manteniendo siempre la coherencia con el desarrollo real del proyecto.

Por tanto, el uso de Inteligencia Artificial se ha limitado a funciones de apoyo documental y revisión, sin delegar en ella la autoría técnica del trabajo ni la validación de los resultados. La responsabilidad sobre el contenido final, las conclusiones y las aportaciones realizadas corresponde al autor del presente Trabajo de Fin de Grado.

13.8. Disponibilidad del código y los materiales

El código fuente desarrollado durante este Trabajo de Fin de Grado, junto con las modificaciones realizadas sobre IPSCampaign y la documentación necesaria para su ejecución, se encuentra disponible públicamente en el siguiente repositorio:

https://github.com/juanfradelrm/indoor-positioning-deep-learning

El repositorio incluye la implementación de los métodos de posicionamiento, el tratamiento de los datos y los recursos necesarios para reproducir los experimentos descritos en esta memoria.

Bibliografía

[1] Blender Foundation (2025). Blender. Disponible en: https://www.blender.org/. Accedido: 8 de mayo de 2026.

[2] Bluetooth Special Interest Group (2024). The Bluetooth Low Energy Primer. Disponible en: https://www.bluetooth.com/bluetooth-le-primer/. Accedido: 8 de mayo de 2026.

[3] Cortesi, S., Dreher, M., and Magno, M. (2023). Design and implementation of an rssi-based bluetooth low energy indoor localization system. *arXiv preprint arXiv:2310.14704*. Disponible en: https://arxiv.org/abs/2310.14704.

[4] DataSolut (2019). CRISP-DM Methodology. Disponible en: https://datasolut.com/wp-content/uploads/2019/11/grafik-2.png. Accedido: 8 de mayo de 2026.

[5] Departamento de Informática y Sistemas, Universidad de Las Palmas de Gran Canaria (2026). Laboratorio 2.4. Disponible en: https://www.dis.ulpgc.es/basesdis/laboratorios/laboratorio.asp?id=lab2-4. Accedido: 8 de mayo de 2026.

[6] European Union Agency for the Space Programme (2025). What is GNSS? Disponible en: https://www.euspa.europa.eu/eu-space-programme/galileo/what-gnss. Accedido: 8 de mayo de 2026.

[7] Hayward, S. J., van Lopik, K., Hinde, C., and West, A. A. (2022). A survey of indoor location technologies, techniques and applications in industry. *Internet of Things*, 20:100608. Disponible en: https://www.sciencedirect.com/science/article/pii/S2542660522000907.

[8] Kontakt.io (2021). What is a Beacon? BLE Beacons Explained. Disponible en: https://kontakt.io/blog/what-is-a-beacon/. Accedido: 8 de mayo de 2026.

[9] Marvelmind Robotics (2025). Precise indoor positioning system. Disponible en: https://marvelmind.com/. Accedido: 8 de mayo de 2026.

[10] National Coordination Office for Space-Based Positioning, Navigation, and Timing (2024). The Global Positioning System. Disponible en: https://www.gps.gov/gps/. Accedido: 8 de mayo de 2026.

[11] Python Software Foundation (2025). What is Python? Executive Summary. Disponible en: https://www.python.org/doc/essays/blurb/. Accedido: 8 de mayo de 2026.

[12] PyTorch Foundation (2025). PyTorch documentation. Disponible en: https://docs.pytorch.org/docs/stable/index.html. Accedido: 8 de mayo de 2026.

[13] Ramos Sánchez, A. (2023). Robotcontrol Editor Toolbox - Blender addon. Disponible en: https://github.com/bertoramos/blender-editor. Accedido: 8 de mayo de 2026.

[14] Rusu Stratulat, S. T. (2023). Sistema de procesamiento de datos para la mejora del posicionamiento en interiores: integración con plataforma robótica de toma de datos bluetooth low energy. Trabajo de Fin de Grado, Universidad de Las Palmas de Gran Canaria. Disponible en: https://accedacris.ulpgc.es/bitstream/10553/126133/1/TFG_Simon_Rusu_v2_AQ_GdB.pdf.

[15] Safwat, R., Shaaban, E., and Altabbakh, S. (2023). Fingerprint-based indoor positioning system using ble: Real deployment study. *Bulletin of Electrical Engineering and Informatics*, 12(1):240–249. Disponible en: https://beei.org/index.php/EEI/article/view/3798.

[16] scikit-learn developers (2025). scikit-learn: Machine Learning in Python. Disponible en: https://scikit-learn.org/stable/. Accedido: 8 de mayo de 2026.

[17] Subedi, S., Gang, H.-S., Ko, N. Y., Hwang, S., and Pyun, J.-Y. (2020). A survey of smartphone-based indoor positioning system using rf-based wireless technologies. *Sensors*, 20(24):7230. Disponible en: https://www.mdpi.com/1424-8220/20/24/7230.

[18] Xia, S., Liu, Y., Yuan, G., Zhu, M., and Wang, Z. (2017). Indoor fingerprint positioning based on wi-fi: An overview. *ISPRS International Journal of Geo-Information*, 6(5):135. Disponible en: https://www.mdpi.com/2220-9964/6/5/135.

[19] Yang, T., Cabani, A., and Chafouk, H. (2021). A survey of recent indoor localization scenarios and methodologies. *Sensors*, 21(23):8086. Disponible en: https://www.mdpi.com/1424-8220/21/23/8086.

[20] Yaro, A. S., Sha'ameri, A. Z., Kamel, N., Saad, N. M., and Mabrouk, M. (2023). A survey of the performance-limiting factors of a 2-dimensional rss fingerprinting-based indoor wireless localization system. *Sensors*, 23(5):2545. Disponible en: https://www.mdpi.com/1424-8220/23/5/2545.